Descubrimiento de Información en Textos

Tarea del tema 4: Comparativa de etiquetadores estadísticos

Ariadna Frutos Javierre

8 de febrero de 2020

Índice

Introducción **3**

1. Descripción de los etiquetadores **3**

1.1. Averaged Perceptron Classifier . . . 3

1.1.1. El modelo Perceptron . . . 3

1.1.2. Implementación del modelo perceptron en el etiquetador Average Perceptron Classifier . . . 4

1.2. Trigrams'n Tags (TnT) . . . 5

1.2.1. El modelo de Markov oculto . . . 5

1.2.2. Implementación del modelo HMM en el etiquetador TnT . . . 6

1.3. Standford MaxEnt POS Tagger. Versión unidireccional . . . 8

1.3.1. El modelo de maximización de la entropía . . . 8

1.3.2. Implementación del modelo de maximización de la entropía en el etiquetador Stanford MaxEnt PoS Tagger . . . 9

1.4. Standford MaxEnt POS Tagger. Versión bidireccional . . . 11

2. Comparativa **12**

2.1. Descripción del proceso realizado . . . 12

2.1.1. Entrenamiento . . . 12

2.1.2. Conjunto de etiquetas . . . 15

2.1.3. Test cuantitativo . . . 16

2.1.4. Test cualitativo . . . 16

2.2. Resultados . . . 16

2.2.1. Test cuantitativo . . . 16

2.2.2. Test cualitativo . . . 17

3. Conclusiones **19**

Anexos **21**

Anexo A: Conjuntos de etiquetas gold 21

Tagset Brown 21

Etiquetas adicionales 23

Tagset Universal 23

Correspondencia entre etiquetas Brown y Universal 23

Anexo B: Texto del test cualitativo (corpus Brown, CE01) 27

Versión sin etiquetar 27

Versión con etiquetas gold 27

Versiones etiquetadas por los tres etiquetadores entrenados 28

Referencias **36**

Introducción

El etiquetado léxico consiste en asignar la secuencia de categorías léxicas más probable a una cadena de palabras. En esta tarea se comparan 3 etiquetadores distintos: el *Averaged Perceptron Classifier* [Honnibal 2013A], el *Trigrams' n Taggs* [Brants 2000] y el *Stanford MaxEnt POS Tagger* [Toutanova 2000, Toutanova 2003]. El primero se ha elegido por su sencillez. No se incluye en el listado de etiquetadores propuesto en el enunciado de la tarea ([Manning 2014]), pero es el etiquetador por defecto de la librería NLTK y el código, que no llega a las 200 líneas, es muy accesible [Honnibal 2013B], de modo que consideré oportuno analizarlo. El segundo se ha elegido por ser un etiquetador basado en HMM que, sin ser muy complejo, consigue, según [Jurafsky 2019], una precisión apenas superada por los etiquetadores más robustos de última generación. Finalmente, el *Stanford MaxEnt POS Tagger* se ha elegido por utilizar una aproximación distinta a las anteriores y por la confianza en la institución que lo distribuye, el grupo de PLN de la Universidad de Stanford. De este último se presentan dos versiones, la unidireccional y la bidireccional, pero solo se incluyen resultados experimentales de la primera.

El trabajo se divide en tres partes. En la primera se describen los etiquetadores. En la segunda parte se describen las pruebas realizadas y se presenta una comparativa. Finalmente, en la tercera se resumen las observaciones sobre la comparativa de los resultados, a modo de conclusión. Las descripciones de los etiquetadores se basan en la documentación específica de cada etiquetador, ampliada con información extraída de [Jurafsky 2019] y [Manning 2000], así como en aportaciones personales derivadas del estudio del código fuente, cuando ha sido posible.

1. Descripción de los etiquetadores

1.1. Averaged Perceptron Classifier

El interés de este etiquetador está, sobre todo, en su simplicidad. Según el propio autor, se ha renunciado a algo de precisión y eficiencia a cambio de mantener una implementación sencilla.

1.1.1. El modelo Perceptron

La aproximación utilizada es el modelo conocido como **perceptron**, un algoritmo de entrenamiento supervisado basado en clasificadores lineales binarios. En el perceptron, cada elemento a caracterizar (las palabras[1], en este caso) se representa mediante un vector de rasgos (*«feature vector»*). La predicción de si una palabra pertenece o no a una determinada clase (categoría léxica) se basa en el resultado de combinar linealmente el vector de rasgos con el llamado vector de pesos (*«weight vector»*) para esa clase:

$$f_c(\mathbf{x}) = \mathbf{w} \cdot \mathbf{x} = \sum_{i=1}^{m} w_i \cdot f_i \,, \tag{1}$$

donde $\mathbf{x}$ es el vector de rasgos de la palabra a etiquetar, $\mathbf{w}$ es el vector de pesos para la clase c, m el número de rasgos que se consideran y$f_c(\mathbf{x})$ es la función de predicción de la clase c para el vector $\mathbf{x}$. La clase c que obtiene un mayor valor de la función de predicción $f_c(\mathbf{x})$ es la que se asigna a la palabra. El vector $\mathbf{x}$ se obtiene a partir de ciertas características de la palabra a etiquetar y su contexto (las características de las palabras que la rodean). Estas características son rasgos del tipo «*palabra i = 'Parliament'*», «*palabra i-1 = 'the'*», «*categoría de la palabra i = 'Nombre'*», «*categoría de la palabra i-1 = 'Determinante'*», etc., donde i representa la palabra que se está considerando e i-1 la palabra anterior a ésta. El vector $\mathbf{w}$ se determina mediante aprendizaje automático supervisado, utilizando un corpus previamente etiquetado.

[1] En todo el trabajo, se utiliza «palabra» en el sentido de «token». Es decir, el término puede referirse a las palabras del diccionario u otros símbolos, como símbolos de puntuación, símbolos de moneda o números.

1.1.2. Implementación del modelo perceptron en el etiquetador Average Perceptron Classifier

Como puede deducirse de los ejemplos anteriores, el número de rasgos a incluir en un etiquetador basado en el modelo perceptron será, como mínimo, del orden del vocabulario que se considere; es decir, un número impracticable vectorialmente. Por ello, en su implementación, el Average Perceptron Classifier utiliza diccionarios en vez de vectores, descartando así las componentes nulas, que no afectan al resultado de la combinación lineal. En concreto, el conjunto de rasgos relevantes (no nulos) de la palabra i a etiquetar se almacena en el diccionario *rasgos* («*features*») utilizando el método `_get_features()`. Este método determina los rasgos relevantes de la palabra utilizando patrones y les asigna el valor 1. Los pesos se almacenan en el objeto *pesos* («*weights*»), un diccionario de diccionarios que asigna a cada pareja rasgo/clase (*feature*/*class*, o, conjuntamente, «*label*») un peso. Los pesos se determinan mediante entrenamiento, tal como se explica en el apartado siguiente. A partir de estos dos objetos, *rasgos* y *pesos*, el método `predict()` realiza la operación (1) para cada clase y selecciona la que obtiene un resultado mayor.

1.1.2.1. Rasgos

Los rasgos incluidos en el algoritmo se muestran en el cuadro 1.

Cuadro 1:

Nombre del rasgo	Rasgo	Descripción, respecto la palara a etiquetar
`i suffix`	`word[-3:]`	Los tres últimos caracteres
`i pref1`	`word[0]`	El primer carácter
`i-1 tag`	`prev`	La etiqueta anterior
`i-2 tag`	`prev2`	La etiqueta a dos posiciones a la izquierda
`i tag+i-2 tag'`	`prev, prev2`	Las dos etiquetas anteriores
`i word`	`context[i]`	La misma palabra a etiquetar
`i-1 tag+i word`	`prev, context[i]`	La etiqueta anterior y la misma palabra a etiquetar
`i-1 word`	`context[i-1]`	La palabra anterior
`i-1 suffix'`	`context[i-1][-3:]`	La palabra anterior y los últimos tres caracteres
`i-2 word`	`context[i-2]`	La palabra dos posiciones a la izquierda
`i+1 word`	`context[i+1]`	La palabra siguiente
`i+1 suffix`	`context[i+1][-3:]`	La palabra siguiente y los últimos tres caracteres
`i+2 word`	`context[i+2]`	La palabra dos posiciones a la derecha

1.1.2.2. Entrenamiento

En el entrenamiento se empieza con un diccionario de pesos vacío. A partir de aquí, los pesos de los distintos rasgos se determinan realizando un cierto número de veces, según se considere oportuno, las siguientes iteraciones, una para cada palabra del corpus de entrenamiento:

1. Se toma la pareja rasgos/clase correspondiente a la palabra . Como ya se ha dicho, el objeto *rasgos* es un diccionario que reúne los valores que toman los rasgos para la palabra; la *clase* es la categoría léxica que tiene asignada.
2. Se realiza una predicción de la categoría léxica, utilizando los pesos actuales.
3. Si la predicción es errónea, se actualizan los pesos de la siguiente manera: se suma +1 a los pesos asociados a la clase correcta y -1 a los pesos correspondientes a la clase predicha.

En el resultado final, en vez de utilizar los valores de los pesos de la última iteración, se toma la media de los valores que han ido tomando tras cada paso 3. Este refinamiento se introduce para evitar que las últimas iteraciones, en que toman protagonismo los ejemplos mal clasificados, sean las que determinen el modelo. Para ello se utilizan los métodos `update()` y `average_weights()`.

El primero lleva la cuenta del número de iteraciones en que un peso no cambia y cuando cambia, actualiza el acumulador. Este método de actualización disminuye el espacio en memoria respecto al que se requeriría si se guardaran uno a uno los resultados. El segundo realiza el cálculo final a partir del último valor del acumulador y el número total de iteraciones.

1.1.2.3. Etiquetado

Una vez determinados los pesos (el algoritmo en la versión de la librería NLTK permite cargar pesos ya entrenados o utilizar el `método train()` para entrenar nuevos pesos), el modelo permite etiquetar frases previamente *tokenizadas* utilizando el método `tag()`. Este método recorre las palabras de la frase, una a una, y les adjunta la etiqueta seleccionada por el método `predict()`, descrito más arriba.

1.1.2.4. Otros refinamientos

Además de los descritos, el módulo incluye métodos para realizar las siguientes operaciones:

`_make_tagdict()`: Dado un corpus de entrenamiento, crea un diccionario palabra-categoría con las palabras que no presentan ambigüedad. Este diccionario sustituye, durante el entrenamiento, el proceso iterativo de predicción para esas palabras, mejorando notablemente la eficiencia.

`normalize()`: Preprocesamiento de los textos a etiquetar (*tokenización*).

`_softmax()`: (Opcional): Añade, junto a la etiqueta predicha para una palabra, un valor númerico que indica la fiabilidad de ésta.

`save()/load()`: Guarda y carga, respectivamente, los pesos del modelo.

`_get_pretrain_model()`: Entrena el modelo utilizando como corpus el subconjunto WSJ del Treebank.

1.2. Trigrams'n Tags (TnT)

1.2.1. El modelo de Markov oculto

En el modelo de Markov oculto (HHM) se considera que a una secuencia de observaciones dada, o_1 ... o_n, le corresponde una secuencia de estados ocultos, q_1 ... q_n. Además, se presuponen las siguientes hipótesis:

1- Hipótesis de Markov: La probabilidad de un estado q_i depende únicamente de los estados anteriores. En concreto, para un modelo de Markov de segundo orden, depende de los dos estados anteriores:

$$P(q_i|q_1...q_{i-1}) = P(q_i|q_{i-2}, q_{i-1})$$

Esta probabilidad recibe el nombre de **probabilidad de transmisión**.

2- Independencia de las observaciones: La probabilidad de una observación o_i solo depende del estado q_i que la ha producido, no del resto de estados ni observaciones:

$$P(o_i|o_1...o_i...o_n, q_1...q_i) = P(o_i|q_i)$$

Esta probabilidad recibe el nombre de **probabilidad de emisión**.

Por lo tanto, en este modelo la probabilidad total de la secuencia de estados q_1 ... q_n dada la secuencia de observaciones o_1 ... o_n es, aplicando primero el teorema de Bayes y luego las dos hipótesis :

$$P(q_1...q_n|o_1...o_n) = \frac{P(o_1...o_n|q_1...q_n) \cdot P(q_1...q_n)}{P(o_1...o_n)} \approx \frac{\prod_{i=1}^{n} P(o_i|q_i)P(q_i|q_{i-2}, q_{i-1})}{P(o_1...o_n)} \tag{2}$$

La secuencia de estados más probable dada una secuencia de observaciones es, pues, aquella que satisface la siguiente igualdad:

$$(q_1...q_n) = \underset{q_1...q_n}{\arg\max} \prod_{i=1}^{n} P(o_i|q_i)P(q_i|q_{i-2}, q_{i-1}) \tag{3}$$

No es necesario incluir la cantidad $P(o_1 \ ... \ o_n)$ en la fórmula porque se trata de un valor constante.

1.2.2. Implementación del modelo HMM en el etiquetador TnT

En el modelo utilizado por el etiquetador TnT las observaciones son las palabras y los estados, las categorías léxicas a asignar. Dada una secuencia de palabras $w_1 \ ... \ w_n$ de longitud n, el etiquetador TnT calcula las etiquetas $t_1 \ ... \ t_n$ a partir de las dos etiquetas anteriores maximizando la probabilidad siguiente[2]:

$$\underset{t_1...t_n}{\arg\max} \left[\prod_{i=1}^{n} P(t_i|w_i)P(t_i|t_{i-2}, t_{i-1}) \right] P(t_{n+1}|t_n) \tag{4}$$

A la secuencia de etiquetas original se añaden las etiquetas adicionales t_{-1}, t_0, y t_{n+1} , correspondientes a los marcadores de principio y final de secuencia.

Las probabilidades de transmisión y emisión se estiman a partir de las frecuencias relativas de palabras y etiquetas de un corpus de entrenamiento. Las probabilidades de transmisión se calculan como una interpolación lineal de las probabilidades de unigramas, bigramas y trigramas:

$$P(t_3|t_2, t_1) = \lambda_1 \hat{P}(t_3) + \lambda_2 \hat{P}(t_3|t_2) + \lambda_3 \hat{P}(t_3|t_2, t_1) \tag{5}$$

donde $\hat{P}(t_3)$, $\hat{P}(t_3|t_2)$ y $\hat{P}(t_3|t_2, t_1)$ son las estimaciones por máxima verosimilitud de unigramas, bigramas y trigramas, respectivamente. La interpolación es necesaria para evitar los problemas derivados de la dispersión, como las probabilidades nulas para trigramas que no se dan en el corpus pero que pueden aparecer en una nueva secuencia.

Las probabilidades de emisión son, para las palabras que aparecen en el corpus:

$$P(w_3|t_3) = \hat{P}(w_3|t_3) \tag{6}$$

Para las palabras que no aparecen en el corpus, la aproximación de [Brants 2000] incluye una asignación de etiquetas basada en las terminaciones que se describen en el apartado 1.2.2.3.

[2]De hecho, la versión de la librería NLTK [nltk.tag.tnt - Code] analizada maximiza la adición logarítmica en lugar de multiplicación, es decir:

$$\underset{t_1...t_n}{\arg\max} \left[\sum_{i=1}^{n} (\log(P(t_i|w_i))) + \log(P(t_i|t_{i-2}, t_{i-1})) \right] + \log(P(t_{n+1}|t_n))$$

1.2.2.1. Entrenamiento

En este caso, el entrenamiento consiste en encontrar las frecuencias relativas, $\hat{P}(t_3)$, $\hat{P}(t_3|t_2)$, $\hat{P}(t_3|t_2,t_1)$ y $\hat{P}(w_3|t_3)$, así como los pesos λ_1, λ_2 y λ_3. En el módulo TnT de la librería NLTK [nltk.tag.tnt - Code], estos cálculos ser realizan a través del método `train()`. Las frecuencias relativas se obtienen directamente del corpus etiquetado:

$$\begin{aligned} \text{Frecuencias léxicas} : \hat{P}(w_3|t_3) &= \frac{f(w_3,t_3)}{f(t_3)} \\ \text{Unigramas} : \hat{P}(t_3) &= \frac{f(t_3)}{N} \\ \text{Bigramas} : \hat{P}(t_3|t_2) &= \frac{f(t_2,t_3)}{f(t_2)} \\ \text{Trigramas} : \hat{P}(t_3|t_2,t_1) &= \frac{f(t_1,t_2,t_3)}{f(t_2,t_3)} \end{aligned} \tag{7}$$

N es el número de palabras del corpus y $f()$ es el número de veces en que aparece la combinación palabra-etiqueta o la cadena de etiquetas mencionadas entre paréntesis. Cuando el denominador de la estimación es cero, ésta se define como igual a cero.

Los pesos λ_1, λ_2 y λ_3 se calculan utilizando el método de interpolación eliminada, que consiste en ir eliminando sucesivamente cada trigrama del corpus de entrenamiento, eligiendo, en cada iteración, el valor de los pesos que maximizan la verosimilitud del resto del corpus. En la librería NLTK, esta operación se realiza mediante la función `_compute_lambda()`.

1.2.2.2. Etiquetado

Para el etiquetado se maximiza la probabilidad 4 mediante el algoritmo de Viterbi, modificado con la técnica de búsqueda por haces (*beam search*) para mejorar la eficiencia: en lugar de mantener toda la columna de estados en cada punto de la secuencia a etiquetar, se seleccionan únicamente los que cumplen mejor la hipótesis en ese punto[3]. Las probabilidades locales se calculan utilizando de las ecuaciones 5 y 6 y los valores $\hat{P}(t_3)$, $\hat{P}(t_3|t_2)$, $\hat{P}(t_3|t_2,t_1)$, $\hat{P}(w_3|t_3)$, λ_1, λ_2 y λ_3 estimados durante el entrenamiento.

1.2.2.3. Refinamientos

La implementación del algoritmo original [Brants 2000] incluye los siguientes refinamientos:

- Posibilidad de incluir la observación o no de mayúsculas

  En caso de querer incluir esta información, el algoritmo añade, tanto en el entrenamiento como en el etiquetado, una etiqueta booleana c_i para cada palabra i que indica si la palabra empieza o no en mayúscula. Las probabilidades $P(t_i|t_{i-2},t_{i-1})$ pasan entonces a ser del tipo $P(t_i,c_i|t_{i-2},c_{i-2},t_{i-1},c_{i-1})$; las estimaciones (7) se modifican de la misma manera.

- Posibilidad de modificar el grado del haz H (número máximo de soluciones posibles que se mantienen durante el etiquetado) del algoritmo de Viterbi modificado.

- Etiquetado de palabras desconocidas[4]. Para las palabras que no aparecen en el corpus («palabras desconocidas»), las probabilidades de emisión se establecen a partir de las probabilidades de sus terminaciones:

$$P(t|w) = P(t|l_{s-r+1}...l_s),$$

[3]Tras esta modificación, ya no puede decirse estrictamente que la secuencia de etiquetas encontrada maximiza la probabilidad 4. Sin embargo, la aproximación es válida a efectos prácticos pues, como se verá, el algoritmo da buenos resultados.

[4]Este refinamiento no está incluido en la versión del la librería NLTK

donde s es la longitud de la palabra y r la longitud de la terminación, que se determina empíricamente. La estimación de la probabilidad de una etiqueta dada una terminación de longitud i, $P(t|l_{s-i+1}...l_s)$ se obtiene a partir de los datos del corpus según la siguiente fórmula recursiva, que tiene en cuenta las frecuencias relativas de las terminaciones de longitud i y menores:

$$P(t|l_{s-i+1}...l_s) = \frac{\hat{P}(t|l_{s-i+1}...l_s) + \theta_i P(t|l_{s-i}...l_s)}{1+\theta_i} \tag{8}$$

Las frecuencias relativas se calculan a partir de los datos del corpus, según:

$$\hat{P}(t|l_{s-i+1}...l_s) = \frac{f(t|l_{s-i+1}...l_s)}{f(l_{s-i+1}...l_s)}$$

La interpolación se realiza para suavizar el resultado. Los pesos θ_i se definen como la la desviación estándar de la probabilidad no condicionada de las etiquetas en el corpus:

$$\theta_i = \frac{1}{t-1}\sum_{j=1}^{T}\left(P(t_j) - \bar{P}\right)$$

siendo T el número de etiquetas que del *tagset* y $\bar{P}$, la media:

$$\bar{P} = \frac{1}{t}\sum_{j=1}^{T}\hat{P}(t_j)$$

1.3. Standford MaxEnt POS Tagger. Versión unidireccional

Para la descripción de este etiquetador me baso en [Toutanova 2000], [Manning 2000] y [Berger 1996]. En este caso no he analizado el código.

1.3.1. El modelo de maximización de la entropía

La entropía de una variable aleatoria discreta X que toma valores $x \in X$ con una probabilidad es $p(x)$ se define como [Manning 2000]:

$$H(\mathcal{X}) = -\sum_{x \in X} p(x)\log\left(p(x)\right).$$

Se trata de una medida de la cantidad de información contenida en la variable aleatoria.

El modelo de máxima entropía selecciona, de entre todas las distribuciones $p(x)$ compatibles con las restricciones impuestas por las observaciones, aquella que maximiza $H(X)$:

$$P(x) = \arg\max_{p(x)} H(x) \tag{9}$$

La motivación para la maximización está en la voluntad de mantener la máxima incertidumbre posible, pues de no ser así se estarían incluyendo restricciones no justificadas por los datos.

Las restricciones se expresan como los valores esperados de ciertas funciones binarias $f_i(x,\ c)$ llamadas «rasgos» (en inglés, «*features*»), las cuales caracterizan las propiedades de las parejas (x, c), donde c es la clase asignada al elemento cuyas propiedades son x. Es decir:

$$f_i(x,c) = \begin{cases} 1 & \text{si } c = 1 \text{ el y rasgo } f_i \text{ se da en } x \\ 0 & \text{en otro caso} \end{cases}$$

Una clase de distribución que es solución del problema de optimización (9) es el modelo exponencial parametrizado:

$$P(x,c) = \frac{\prod_{j=1}^{K} e^{\lambda_j f_j(x,c)}}{\sum_{c' \in C} \prod_{j=1}^{K} e^{\lambda_j f_j(x,c')}}, \tag{10}$$

donde K es el número de rasgos, C el conjunto de categorías o clases y λ_j los parámetros o pesos a determinar. El denominador es un término de normalización llamado función de partición.

1.3.2. Implementación del modelo de maximización de la entropía en el etiquetador Stanford MaxEnt PoS Tagger

El etiquetador Standford MaxEnt POS Tagger es un etiquetador basado en un modelo de maximización de la entropía. En su versión unidireccional [Toutanova 2000] el modelo probabilístico utilizado es, como en el caso anterior, un modelo condicional de Markov: dada una secuencia de palabras w_1 ... w_n de longitud n, la probabilidad de que a la palabra w_i le corresponda la etiqueta t_i depende de la secuencia de palabras w_1 ... w_n y de las etiquetas asignadas a las palabras anteriores, t_1 ... t_n. Se trata, pues, de una red bayesiana, de modo que la probabilidad conjunta de la secuencia de etiquetas t_1 ... t_{i-1}, dada la secuencia de palabras w_1 ... w_n es el producto de las probabilidades condicionales individuales de cada etiqueta, dadas las etiquetas anteriores y la secuencia de palabras:

$$P(t_1...t_n|w_1...w_n) = \prod_{i=1}^{n} P(t_i|t_1...t_{i-1}, w_1...w_n))$$

De modo parecido al modelo HMM, estas probabilidades individuales se pueden aproximar a las probabilidades dado el contexto más inmediato, representado aquí por h_i:

$$P(t_1...t_n|w_1...w_n) = \prod_{i=1}^{n} P(t_i|t_1...t_{i-1}, w_1...w_n) \approx \prod_{i=1}^{n} P(t_i|h_i) \tag{11}$$

Como ya se ha dicho, la estrategia basada en la maximización de la entropía consiste en seleccionar, de entre las posibles distribuciones de probabilidad compatibles con las restricciones impuestas por el corpus de entrenamiento, aquella distribución $p(t_1...t_n|w_1...w_n)$ con mayor entropía. Los rasgos son $f_i(h,t)$, donde t representa una clase o etiqueta léxica y h un posible contexto; sus valores esperados, calculados siguiendo la distribución conjunta de contextos y etiquetas, $P(h,t)$, son:

$$Ef_i = \sum_{h \in X, t \in T} P(h,t) f_i(h,t) = \sum_{h \in X, t \in T} \widetilde{p}(h) P(t|h) f_i(h,t), \tag{12}$$

donde T es el conjunto de etiquetas considerado y X el espacio de contextos h del corpus de entrenamiento en que aparece la etiqueta t. Se ha aproximado la distribución conjunta de contextos y etiquetas, $P(h,t)$, por el producto de la distribución empírica de contextos, $\widetilde{p}(h)$, y la distribución condicional, $P(t|h)$.

Estos valores deben coincidir con los correspondientes a la distribución empírica, es decir:

$$E_{P(h,t)} f_i(h,t) = E_{\widetilde{p}(h,t)} f_i(h,t)$$

La clase distribución que maximiza la entropía bajo estas constricciones es [Toutanova 2000]:

$$P(h,t) = \frac{\prod_{j=1}^{K} e^{\lambda_j f_j(h,t)}}{\sum_{t' \in T} \prod_{j=1}^{K} e^{\lambda_j f_j(h,t')}}. \tag{13}$$

Se trata, de hecho, de la clase 10, adaptada al caso que nos ocupa.

1.3.2.1. Rasgos

En el modelo base del etiquetador, los contextos h considerados para el etiquetado léxico de la palabra w_i incluida en de la secuencia $\{w_1 \ldots w_n\}$ con etiquetas $\{t_1 \ldots t_n\}$ se reducen a combinaciones de $\{t_{i-2}, t_{i-1}, w_i, w_{i+1}\}$. Los rasgos se generan a partir de las plantillas de la tabla 2. Se distinguen dos tipos de plantilla: las generales, que crean instancias de contextos arbitrarios, y las raras, que crean instancia solo cuando la palabra w_i es poco frecuente.

Cuadro 2: Rasgos genéricos considerados en el mdoelo base (fuente: [Toutanova 2000])

No.	Feature Type	Template
1.	General	w_i=X & t_i =T
2.	General	t_{i-1}=T_1 & t_i=T
3.	General	t_{i-1}=T_1 & t_{i-2}=T_2 & t_i=T
4.	General	w_{i+1}=X & t_i =T
5.	Rare	Suffix of w_i =S, $\|S\|$<5 & t_i=T
6.	Rare	Prefix of w_i =P, 1<$\|P\|$<5 & t_i=T
7.	Rare	w_i contains a number & t_i=T
8.	Rare	w_i contains an uppercase character & t_i=T
9.	Rare	w_i contains a hyphen & t_i=T

1.3.2.2. Entrenamiento

El entrenamiento consiste en estimar los parámetros λ_j a partir del corpus etiquetado. El algoritmo utilizado para ello realiza un procedimiento de escalado iterativo mejorado que combina las ecuaciones (11), (13) y (12) como sigue [Berger 1996]:

1. Inicializar λ_j=0 para todo $j \in \{1, 2, \ldots, K\}$
2. Hacer, para cada $j \in \{1, 2, \ldots, K\}$:
   a) Sea $\Delta\lambda_j$ la solución de

   $$\sum_{h \in X, t \in T} \widetilde{p}(h) P(t|h) f_j(h,t) e^{\Delta\lambda_j f^*(h,t)} = \widetilde{p}(f_i),$$

   donde

   $$f^*(h,t) = \sum_{j=1}^{K} f_i(h,t)$$

   b) Actualizar el valor de λ_j según

   $$\lambda_j \leftarrow \lambda_j + \Delta\lambda_j$$

   c) Volver al paso 2 si no han convergido todas las λ_j.

1.3.2.3. Etiquetado

No se describe, y el código fuente [Stanford MaxEnt - code] es demasiado complejo para el alcance de esta tarea. Entiendo que se realiza palabra a palabra, de izquierda a derecha, calculando (13) para cada posible etiqueta y asignando la etiqueta más probable.

1.3.2.4. Refinamientos

Los refinamientos asignados consisten en rasgos añadidos respecto los de la tabla 2, basados en [Ratnaparkhi 1996]. Se centran en la mejora del etiquetado de palabras desconocidas, en particular:

- La distinción de nombres propio, NNP
- La distinción entre las categorías de verbos VBN/VBD y VBP/VB
- La desambiguación de partículas RB/RP/IN

Además de estos, en la versión utilizada en la comparativa ([Stanford MaxEnt - download]) se incluyen los siguientes nuevos extractores de rasgos para palabras poco frecuentes:

- `wordshapes(-1,1)`: En palabras poco frecuentes, comprueba si la secuencia formada por los caracteres anterior (-1), actual (0) y posterior (1) sigue ciertos patrones y crea un rasgo a partir de estos.
- `distsim(models\egw4-reut.512.clusters,-1,1)`: Extrae rasgos para la posición anterior (-1), actual (0) y posterior (1), comparando la palabra con el diccionario proporcionado como parámetro. El diccionario `egw4-reut.512.clusters` puede descargarse de [Stanford MaxEnt - FAQs].
- `distsimconjunction(models\egw4-reut.512.clusters,-1,1)`: Concatenación de los rasgos generados por `distsim()`desde la posición anterior (-1) a la posterior (1).

1.4. Standford MaxEnt POS Tagger. Versión bidireccional

En la versión [Toutanova 2003] del etiquetador Standford MaxEnt POS Tagger el modelo unidireccional se modifica para convertirlo en bidireccional, de modo que a la hora de asignar la etiqueta t_i a la palabra w_i de la secuencia w_1 ... w_n puedan tenerse en cuenta rasgos relacionados con las etiquetas posteriores, además de las anteriores. Para ello se construye una red de dependencia en que la etiqueta de cada nodo puede estar condicionada de forma directa por el número que se quiera de otros nodos, tanto a izquierda como a derecha. Con este modelo, la red deja de ser acíclica, con lo que la probabilidad $P(t_1...t_n|w_1...w_n)$ ya no se corresponde con (11). Por ello, en lugar de maximizar la entropía de $P(t_1...t_n|w_1...w_n)$ se maximiza la entropía de una nueva cantidad, *score*, definida como:

$$score(t_1...t_n|w_1...w_n) = \prod_i P(t_i|Pa(t_i)),$$

donde $Pa(\ t_i\ )$ son los padres del nodo t_i , es decir, las etiquetas anteriores y posteriores a la etiqueta t_i[5].

Nótese que, ahora, la secuencia de etiquetas seleccionada puede no ser la secuencia más probable. Sin embargo, para el etiquetado sintáctico esta aproximación da buenos resultados [Toutanova 2003].

[5] Para grafos cíclicos, en que solo se consideran o bien las etiquetas anteriores, como en la versión [Toutanova 2003], o bien las posteriores, el valor $score(t_1...t_n|w_1...w_n)$ coincide con la probabilidad $P(t_1...t_n|w_1...w_n)$ de (11).

2. Comparativa

La comparativa se ha realizado entrenando modelos para cada etiquetador utilizando un mismo corpus de entrenamiento. Todos los etiquetadores estudiados incluyen la opción de utilizar modelos ya entrenados, pero las condiciones de entrenamiento de éstos varían. Por ello se ha considerado oportuno realizar el proceso entero, incluyendo el entrenamiento. Una vez entrenados, se ha realizado un test cuantitativo con 50 nuevos textos. Finalmente se ha realizado el etiquetado de las 15 primeras líneas de uno de estos últimos textos, como se pedía el enunciado de la práctica.

Los textos utilizados proceden del corpus de Brown, en la versión distribuida en el módulo [nltk.corpus - Doc.] de la librería nltk. Para los cálculos se ha utilizado un ordenador Intel Core i5-7200U con 8GB de memoria RAM. En el caso de los etiquetadores Averaged Perceptron Classifier y TnT se han utilizado las versiones incluidas en la librería NLTK. En el caso del Stanford MaxEnt Pos Tagger, se ha utilizado la versión Java distribuida por el grupo de PLN de la Universidad de Stanford, [Stanford MaxEnt - download]. La idea inicial era incluir tanto la versión unidireccional como la bidireccional de éste último etiquetador en la comparativa; desgraciadamente, los intentos de entrenar del modelo bidireccional con un corpus de test lo suficientemente grande como para proporcionar resultados significativamente buenos ha sido todos fallidos.

2.1. Descripción del proceso realizado

2.1.1. Entrenamiento

El entrenamiento se ha realizado utilizando los 105 primeros documentos del corpus Brown. Estos documentos se corresponden con las temáticas siguientes:

A. Reportajes de prensa (44 textos)

B. Editoriales en prensa (27 textos)

C. Reseñas de prensa (17 textos)

D. Religión (17 textos)

Se ha utilizado el corpus Brown por tratarse de un corpus de confianza y porque existe una versión completa etiquetada del mismo de libre distribución. La limitación en el tamaño del corpus utilizada (poco más del 20 %) ha venido dada por las limitaciones técnicas presentadas por el Standford MaxEnt Pos Tagger, en su versión unidireccional. Los intentos de entrenar corpus mayores generaban el error «`Exception in thread "main" java.lang.OutOfMemoryError: Java heap space`» [6]. Los otros dos etiquetadores no han presentado ninguna limitación en el tamaño del corpus: en los pre-entrenamientos de prueba, se han podido entrenar modelos con el corpus Brown entero (500 textos de unas 2000 palabras cada uno). Sin embargo, en la comparativa se han utilizado siempre los modelos entrenados con los 105 primeros textos.

Parámetros de entrenamiento

Se describen a continuación los parámetros de cada etiquetador, y se proporcionan los valores utilizados en la comparativa.

Averaged Perceptron Classifier

`nr_iter`	Número de veces que se realizan las iteraciones 1 a 3 descritas en el apartado 1.1.2.2. Se ha dejado el valor por defecto, nr_iter = 5.
`freq_thresh`	Número mínimo de veces que tiene que aparecer una palabra en el corpus para ser incluída en el diccionario palabra-categoría descrito en el apartado 1.1.2.4. Se ha mantenido el valor asignado en el código de la librería NLTK, `freq_thresh = 20`

[6] En la versión bidireccional, este error se daba incluso para corpus menores, de modo que ha sido descartado.

`ambiguity_thresh` Porcentaje de veces que una palabra que cumple `freq_thresh` $\geq$ 20 tiene que tener la misma etiqueta para que el par palabra-etiqueta sea incluída en el diccionario palabra-categoría descrito en el apartado 1.1.2.4. Se ha mantenido el valor asignado en el código de la librería NLTK, `ambiguity_thresh = 0,97`.

TnT

`N` Grado del beam search (número máximo de soluciones que se mantienen durante el etiquetado) mencionado en el apartado 1.2.2.2. Se ha mantenido el valor asignado en el código de la librería NLTK, `N = 1000`.

C Uso de la etiqueta booleana de identificación de mayúsculas. Se ha mantenido el valor asignado en el código de la librería NLTK, `C = False`[7].

unk Etiquetador alternativo para palabras desconocidas. Se ha mantenido el valor asignado en el código de la librería NLTK, `unk = False`[8].

Stanford MaxEnt PosTagger

`arch` Modelo de arquitectura. Pueden incluirse distintas opciones, cada una de las cuales especifica el uso de uno o varios extractores. Se han aprovechado las opciones incluidas en el fichero de propiedades correspondiente al modelo entrenado `english-bidirectional-distsim.tagger.props`, incluido en la distribución del etiquetador[9]:

```
arch = left3words,naacl2003unknowns,wordshapes(-1,1),
distsim(models\egw4-reut.512.clusters,-1,1),
distsimconjunction(models\egw4-reut.512.clusters,-1,1).
```

- `left3words`: Combinación de los extractores `words(-1,1)`, que crea rasgos que predicen la etiqueta actual a partir de la palabra anterior (-1), actual (0) y posterior (1), y `order(2)`, que crea rasgos bigrama y trigrama que predicen la etiqueta actual a partir de las dos etiquetas anteriores.

`naacl2003unknowns`: Combinación de los extractores 6 a 9 mencionados en la tabla 2 para palabras poco frecuentes. Para los prefijos y sufijos se han creado rasgos para cadenas de 1 a 10 caracteres[10].

[7] La misma documentación sobre la versión del etiquetador utilizada, [nltk.tag - Doc.], especifica que los resultados no mejoran significativamente por aplicar la identificación de mayúsculas.

[8] La única alternativa ofrecida en la librería NLTK es utilizar etiquetadores básicos que asignan la misma etiqueta, la considerada más probable, a todas las palabras desconocidas. He preferido no alterar la estadística utilizando este recurso, y mantener, para este etiquetador, las palabras desconocidas fuera de la comparativa.

[9] Las opciones seleccionadas han significado el uso de los siguientes exctractores, según la información proporcionada por consola durante el entrenamiento:

```
Extractors[Extractor(-1,word), Extractor(0,word), Extractor(1,word), ExtractorFrames$ExtractorContinuousTagConjunction(
Extractor(-1,tag)] rareExtractors[ExtractorUCase(), ExtractorCNumber(), ExtractorDash(),
ExtractorAllCap(), ExtractorLetterDigitDash(), CompanyNameDetector(), ExtractorAllCapitalized(),
ExtractorUpperDigitDash(), ExtractorStartSentenceCap(), ExtractorMidSentenceCapC(),
ExtractorMidSentenceCap(), ExtractorWordSuff(len1,w0), ExtractorWordSuff(len2,w0),
ExtractorWordSuff(len3,w0), ExtractorWordSuff(len4,w0), ExtractorWordSuff(len5,w0),
ExtractorWordSuff(len6,w0), ExtractorWordSuff(len7,w0), ExtractorWordSuff(len8,w0),
ExtractorWordSuff(len9,w0), ExtractorWordSuff(len10,w0), ExtractorWordPref(len1,w0),
ExtractorWordPref(len2,w0), ExtractorWordPref(len3,w0), ExtractorWordPref(len4,w0),
ExtractorWordPref(len5,w0), ExtractorWordPref(len6,w0), ExtractorWordPref(len7,w0),
ExtractorWordPref(len8,w0), ExtractorWordPref(len9,w0), ExtractorWordPref(len10,w0),
ExtractorWordShapeClassifier(-1,chris2), ExtractorWordShapeClassifier(0,chris2),
ExtractorWordShapeClassifier(1,chris2), ExtractorDistsim(-1,word), ExtractorDistsim(0,word),
ExtractorDistsim(1,word), ExtractorDistsimConjunction(-1,1)]
```

[10] Esta afirmación está basada en el comentario «'naacl2003unknowns' was our traditional set of unknown word features» asignado en el código [Stanford MaxEnt - Doc.]. Véase la nota anterior para más detalles.

	- `wordshapes(-1,1)`: En palabras poco frecuentes, comprueba si la secuencia formada por los caracteres anterior (-1), actual (0) y posterior (1) sigue ciertos patrones y crea un rasgo a partir de éstos. - `distsim(models\egw4-reut.512.clusters,-1,1)`: Extrae rasgos para la posición anterior (-1), actual (0) y posterior (1), comparando la palabra con el diccionario proporcionado como parámetro. El diccionario `egw4-reut.512.clusters` puede descargarse de [Stanford MaxEnt - FAQs]. - `distsimconjunction(models\egw4-reut.512.clusters,-1,1)`: Concatenación de los rasgos generados por `distsim()` desde la posición anterior (-1) a la posterior (1).
`closedClass TagThreshold`	Número máximo de palabras únicas a que puede asignarse una etiqueta para considerarse de la clase cerrada. Se ha asignado la opción contenida en el documento original de preferencias incluido en el paquete, `closedClassTagThreshold = 40`.
`curWordMin FeatureThresh`	Las palabras que aparecen más que este número de veces, generan rasgos para todas las etiquetas con que han aparecido. Se ha asignado la opción por defecto, `curWordMinFeatureThresh = 2.`
`debug`	Escribir o no la información para depurar. Se ha asignado la opción contenida en el documento original de preferencias incluido en el paquete, `debug = false`
`debugPrefix`	Fichero en el que guardar la información de depuración. Se ha asignado la opción por defecto, `debugPrefix = N/A`.
`tagSeparator`	Carácter utilizado para separar la palabra de la etiqueta asignada en el fichero de salida. Se ha asignado `tagSeparator = /`.
`encoding`	Codificación para leer los ficheros. Se ha asignado la opción por defecto, `encoding = UTF-8`.
`iterations`	Número de iteraciones utilizado en el escalado iterativo mejorado descrito en el apartado 1.3.2.2. Se ha asignado la opción por defecto, `iterations = 100`.
`lang`	Lengua de la que se extraen las etiquetas. Esta opción determina si las etiquetas son consideradas de una clase abierta o cerrada. Se ha asignado la opción por defecto, `lang = english`.
`learnClosed ClassTags`	Si se asigna «True», se inducen las etiquetas que se considerarán de clase cerrada a partir de `closedClassTagThreshold`. Se ha asignado la opción por defecto, `learnClosedClassTags = false`.
`minFeature Thresh`	Los rasgos que se dan menos veces que este número son descartados. Se ha asignado la opción por defecto, `minFeatureThresh = 2`.
`openClassTags`	Lista de etiquetas que deben considerarse de clase abierta. Se ha asignado la opción por defecto, vacía (`openClassTags = N/A`).
`rareWordMin FeatureThresh`	Los rasgos de palabras poco frecuentes que aparecen menos veces que este número son descartados. Se ha asignado la opción por defecto, `rareWordMinFeatureThresh = 10`.
`rareWord Thresh`	Número máximo de veces que tiene que aparecer una palabra para ser considerada poco frecuente. Se ha asignado la opción por defecto, `rareWordThresh = 5`.
`search`	Método utilizado para realizar el método de optimización durante el entrenamiento. Se ha asignado el método casi-newton, `search = qn`.
`sgml`	Para textos de entrenamiento en formato sgml, debe asignarse `True`. Como no es el caso, se ha asignado, `sgml = false`.

`sigmaSquared`	Parámetro de regularización utilizado en `search`, cuando éste se realiza mediante el método de descenso de gradiente o casi-newton. Se ha asignado el valor `sigmaSquared = 1.0`.
`regL1`	Parámetro de regularización utilizado en `search`, cuando éste se realiza mediante el método de OWLQN. Se ha asignado la opción contenida en el documento original de preferencias incluido en el paquete, `regL1 = 0.75`.
`tagInside`	Etiquetas dentro de elementos que coinciden con la expresión regular que se pasa como parámetro. Se ha asignado la opción por defecto, `tagInside = ""`.
`tokenize`	Si el documento a etiquetar requiere ser tokenizado, hay que asignar el valor `true`. De lo contrario, la tokenización se realiza a partir de los espacios en blanco . Se ha asignado la opción por defecto, `tokenize = false`, porque el tokenizado realizado era distinto al existente en el corpus de enterenamiento. [11]
`tokenizer Factory`	Nombre del tokenizador que se quiere usar. Como la opción `tokenize` se ha establecido e, el valor de este parámetro no tiene relevancia.
`tokenizer Options`	Lista de opciones para `tokenizerFactory`. Como la opción `tokenize` se ha establecido e, el valor de este parámetro no tiene relevancia.
`verbose`	Opción para incluir información de depuración extra. Se ha asignado la opción por defecto, `verbose = false`.
`verbose Results`	Opción para imprimir resultados intermedios de la depuración. Se ha asignado la opción `verboseResults = true` para poder realizar un seguimiento detallado del proceso e identificar fuentes de errores, en particular cuando el proceso fallaba.
`veryCommon WordThresh`	Las palabras cuyo número de instancias supera este número son consideradas como una clase de equivalencia ellas mismas. Si no se utilizan clases de ambiguedad, este parámetro es ignorado. Se ha asignado la opción por defecto, `veryCommonWordThresh = 250`.
`xmlInput`	Para textos de entrenamiento en formato xml. Como los textos de entrenamiento estaban en formato de texto plano, se ha asignado la opción `xmlInput = false`.
`outputFile`	Ruta del fichero de salida. Se ha asignado la opción por defecto, `outputFile = ""` (el método és `stout`).
`outputFormat`	Formato del fichero de salida. Se ha asignado la opción por defecto, `voutputFormat = slashTags`.
`outputFormat Options`	Opciones del formato del fichero de salida. Se ha asignado la opción por defecto, `outputFormatOptions = ""`.
`nthreads`	Número de hilos a utilizar cuando se procesa texto. Se ha asignado la opción por defecto, `nthreads = 1`.

2.1.2. Conjunto de etiquetas

Las etiquetas *gold* de los textos de entrenamiento son las correspondientes al *tagset* Brown [Francis 1979], más las etiquetas «Comillas iniciales» (”) y «comillas finales» (“), que indican inicio y final de cita, respectivamente. Puede consultarse el tagset Brown en el Anexo A.

[11] En concreto, este etiquetador separaba contracciones «guy's» o «could n't couldn't», dando lugar a «guy» + «s» y «could» + «n't», cuando en los corpus de entrenamiento estos figuraban como «guy's\NN+HVZ» y «MD*». Esto resultaba en un etiquetado erróneo, no atribuible al etiquetador sino a la tokenización. En lugar de utilizar la tokenización, se ha pre-procesado manualmente el texto, añadiendo espacios entre tokens no lo había.

2.1.3. Test cuantitativo

El test cuantitativo se ha realizado con 50 textos del corpus Brown de temáticas distintas a las utilizadas en el entrenamiento. La motivación para esta elección ha sido realizar la comparativa de los etiquetadores en condiciones adversas, para que las diferencias entre ellos se hagan más evidentes. Se han seleccionado textos del mismo corpus, pero de temáticas distintas. En concreto, se han utilizado textos de las categorías:

E Ocio y habilidades (36 textos)

F Cultura popular (14 textos)

Estas temáticas presentan dos dificultades: son temáticas distintas a las de los textos de entrenamiento y el estilo es más informal, de modo que se dan términos y construcciones desconocidos para los etiquetadores.

2.1.4. Test cualitativo

Para el test cualitativo se han utilizado las primeras 15 líneas (350 palabras) del primer texto de la selección anterior, el texto E01. La información sobre el texto proporcionada en el documento de contenidos es:

Título: Mr. America, 4:6

Publicación: "Henri de Courcy [:] Junior Mr. Canada" by Ben Weider

Fecha: Noviembre 1961

Información especial (de relevancia para las 15 líneas analizadas): Guión arbitrario: *prize-winning*

2.2. Resultados

2.2.1. Test cuantitativo

Los resultados del test cuantitativo se muestran en la tabla 6. En la tabla se incluye el tiempo que ha durado el entrenamiento, el tiempo que ha durado el test y el porcentaje de aciertos. Para el etiquetador TnT se añaden entre paréntesis los resultados de un segundo entrenamiento y test en el cual se han utilizando 100 iteraciones en vez de 1000. Nótese que el tiempo de test se reduce casi diez veces, sin afectar significativamente a la eficiencia. Para el etiquetador Stanford Unidirecciónal no se ha podido realizar el test con el modelo entrenado porque se obtenía el error «`Exception in thread "main" java.lang.OutOfMemoryError: Java heap space`». Solo se ha podido realizar el test con el modelo entrenado con 3000 líneas. Este test ha durado 830 segundos y el número de etiquetas correctas ha sido del 88 %. Este resultado es significativamente inferior al obtenido en el etiquetado del texto E01 (véase tabla 7), por lo cual no se ha considerado significativo y no se ha incluido en la tabla.

Cuadro 6: *Test cuantitativo de los modelos entrenados*

Etiquetador	**Tiempo de entrenamiento (segundos)**	**Tiempo de test (segundos)**	**Etiquetas correctas**
Perceptron	231	25	93 %
TnT (sin tratamiento de palabras desconocidas)	2 (2)	926 (99)	86 % (86,40 %)
Stanford Unidireccional[12]	5677	-	-

Según los autores de los etiquetadores, la precisión de todos ellos puede alcanzar prácticamente el 97 % ([Honnibal 2013A], [Honnibal 2013A, Brants 2000, Stanford MaxEnt - Doc.]).

2.2.2. Test cualitativo

El etiquetado realizado por cada uno de los etiquetadores para el texto de test E01 puede consultarse en el Anexo B. Para facilitar el análisis, se han incluido también las etiquetas correspondientes al tagset Universal propuesto por [Petrov 2012]. Para ello se ha realizado un mapeo de las etiquetas Brown a las etiquetas Universal siguiendo el esquema incluido en [Petrov 2014]. Del número total de palabras a etiquetar, 350, de las cuales 40 han sido desconocidas (no existen en el corpus de entrenamiento). La tabla 7 muestra los resultados cuantitativos para cada etiquetador.

Cuadro 7: *Resultados del etiquetado de las primeras 15 líneas del texto E01, perteneciente al corpus Brown*

	Perceptron		**MaxEnt Stanford**		**TnT**	
	Brown	**Universal**	**Brown**	**Universal**	**Brown**	**Universal**
Nº total de aciertos	317	323	323	328	301	303
Porcentaje de aciertos	90,57	92.29	92.29	93,71	0.86	86,58
Nº de aciertos en palabras desconocidas	23	26	27	29	0	0
Porcentaje de aciertos en palabras desconocidas	57,50	65,00	67,50	72,50	0	0

Como puede verse en el cuadro 7, una parte importante de los errores se dan en el etiquetado de las palabras desconocidas. En concreto, en el caso del etiquetador Perceptron las palabras desconocidas contribuyen en un 4,86 % al porcentaje total de errores que, es del 9,43 %. Es decir, a más de la mitad. Para el etiquetador MaxEnt esta contribución es del 3,14 %, lo que también representa casi la mitad de los errores. Para el TnT, que no etiqueta palabras desconocidas, la contribución al error de las palabras desconocidas es del 11,43 %.

Como era de esperar, para las palabras conocidas los errores se dan en aquellas que presentan ambigüedad. Para el caso de las palabras desconocidas la ambigüedad también es una fuente frecuente de error. Los errores cometidos pueden clasificarse en los siguientes tipos[13], resumidos en el cuadro 8:

- Palabras con terminación -*ing*, que pueden ser verbos en participio presente o gerundio (VBG), nombres en singular (NN) o adjetivos (JJ): *beginning*, *training*, *discouraging*, *admonishing*, *bodybuilding* y *prize-winning*. Aquí, el mejor etiquetador es Perceptron, y el peor, TnT.
- Formas verbales en pasado (VBD) o en participio (VBN): *had*, *taunted*. Todos los etiquetadores aciertan en asignar la categoría universal «verbo» a estas palabras, pero la etiqueta Brown, que también especifica el modo, no siempre es la acertada. De nuevo, Perceptron es el que mejor etiqueta esta tipología, sin producir ningún error. TnT falla en una ocasión («*never has been taunted*») y Standford, en 2 («*never has been taunted*» y «*who has never had to train*»). En los tres casos, se asigna la forma verbal pasado en lugar del participio.
- Partícula *to*, que en el tagset Brown puede ser una marca de infinitivo (TO) o una preposición (IN). Aquí el mejor etiquetador resulta ser TnT, que acierta siempre, seguido de Perceptron.
- Partícula *on*, que en el tagset Brown puede ser un adverbio o partícula (RP) o una preposición (IN). Esta partícula se da una vez en el texto: solo TnT acierta en la etiqueta asignada, RP.

[12]

[13] Las palabras mencionadas son las que han sido etiquetadas incorrectamente por al menos un etiquetador. Las palabras categorizadas como «unknown» por TnT no se consideran error en el análisis, pero se incluyen en el cuadro 8.

- Distincion «'s» de genitivo y elipsis «has»: *guy's*. Tanto Stanford como Perceptron asignan la etiqueta «nombre singular posesivo» (NN$) al término, en lugar de nombre común + verbo has (NN+HVZ). TnT no reconoce el término.
- Distinción entre adjetivos y adverbios: *little, better*, *best*, *right*, *most*. La confusión entre estas dos categorías se da en todos los etiquetadores, siendo Stanford el que obtiene peores resultados.
- Distinción entre nombres y adjetivos: *sonny-boy*, *barbell*, *East, Junior*, *sterno-cleido*, *Weider*, *principles, physique*, *anticus*. Aquí los fallos se dan, sobre todo, en palabras desconocidas. El etiquetador que falla más es Perceptron.
- Distinción entre verbos y nombres: *gonna*, *gotta*, *exercices*. De nuevo, los errores se dan más en palabras desconocidas. Perceptron vuelve a ser el etiquetador que más errores de este tipo tiene.
- Distinción entre verbos y adposiciones: *lookit*, *urge*. Esta confusión se da únicamente en Perceptron.
- Distinción entre verbos y adjetivos: *work*. Esta confusión se da únicamente en Perceptron.
- Confusión interjección por nombre: «*Hey lookit Mr. America*». Este error lo hacen todos los etiquetadores. Teniendo en cuenta que tanto «Hey» como «lookit» son palabras desconocidas.
- Palabras extranjeras desconocidas: *professeur*, *tibialis*, *anticus*. La única palabra reconocida correctamente es professeur, por parte del etiquetador Stanford. Todos los etiquetadores aciertan con la palabra extranjera conocida *le* (lo que es normal, pues no presenta ambigüedad).
- Títulos (etiqueta -TL): *Montreal*, *Health*, *Mt.*, *Most*, *Muscular*. Aquí el mejor etiquetador es TnT, que reconoce correctamente todas las etiquetas (excepto las de palabras desconocidas, que en la versión utilizada no se tienen en cuenta), seguido de Stanford.
- Otros: *whaddya*: Este coloquialismo no es etiquetado correctamente por ninguno de los etiquetadores.

Cuadro 8: Errores realizados por los distintos etiquetadores, según la tipología. El primer sumando se refiere a palabras conocidas y el segundo, a desconocidas.

	Nº de errores					
	Perceptron		**MaxEnt Stanford**		**TnT**	
	Brown	**Universal**	**Brown**	**Universal**	**Brown**	**Universal**
Gerundio /Nombre singular /Adjetivo (-ing)	2+2	2+2	1+1	1+1	3+3	3+3
Verbo pasado / participio (-ed, had, been)	0+0	0+0	1+0	0+0	1+1	0+1
to	1+0	1+0	2+0	2+0	0+0	0+0
on	1+0	1+0	1+0	1+0	0+0	0+0
's	0+1	0+1	0+1	0+1	0+1	0+1
Adjetivos / Adverbios	5+0	4+0	5+0	5+0	3+0	3+0
Nombres / adjetivos	2+6	2+5	1+3	1+3	1+6	1+6
Nombres / verbos	2+2	2+2	0+2	0+2	0+2	0+2
Verbos / adposiciones	1+1	1+1	0+0	0+0	0+0	0+0
Verbos / adjetivos	1+0	1+0	0+0	0+0	0+0	0+0
Interjección / nombre	0+1	0+1	0+1	0+1	0+1	0+1
Extranjerismos deconocidos	0+3	0+0	0+2	0+0	0+3	0+0
Títulos (-TL)	4+2	1+0	1+1	1+0	0+2	0+2

3. Conclusiones

Los tests cuantitativo y cualitativo muestran que, entrenados con un corpus grande (210.000 palabras), los tres etiquetadores funcionan razonablemente bien. (Recuérdese que, en el caso de TnT, no se está aplicando el algoritmo para tratar palabras desconocidas; cuando se incluye, la precisión del etiquetado puede alcancar entre el 96 % y el 97 %, según [Brants 2000].) Esto justifica la afirmación de Andrew Ng de que «no es el que tiene el mejor algoritmo el que gana. Es el que tiene más datos». Con una cantidad suficiente de datos, la eficiencia de los etiquetadores converge. El etiquetador que, aparentemente, consigue mejores resultados (Stanford MaxEnt) lo hace al alto precio de ralentizar enormemente los procesos: el entrenamiento dura más de 2500 veces más que el del etiquetador Perceptron, para mejorar la precisión apenas un 2 % en el test cualitativo. El test cuantitativo ni siquiera puede hacerse, por problemas de memoria. Este fenómeno también se aprecia en el etiquetador TnT cuando se le compara consigo mismo, cambiando el número de estados incluidos en el algoritmo de Viterbi: cambiar de 100 a 1000 el número de estados multiplica el tiempo de etiquetado en la misma proporción, 10 veces, y la mejora en la precisión es de tan solo el 0.40 %.

A nivel cualitativo, destacan, por extraños, los errores cometidos por Perceptron. Por ejemplo:

> «*Hey lookit/IN-TL Mr. America*»
>
> «*he knows just what exercises work/JJ best for them*»
>
> «*what Weider principles/VBZ to combine them with*»

También sorprende que Stanford MaxEnt sea el etiquetador que peor distingue las formas verbales en pasado y los participios (VBN/VBD), así como los distintos tipos de partículas (RB/RP/IN), ya que el etiquetador incluye rasgos especialmente diseñados para hacer estas distinciones.

En lo que respecta al tiempo de ejecución, parece claro que la aproximación por rasgos tiene un coste altísimo, que Perceptron consigue reducir creando un diccionario para etiquetar las palabras que presentan siempre o casi siempre (la barrera se ha establecido en el 97 %). Para confirmar esta intuición deberíamos hacer la comparativa con una versión de TnT que reconozca las palabras desconocidas, para incluir en el análisis el tiempo de ejecución de esta parte del algoritmo.

Anexos

Anexo A: Conjuntos de etiquetas gold

El conjunto de etiquetas utilizado en el corpus de entrenamiento es el *tagset* Brown [Francis 1979], más las etiquetas «Comillas iniciales» (”) y «comillas finales» (“), que indican inicio y final de cita, respectivamente.

Tagset Brown

Etiqueta	Definición
.	sentence (. ; ? *)
(	left paren
)	right paren
*	not, n’t
–	dash
,	comma
:	colon
ABL	pre-qualifier (quite, rather)
ABN	pre-quantifier (half, all)
ABX	pre-quantifier (both)
AP	post-determiner (many, several, next)
AT	article (a, the, no)
BE	be
BED	were
BEDZ	was
BEG	being
BEM	am
BEN	been
BER	are, art
BEZ	is
CC	coordinating conjunction (and, or)
CD	cardinal numeral (one, two, 2, etc.)
CS	subordinating conjunction (if, although)
DO	do
DOD	did
DOZ	does
DT	singular determiner/quantifier (this, that)
DTI	singular or plural determiner/quantifier (some, any)
DTS	plural determiner (these, those)
DTX	determiner/double conjunction (either)
EX	existential there
FW	foreign word (hyphenated before regular tag)
HL	word occurring in the headline (hyphenated after regular tag)
HV	have
HVD	had (past tense)
HVG	having
HVN	had (past participle)
HVZ	has
IN	preposition

Etiqueta	**Definición**
JJ	adjective
JJR	comparative adjective
JJS	semantically superlative adjective (chief, top)
JJT	morphologically superlative adjective (biggest)
MD	modal auxiliary (can, should, will)
NC	cited word (hyphenated after regular tag)
NN	singular or mass noun
NN$	possessive singular noun
NNS	plural noun
NNS$	possessive plural noun
NP	proper noun or part of name phrase
NP$	possessive proper noun
NPS	plural proper noun
NPS$	possessive plural proper noun
NR	adverbial noun (home, today, west)
NRS	plural adverbial noun
OD	ordinal numeral (first, 2nd)
PN	nominal pronoun (everybody, nothing)
PN$	possessive nominal pronoun
PP$	possessive personal pronoun (my, our)
PP$$	second (nominal) possessive pronoun (mine, ours)
PPL	singular reflexive/intensive personal pronoun (myself)
PPLS	plural reflexive/intensive personal pronoun (ourselves)
PPO	objective personal pronoun (me, him, it, them)
PPS	3rd. singular nominative pronoun (he, she, it, one)
PPSS	other nominative personal pronoun (I, we, they, you)
QL	qualifier (very, fairly)
QLP	post-qualifier (enough, indeed)
RB	adverb
RBR	comparative adverb
RBT	superlative adverb
RN	nominal adverb (here, then, indoors)
RP	adverb/particle (about, off, up)
TL	word occurring in title (hyphenated after regular tag)
TO	infinitive marker to
UH	interjection, exclamation
VB	verb, base form
VBD	verb, past tense
VBG	verb, present participle/gerund
VBN	verb, past participle
VBP	verb, non 3rd person, singular, present
VBZ	verb, 3rd. singular present
WDT	wh- determiner (what, which)
WP$	possessive wh- pronoun (whose)
WPO	objective wh- pronoun (whom, which, that)
WPS	nominative wh- pronoun (who, which, that)
WQL	wh- qualifier (how)
WRB	wh- adverb (how, where, when)

Etiquetas adicionales

Etiqueta	Definición
”	Inicio cita
“	Final cita

Tagset Universal

Etiqueta	Definición
ADJ	adjective
ADP	adposition
ADV	adverb
AUX	auxiliary
CCONJ	coordinating conjunction
DET	determiner
INTJ	interjection
NOUN	noun
NUM	numeral
PART	particle
PRON	pronoun
PROPN	proper noun
PUNCT	punctuation
SCONJ	subordinating conjuction
SYM	symbol
VERB	verb
X	other

Correspondencia entre etiquetas Brown y Universal

Brown	Universal	Brown	Universal	Brown	Universal
’	.	FW-NNS-TL	X	PN+HVZ	PRT
”	.	FW-NP	X	PN+MD	PRT
(	.	FW-NP-TL	X	PN-HL	NOUN
(-HL	.	FW-NPS	X	PN-NC	NOUN
)	.	FW-NPS-TL	X	PN-TL	NOUN
)-HL	.	FW-NR	X	PP$	DET
*	ADV	FW-NR-TL	X	PP$$	PRON
*-HL	ADV	FW-OD-NC	X	PP$-HL	DET
*-NC	ADV	FW-OD-TL	X	PP$-NC	DET
*-TL	ADV	FW-PN	X	PP$-TL	DET
,	.	FW-PP$	X	PPL	PRON
,-HL	.	FW-PP$-NC	X	PPL-HL	PRON
,-NC	.	FW-PP$-TL	X	PPL-NC	PRON
,-TL	.	FW-PPL	X	PPL-TL	PRON
–	.	FW-PPL+VBZ	X	PPLS	PRON
—HL	.	FW-PPO	X	PPO	PRON
.	.	FW-PPO+IN	X	PPO-HL	PRON
.-HL	.	FW-PPS	X	PPO-NC	PRON
.-NC	.	FW-PPSS	X	PPO-TL	PRON
.-TL	.	FW-PPSS+HV	X	PPS	PRON
:	.	FW-QL	X	PPS+BEZ	PRT
:-HL	.	FW-RB	X	PPS+BEZ-HL	PRT
:-TL	.	FW-RB+CC	X	PPS+BEZ-NC	PRT

Brown	**Universal**	**Brown**	**Universal**	**Brown**	**Universal**
ABL	PRT	FW-RB-TL	X	PPS+HVD	PRT
ABN	PRT	FW-TO+VB	X	PPS+HVZ	PRT
ABN-HL	PRT	FW-UH	X	PPS+MD	PRT
ABN-NC	PRT	FW-UH-NC	X	PPS-HL	PRON
ABN-TL	PRT	FW-UH-TL	X	PPS-NC	PRON
ABX	DET	FW-VB	X	PPS-TL	PRON
AP	ADJ	FW-VB-NC	X	PPSS	PRON
AP$	PRT	FW-VB-TL	X	PPSS+BEM	PRT
AP+AP-NC	ADJ	FW-VBD	X	PPSS+BER	PRT
AP-HL	ADJ	FW-VBD-TL	X	PPSS+BER-N	PRT
AP-NC	ADJ	FW-VBG	X	PPSS+BER-NC	PRT
AP-TL	ADJ	FW-VBG-TL	X	PPSS+BER-TL	PRT
AT	DET	FW-VBN	X	PPSS+BEZ	PRT
AT-HL	DET	FW-VBZ	X	PPSS+BEZ*	PRT
AT-NC	DET	FW-WDT	X	PPSS+HV	PRT
AT-TL	DET	FW-WPO	X	PPSS+HV-TL	PRT
AT-TL-HL	DET	FW-WPS	X	PPSS+HVD	PRT
BE	VERB	HV	VERB	PPSS+MD	PRT
BE-HL	VERB	HV*	VERB	PPSS+MD-NC	PRT
BE-TL	VERB	HV+TO	VERB	PPSS+VB	PRT
BED	VERB	HV-HL	VERB	PPSS-HL	PRON
BED*	VERB	HV-NC	VERB	PPSS-NC	PRON
BED-NC	VERB	HV-TL	VERB	PPSS-TL	PRON
BEDZ	VERB	HVD	VERB	QL	ADV
BEDZ*	VERB	HVD*	VERB	QL-HL	ADV
BEDZ-HL	VERB	HVD-HL	VERB	QL-NC	ADV
BEDZ-NC	VERB	HVG	VERB	QL-TL	ADV
BEG	VERB	HVG-HL	VERB	QLP	ADV
BEM	VERB	HVN	VERB	RB	ADV
BEM*	VERB	HVZ	VERB	RB$	PRT
BEM-NC	VERB	HVZ*	VERB	RB+BEZ	PRT
BEN	VERB	HVZ-NC	VERB	RB+BEZ-HL	PRT
BEN-TL	VERB	HVZ-TL	VERB	RB+BEZ-NC	PRT
BER	VERB	IN	ADP	RB+CS	ADV
BER*	VERB	IN+IN	ADP	RB-HL	ADV
BER*-NC	VERB	IN+PPO	ADP	RB-NC	ADV
BER-HL	VERB	IN-HL	ADP	RB-TL	ADV
BER-NC	VERB	IN-NC	ADP	RBR	ADV
BER-TL	VERB	IN-TL	ADP	RBR+CS	ADV
BEZ	VERB	IN-TL-HL	ADP	RBR-NC	ADV
BEZ*	VERB	JJ	ADJ	RBT	ADV
BEZ-HL	VERB	JJ$-TL	PRT	RN	ADV
BEZ-NC	VERB	JJ+JJ-NC	ADJ	RP	PRT
BEZ-TL	VERB	JJ-HL	ADJ	RP+IN	PRT
CC	CONJ	JJ-NC	ADJ	RP-HL	PRT
CC-HL	CONJ	JJ-TL	ADJ	RP-NC	PRT
CC-NC	CONJ	JJ-TL-HL	ADJ	RP-TL	PRT
CC-TL	CONJ	JJ-TL-NC	ADJ	TO	PRT
CC-TL-HL	CONJ	JJR	ADJ	TO+VB	PRT
CD	NUM	JJR+CS	ADJ	TO-HL	PRT
CD$	NOUN	JJR-HL	ADJ	TO-NC	PRT
CD-HL	NUM	JJR-NC	ADJ	TO-TL	PRT
CD-NC	NUM	JJR-TL	ADJ	UH	PRT
CD-TL	NUM	JJS	ADJ	UH-HL	PRT
CD-TL-HL	NUM	JJS-HL	ADJ	UH-NC	PRT

Brown	**Universal**	**Brown**	**Universal**	**Brown**	**Universal**
CS	ADP	JJS-TL	ADJ	UH-TL	PRT
CS-HL	ADP	JJT	ADJ	VB	VERB
CS-NC	ADP	JJT-HL	ADJ	VB+AT	VERB
CS-TL	ADP	JJT-NC	ADJ	VB+IN	VERB
DO	VERB	JJT-TL	ADJ	VB+JJ-NC	VERB
DO*	VERB	MD	VERB	VB+PPO	VERB
DO*-HL	VERB	MD*	VERB	VB+RP	VERB
DO+PPSS	X	MD*-HL	VERB	VB+TO	VERB
DO-HL	VERB	MD+HV	VERB	VB+VB-NC	VERB
DO-NC	VERB	MD+PPSS	VERB	VB-HL	VERB
DO-TL	VERB	MD+TO	VERB	VB-NC	VERB
DOD	VERB	MD-HL	VERB	VB-TL	VERB
DOD*	VERB	MD-NC	VERB	VBD	VERB
DOD*-TL	VERB	MD-TL	VERB	VBD-HL	VERB
DOD-NC	VERB	NIL	X	VBD-NC	VERB
DOZ	VERB	NN	NOUN	VBD-TL	VERB
DOZ*	VERB	NN$	NOUN	VBG	VERB
DOZ*-TL	VERB	NN$-HL	NOUN	VBG+TO	VERB
DOZ-HL	VERB	NN$-TL	NOUN	VBG-HL	VERB
DOZ-TL	VERB	NN+BEZ	PRT	VBG-NC	VERB
DT	DET	NN+BEZ-TL	PRT	VBG-TL	VERB
DT$	DET	NN+HVD-TL	PRT	VBN	VERB
DT+BEZ	PRT	NN+HVZ	PRT	VBN+TO	VERB
DT+BEZ-NC	PRT	NN+HVZ-TL	PRT	VBN-HL	VERB
DT+MD	PRT	NN+IN	NOUN	VBN-NC	VERB
DT-HL	DET	NN+MD	PRT	VBN-TL	VERB
DT-NC	DET	NN+NN-NC	NOUN	VBN-TL-HL	VERB
DT-TL	DET	NN-HL	NOUN	VBN-TL-NC	VERB
DTI	DET	NN-NC	NOUN	VBZ	VERB
DTI-HL	DET	NN-TL	NOUN	VBZ-HL	VERB
DTI-TL	DET	NN-TL-HL	NOUN	VBZ-NC	VERB
DTS	DET	NN-TL-NC	NOUN	VBZ-TL	VERB
DTS+BEZ	PRT	NNS	NOUN	WDT	DET
DTS-HL	DET	NNS$	NOUN	WDT+BER	PRT
DTX	DET	NNS$-HL	NOUN	WDT+BER+PP	X
EX	PRT	NNS$-NC	NOUN	WDT+BEZ	PRT
EX+BEZ	PRT	NNS$-TL	NOUN	WDT+BEZ-HL	PRT
EX+HVD	PRT	NNS$-TL-HL	NOUN	WDT+BEZ-NC	PRT
EX+HVZ	PRT	NNS+MD	PRT	WDT+BEZ-TL	PRT
EX+MD	PRT	NNS-HL	NOUN	WDT+DO+PPS	X
EX-HL	PRT	NNS-NC	NOUN	WDT+DOD	PRT
EX-NC	PRT	NNS-TL	NOUN	WDT+HVZ	PRT
FW-*	X	NNS-TL-HL	NOUN	WDT-HL	DET
FW-*-TL	X	NNS-TL-NC	NOUN	WDT-NC	DET
FW-AT	X	NP	NOUN	WP$	DET
FW-AT+NN-TL	X	NP$	NOUN	WPO	PRON
FW-AT+NP-TL	X	NP$-HL	NOUN	WPO-NC	PRON
FW-AT-HL	X	NP$-TL	NOUN	WPO-TL	PRON
FW-AT-TL	X	NP+BEZ	PRT	WPS	PRON
FW-BE	X	NP+BEZ-NC	PRT	WPS+BEZ	PRT
FW-BER	X	NP+HVZ	PRT	WPS+BEZ-NC	PRT
FW-BEZ	X	NP+HVZ-NC	PRT	WPS+BEZ-TL	PRT
FW-CC	X	NP+MD	PRT	WPS+HVD	PRT
FW-CC-TL	X	NP-HL	NOUN	WPS+HVZ	PRT
FW-CD	X	NP-NC	NOUN	WPS+MD	PRT

Brown	**Universal**	**Brown**	**Universal**	**Brown**	**Universal**
FW-CD-TL	X	NP-TL	NOUN	WPS-HL	PRON
FW-CS	X	NP-TL-HL	NOUN	WPS-NC	PRON
FW-DT	X	NPS	NOUN	WPS-TL	PRON
FW-DT+BEZ	X	NPS$	NOUN	WQL	ADV
FW-DTS	X	NPS$-HL	NOUN	WQL-TL	ADV
FW-HV	X	NPS$-TL	NOUN	WRB	ADV
FW-IN	X	NPS-HL	NOUN	WRB+BER	PRT
FW-IN+AT	X	NPS-NC	NOUN	WRB+BEZ	PRT
FW-IN+AT-T	X	NPS-TL	NOUN	WRB+BEZ-TL	PRT
FW-IN+AT-TL	X	NR	NOUN	WRB+DO	PRT
FW-IN+NN	X	NR$	NOUN	WRB+DOD	PRT
FW-IN+NN-TL	X	NR$-TL	NOUN	WRB+DOD*	PRT
FW-IN+NP-TL	X	NR+MD	PRT	WRB+DOZ	PRT
FW-IN-TL	X	NR-HL	NOUN	WRB+IN	PRT
FW-JJ	X	NR-TL	NOUN	WRB+MD	PRT
FW-JJ-NC	X	NR-TL-HL	NOUN	WRB-HL	ADV
FW-JJ-TL	X	NR-NC	NOUN	WRB-NC	ADV
FW-JJR	X	NRS	NOUN	WRB-TL	ADV
FW-JJT	X	NRS-TL	NOUN	“	.
FW-NN	X	OD	ADJ		
FW-NN$	X	OD-HL	ADJ		
FW-NN$-TL	X	OD-NC	ADJ		
FW-NN-NC	X	OD-TL	ADJ		
FW-NN-TL	X	PN	NOUN		
FW-NN-TL-NC	X	PN$	NOUN		
FW-NNS	X	PN+BEZ	PRT		
FW-NNS-NC	X	PN+HVD	PRT		

Anexo B: Texto del test cualitativo (corpus Brown, CE01)

Versión sin etiquetar

Too often a beginning bodybuilder has to do his training secretly either because his parents don't want sonny-boy to " lift all those old barbell things " because " you'll stunt your growth " or because childish taunts from his schoolmates , like " Hey lookit Mr. America ; ; whaddya gonna do with all those muscles (of which he has none at the time) " ? ? After all , a guy's gotta have a little ego ! ! Therefore it's a genuine pleasure to tell you about an entirely happy bodybuilder who has never had to train in secret has never heard one unkind word from his parents and never has been taunted by his schoolmates ! ! This happy , always smiling lad with the sunny disposition is our new Junior Mr. Canada -- Henri De Courcy . Far from discouraging Henri , his parents urge him on to greater and greater accomplishments . Instead of admonishing him to let the weights alone they personally took him to that master Montreal bodybuilding authority , Professor Roland Claude . And they couldn't have entrusted Henri to better hands because " le professeur " knows his muscles from the sterno-cleido mastoideus of the neck right down to the tibialis anticus of the leg and better still , he knows just what exercises work best for them and what Weider principles to combine them with for fast , fast muscle growth . That's because the good professor teaches only Weider methods at his famous Montreal Health Studio which is located at 1821 Mt. Royal East in Montreal . Undoubtedly you have read the case histories of some of his prize-winning pupils (every pupil has a physique title of some kind or other) . There's Gaetan D'Amours who is our newest Mr. Canada ; ; Jean-Paul Senesac , whose story appeared here two issues ago ; ; Jack Boissoneault , who was with us last month ; ; Charles Harve , who recently won the " Most Muscular Man " subdivision award in the Mr. Canada event ; ; and a host of others .

Versión con etiquetas «gold»

Too/ql often/rb a/at beginning/vbg bodybuilder/nn has/hvz to/to do/do his/pp$ training/nn secretly/rb either/cc because/cs his/pp$ parents/nns don't/do* want/vb sonny-boy/nn to/to "/" lift/vb all/abn those/dts old/jj barbell/nn things/nns "/" because/cs "/" you'll/ppss+md stunt/vb your/pp$ growth/nn "/" or/cc because/cs childish/jj taunts/nns from/in his/pp$ schoolmates/nns ,/, like/cs "/" Hey/uh lookit/vb+in Mr./np America/np ;/. ;/.

whaddya/wdt+ber+pp gonna/vbg+to do/do with/in all/abn those/dts muscles/nns (/(of/in which/wdt he/pps has/hvz none/pn at/in the/at time/nn)/) "/" ?/. ?/.

After/in all/abn ,/, a/at guy's/nn+hvz gotta/vbn+to have/hv a/at little/ap ego/nn !/. !/.

Therefore/rb it's/pps+bez a/at genuine/jj pleasure/nn to/to tell/vb you/ppo about/in an/at entirely/ql happy/jj bodybuilder/nn who/wps has/hvz never/rb had/hvn to/to train/vb in/in secret/nn has/hvz never/rb heard/vbn one/cd unkind/jj word/nn from/in his/pp$ parents/nns and/cc never/rb has/hvz been/ben taunted/vbn by/in his/pp$ schoolmates/nns !/. !/.

This/dt happy/jj ,/, always/rb smiling/vbg lad/nn with/in the/at sunny/jj disposition/nn is/bez our/pp$ new/jj Junior/np Mr./np Canada/np --/-- Henri/np De/np Courcy/np ./.

Far/rb from/in discouraging/vbg Henri/np ,/, his/pp$ parents/nns urge/vb him/ppo on/rp to/in greater/jjr and/cc greater/jjr accomplishments/nns ./.

Instead/rb of/in admonishing/vbg him/ppo to/to let/vb the/at weights/nns alone/rb they/ppss personally/rb took/vbd him/ppo to/in that/dt master/nn Montreal/np bodybuilding/nn authority/nn ,/, Professor/nn-tl Roland/np Claude/np ./.

And/cc they/ppss couldn't/md* have/hv entrusted/vbn Henri/np to/in better/rbr hands/nns because/cs "/" le/fw-at professeur/fw-nn "/" knows/vbz his/pp$ muscles/nns from/in the/at sterno-cleido/nn mastoideus/nn of/in the/at neck/nn right/ql down/rp to/in the/at tibialis/fw-nn anticus/fw-jj of/in the/at leg/nn and/cc better/ql still/rb ,/, he/pps knows/vbz just/rb what/wdt exer-

cises/nns work/vb best/rbt for/in them/ppo and/cc what/wdt Weider/np principles/nns to/to combine/vb them/ppo with/in for/in fast/jj ,/, fast/jj muscle/nn growth/nn ./.

That's/dt+bez because/cs the/at good/jj professor/nn teaches/vbz only/rb Weider/np methods/nns at/in his/pp$ famous/jj Montreal/np-tl Health/nn-tl Studio/nn-tl which/wdt is/bez located/vbn at/in 1821/cd Mt./nn-tl Royal/jj-tl East/jj-tl in/in Montreal/np ./.

Undoubtedly/rb you/ppss have/hv read/vbn the/at case/nn histories/nns of/in some/dti of/in his/pp$ prize-winning/jj pupils/nns (/(every/at pupil/nn has/hvz a/at physique/nn title/nn of/in some/dti kind/nn or/cc other/ap)/) ./.

There's/ex+bez Gaetan/np D'Amours/np who/wps is/bez our/pp$ newest/jjt Mr./np Canada/np ;/. ;/.

Jean-Paul/np Senesac/np ,/, whose/wp$ story/nn appeared/vbd here/rb two/cd issues/nns ago/rb ;/. ;/.

Jack/np Boissoneault/np ,/, who/wps was/bedz with/in us/ppo last/ap month/nn ;/. ;/.

Charles/np Harve/np ,/, who/wps recently/rb won/vbd the/at "/" Most/ql-tl Muscular/jj-tl Man/nn-tl "/" subdivision/nn award/nn in/in the/at Mr./np Canada/np event/nn ;/. ;/.

and/cc a/at host/nn of/in others/nns ./.

Versiones etiquetadas por los tres etiquetadores entrenados

La tabla muestra las etiquetas gold y las asignadas por cada uno de los etiquetadores. Se han añadido las etiquetas correspondientes del conjunto de etiquetas universal. Las palabras del texto marcadas con asterisco (*) son las palabras desconocidas. Se marcan en rojo las etiquetas erróneas.

Texto	**Etiqueta *gold***		**Etiquetado Perceptron**		**Etiquetado MaxEnt Stanford**		**Etiquetado TnT**	
	Brown	**Universal**	**Brown**	**Universal**	**Brown**	**Universal**	**Brown**	**Universal**
Too	QL	**ADV**	QL	ADV	ql	ADV	QL	ADV
often	RB	**ADV**	RB	ADV	rb	ADV	RB	ADV
a	AT	**DET**	AT	DET	at	DET	AT	DET
beginning	VBG	**VERB**	VBG	VERB	nn	NOUN	NN	NOUN
bodybuilder*	NN	**NOUN**	NN	NOUN	nn	NOUN	Unk	Unknown
has	HVZ	**VERB**	HVZ	VERB	hvz	VERB	HVZ	VERB
to	TO	**PRT**	TO	PRT	to	PRT	TO	PRT
do	DO	**VERB**	DO	VERB	do	VERB	DO	VERB
his	PP$	**DET**	PP$	DET	pp$	DET	PP$	DET
training	NN	**NOUN**	VBG	VERB	nn	NOUN	VBG	VERB
secretly	RB	**ADV**	RB	ADV	rb	ADV	RB	ADV
either	CC	**CONJ**	CC	CONJ	cc	CONJ	CC	CONJ
because	CS	**ADP**	CS	ADP	cs	ADP	CS	ADP
his	PP$	**DET**	PP$	DET	pp$	DET	PP$	DET
parents	NNS	**NOUN**	NNS	NOUN	nns	NOUN	NNS	NOUN
don't	DO*	**VERB**	DO*	VERB	do*	VERB	DO*	VERB
want	VB	**VERB**	VB	VERB	vb	VERB	VB	VERB
sonny-boy*	NN	**NOUN**	NN	NOUN	jj	ADJ	Unk	Unknown
to	TO	**PRT**	TO	PRT	in	ADP	TO	PRT
"	"	**.**	"	.	"	.	"	.
lift	VB	**VERB**	VB	VERB	vb	VERB	VB	VERB
all	ABN	**PRT**	ABN	PRT	abn	PRT	ABN	PRT
those	DTS	**DET**	DTS	DET	dts	DET	DTS	DET
old	JJ	**ADJ**	JJ	ADJ	jj	ADJ	JJ	ADJ

Texto	**Etiqueta *gold***		**Etiquetado Perceptron**		**Etiquetado MaxEnt Stanford**		**Etiquetado TnT**	
	Brown	**Universal**	**Brown**	**Universal**	**Brown**	**Universal**	**Brown**	**Universal**
barbell*	NN	**NOUN**	JJ	ADJ	nn	NOUN	Unk	Unknown
things	NNS	**NOUN**	NNS	NOUN	nns	NOUN	NNS	NOUN
”	”	**.**	”	.	”	.	”	.
because	CS	**ADP**	CS	ADP	cs	ADP	CS	ADP
“	“	**.**	“	.	“	.	“	.
you’ll	PPSS+MD	**PRT**	PPSS+MD	PRT	ppss+md	PRT	PPSS+MD	PRT
stunt*	VB	**VERB**	VB	VERB	vb	VERB	Unk	Unknown
your	PP$	**DET**	PP$	DET	pp$	DET	PP$	DET
growth	NN	**NOUN**	NN	NOUN	nn	NOUN	NN	NOUN
”	”	**.**	”	.	”	.	”	.
or	CC	**CONJ**	CC	CONJ	cc	CONJ	CC	CONJ
because	CS	**ADP**	CS	ADP	cs	DET	CS	ADP
childish	JJ	**ADJ**	JJ	ADJ	jj	ADJ	JJ	ADJ
taunts	NNS	**NOUN**	NNS	NOUN	nns	NOUN	NNS	NOUN
from	IN	**ADP**	IN	ADP	in	ADP	IN	ADP
his	PP$	**DET**	PP$	DET	pp$	DET	PP$	DET
schoolmate*s	NNS	**NOUN**	NNS	NOUN	nns	NOUN	Unk	Unknown
,	,	**.**	,	.	,	.	,	.
like	CS	**ADP**	CS	ADP	cs	ADP	CS	ADP
“	“	**.**	“	.	“	.	“	.
Hey*	UH	**PRT**	NP	NOUN	np	NOUN	Unk	Unknown
lookit*	VB+IN	**VERB**	IN-TL	ADP	vbd	VERB	Unk	Unknown
Mr.	NP	**NOUN**	NP	NOUN	np	NOUN	NP	NOUN
America	NP	**NOUN**	NP	NOUN	np	NOUN	NP	NOUN
;	.	**.**	.	.	.	.	.	.
whaddya*	WDT+BER+PP	**X**	NN	NOUN	jj-hl	ADJ	Unk	Unknown
gonna*	VBG+TO	**VERB**	NNS-HL	NOUN	nn-hl	NOUN	Unk	Unknown
do	DO	**VERB**	DO	VERB	do	VERB	DO	VERB
with	IN	**ADP**	IN	ADP	in	ADP	IN	ADP
all	ABN	**PRT**	ABN	PRT	abn	PRT	ABN	PRT
those	DTS	**DET**	DTS	DET	dts	DET	DTS	DET
muscles	NNS	**NOUN**	NNS	NOUN	nns	NOUN	NNS	NOUN
(	(	**.**	(	.	(	.	(	.
of	IN	**ADP**	IN	ADP	in	ADP	IN	ADP
which	WDT	**DET**	WDT	DET	wdt	DET	WDT	DET
he	PPS	**PRON**	PPS	PRON	pps	PRON	PPS	PRON
has	HVZ	**VERB**	HVZ	VERB	hvz	VERB	HVZ	VERB
none	PN	**NOUN**	PN	NOUN	pn	NOUN	PN	NOUN
at	IN	**ADP**	IN	ADP	in	ADP	IN	ADP
the	AT	**DET**	AT	DET	at	DET	AT	DET
time	NN	**NOUN**	NN	NOUN	nn	NOUN	NN	NOUN
)	)	**.**	)	.	)	.	)	.
”	”	**.**	”	.	”	.	”	.
?	.	**.**	.	.	.	.	.	.
After	IN	**ADP**	IN	ADP	in	ADP	IN	ADP
all	ABN	**PRT**	ABN	PRT	abn	PRT	ABN	PRT
,	,	**.**	,	.	,	.	,	.
a	AT	**DET**	AT	DET	at	DET	AT	DET
guy’s*	NN+HVZ	**PRT**	NN$	NOUN	nn$	NOUN	Unk	Unknown
gotta*	VBN+TO	**VERB**	NN	NOUN	nn	NOUN	Unk	Unknown

Texto	**Etiqueta *gold***		**Etiquetado Perceptron**		**Etiquetado MaxEnt Stanford**		**Etiquetado TnT**	
	Brown	**Universal**	**Brown**	**Universal**	**Brown**	**Universal**	**Brown**	**Universal**
have	HV	**VERB**	HV	VERB	hv	VERB	HV	VERB
a	AT	**DET**	AT	DET	at	DET	AT	DET
little	AP	**ADJ**	QL	ADV	jj	ADJ	JJ	ADJ
ego	NN	**NOUN**	NN	NOUN	nn	NOUN	NN	NOUN
!	.	**.**	.	.	.	.	.	.
Therefore	RB	**ADV**	RB	ADV	rb	ADV	RB	ADV
it's	PPS+BEZ	**PRT**	PPS+BEZ	PRT	pps+bez	PRT	PPS+BEZ	PRT
a	AT	**DET**	AT	DET	at	DET	AT	DET
genuine	JJ	**ADJ**	JJ	ADJ	jj	ADJ	JJ	ADJ
pleasure	NN	**NOUN**	NN	NOUN	nn	NOUN	NN	NOUN
to	TO	**PRT**	TO	PRT	to	PRT	TO	PRT
tell	VB	**VERB**	VB	VERB	vb	VERB	VB	VERB
you	PPO	**PRON**	PPO	PRON	ppo	PRON	PPO	PRON
about	IN	**ADP**	IN	ADP	in	ADP	IN	ADP
an	AT	**DET**	AT	DET	at	DET	AT	DET
entirely	QL	**ADV**	QL	ADV	ql	ADV	QL	ADV
happy	JJ	**ADJ**	JJ	ADJ	jj	ADJ	JJ	ADJ
bodybuilder*	NN	**NOUN**	NN	NOUN	nn	NOUN	Unk	Unknown
who	WPS	**PRON**	WPS	PRON	wps	PRON	WPS	PRON
has	HVZ	**VERB**	HVZ	VERB	hvz	VERB	HVZ	VERB
never	RB	**ADV**	RB	ADV	rb	ADV	RB	ADV
had	HVN	**VERB**	HVN	VERB	hvd	VERB	HVN	VERB
to	TO	**PRT**	TO	PRT	to	PRT	TO	PRT
train	VB	**VERB**	VB	VERB	vb	VERB	VB	VERB
in	IN	**ADP**	IN	ADP	in	ADP	IN	ADP
secret	NN	**NOUN**	NN	NOUN	nn	NOUN	NN	NOUN
has	HVZ	**VERB**	HVZ	VERB	hvz	VERB	HVZ	VERB
never	RB	**ADV**	RB	ADV	rb	ADV	RB	ADV
heard	VBN	**VERB**	VBN	VERB	vbn	VERB	VBN	VERB
one	CD	**NUM**	CD	NUM	cd	NUM	CD	NUM
unkind*	JJ	**ADJ**	JJ	ADJ	jj	ADJ	Unk	Unknown
word	NN	**NOUN**	NN	NOUN	nn	NOUN	NN	NOUN
from	IN	**ADP**	IN	ADP	in	ADP	IN	ADP
his	PP$	**DET**	PP$	DET	pp$	DET	PP$	DET
parents	NNS	**NOUN**	NNS	NOUN	nns	NOUN	NNS	NOUN
and	CC	**CONJ**	CC	CONJ	cc	CONJ	CC	CONJ
never	RB	**ADV**	RB	ADV	rb	ADV	RB	ADV
has	HVZ	**VERB**	HVZ	VERB	hvz	VERB	HVZ	VERB
been	BEN	**VERB**	BEN	VERB	ben	VERB	BEN	VERB
taunted	VBN	**VERB**	VBN	VERB	vbd	VERB	VBD	VERB
by	IN	**ADP**	IN	ADP	in	ADP	IN	ADP
his	PP$	**DET**	PP$	DET	pp$	DET	PP$	DET
schoolmates*	NNS	**NOUN**	NNS	NOUN	nns	NOUN	Unk	Unknown
!	.	**.**	.	.	.	.	.	.
This	DT	**DET**	DT	DET	dt	DET	DT	DET
happy	JJ	**ADJ**	JJ	ADJ	jj	ADJ	JJ	ADJ
,	,	**.**	,	.	,	.	,	.
always	RB	**ADV**	RB	ADV	rb	ADV	RB	ADV
smiling	VBG	**VERB**	VBG	VERB	vbg	VERB	VBG	VERB
lad	NN	**NOUN**	NN	NOUN	nn	NOUN	NN	NOUN

Texto	**Etiqueta *gold***		**Etiquetado Perceptron**		**Etiquetado MaxEnt Stanford**		**Etiquetado TnT**	
	Brown	**Universal**	**Brown**	**Universal**	**Brown**	**Universal**	**Brown**	**Universal**
with	IN	**ADP**	IN	ADP	in	ADP	IN	ADP
the	AT	**DET**	AT	DET	at	DET	AT	DET
sunny	JJ	**ADJ**	JJ	ADJ	jj	ADJ	JJ	ADJ
disposition	NN	**NOUN**	NN	NOUN	nn	NOUN	NN	NOUN
is	BEZ	**VERB**	BEZ	VERB	bez	VERB	BEZ	VERB
our	PP$	**DET**	PP$	DET	pp$	DET	PP$	DET
new	JJ	**ADJ**	JJ	ADJ	jj	ADJ	JJ	ADJ
Junior	NP	**NOUN**	JJ-TL	ADJ	jj-tl	ADJ	JJ-TL	ADJ
Mr.	NP	**NOUN**	NP	NOUN	np	NOUN	NP	NOUN
Canada	NP	**NOUN**	NP	NOUN	np	NOUN	NP	NOUN
–	–	**.**	–	.	–	.	–	.
Henri	NP	**NOUN**	NP	NOUN	np	NOUN	NP	NOUN
De	NP	**NOUN**	NP	NOUN	np	NOUN	NP	NOUN
Courcy*	NP	**NOUN**	NP	NOUN	np	NOUN	Unk	Unknown
.	.	**.**	.	.	.	.	.	.
Far	RB	**ADV**	RB	ADV	rb	ADV	RB	ADV
from	IN	**ADP**	IN	ADP	in	ADP	IN	ADP
discouraging	VBG	**VERB**	VBG	VERB	jj	ADJ	JJ	ADJ
Henri	NP	**NOUN**	NP	NOUN	np	NOUN	NP	NOUN
,	,	**.**	,	.	,	.	,	.
his	PP$	**DET**	PP$	DET	pp$	DET	PP$	DET
parents	NNS	**NOUN**	NNS	NOUN	nns	NOUN	NNS	NOUN
urge	VB	**VERB**	IN	ADP	vb	VERB	VB	VERB
him	PPO	**PRON**	PPO	PRON	ppo	PRON	PPO	PRON
on	RP	**PRT**	IN	ADP	in	ADP	RP	PRT
to	IN	**ADP**	IN	ADP	in	ADP	IN	ADP
greater	JJR	**ADJ**	JJR	ADJ	jjr	ADJ	JJR	ADJ
and	CC	**CONJ**	CC	CONJ	cc	CONJ	CC	CONJ
greater	JJR	**ADJ**	JJR	ADJ	jjr	ADJ	JJR	ADJ
accomplishments	NNS	**NOUN**	NNS	NOUN	nns	NOUN	NNS	NOUN
.	.	**.**	.	.	.	.	.	.
Instead	RB	**ADV**	RB	ADV	rb	ADV	RB	ADV
of	IN	**ADP**	IN	ADP	in	ADP	IN	ADP
admonishing*	VBG	**VERB**	VBG	VERB	vbg	VERB	Unk	Unknown
him	PPO	**PRON**	PPO	PRON	ppo	PRON	PPO	PRON
to	TO	**PRT**	TO	PRT	to	PRT	TO	PRT
let	VB	**VERB**	VB	VERB	vb	VERB	VB	VERB
the	AT	**DET**	AT	DET	at	DET	AT	DET
weights*	NNS	**NOUN**	NNS	NOUN	nns	NOUN	Unk	Unknown
alone	RB	**ADV**	RB	ADV	rb	ADV	RB	ADV
they	PPSS	**PRON**	PPSS	PRON	ppss	PRON	PPSS	PRON
personally	RB	**ADV**	RB	ADV	rb	ADV	RB	ADV
took	VBD	**VERB**	VBD	VERB	vbd	VERB	VBD	VERB
him	PPO	**PRON**	PPO	PRON	ppo	PRON	PPO	PRON
to	IN	**ADP**	IN	ADP	in	ADP	IN	ADP
that	DT	**DET**	DT	DET	dt	DET	DT	DET
master	NN	**NOUN**	NN	NOUN	nn	NOUN	NN	NOUN
Montreal*	NP	**NOUN**	NP	NOUN	np	NOUN	Unk	Unknown
bodybuilding*	NN	**NOUN**	VBG	VERB	vbg	VERB	Unk	Unknown
authority	NN	**NOUN**	NN	NOUN	nn	NOUN	NN	NOUN

Texto	**Etiqueta *gold***		**Etiquetado Perceptron**		**Etiquetado MaxEnt Stanford**		**Etiquetado TnT**	
	Brown	**Universal**	**Brown**	**Universal**	**Brown**	**Universal**	**Brown**	**Universal**
,	,	**.**	,	.	,	.	,	.
Professor	NN-TL	**NOUN**	NN-TL	NOUN	nn-tl	NOUN	NN-TL	NOUN
Roland	NP	**NOUN**	NP	NOUN	np	NOUN	NP	NOUN
Claude	NP	**NOUN**	NP	NOUN	np	NOUN	NP	NOUN
.	.	**.**	.	.	.	.	.	.
And	CC	**CONJ**	CC	CONJ	cc	CONJ	CC	CONJ
they	PPSS	**PRON**	PPSS	PRON	ppss	PRON	PPSS	PRON
couldn't	MD*	**VERB**	MD*	VERB	md*	VERB	MD*	VERB
have	HV	**VERB**	HV	VERB	hv	VERB	HV	VERB
entrusted*	VBN	**VERB**	VBN	VERB	vbn	VERB	Unk	Unknown
Henri	NP	**NOUN**	NP	NOUN	np	NOUN	NP	NOUN
to	IN	**ADP**	TO	PRT	to	PRT	IN	ADP
better	RBR	**ADV**	VB	VERB	vb	VERB	JJR	ADJ
hands	NNS	**NOUN**	NNS	NOUN	nns	NOUN	NNS	NOUN
because	CS	**ADP**	CS	ADP	cs	ADP	CS	ADP
“	“	**.**	“	.	“	.	“	.
le	FW-AT	**X**	FW-AT	X	fw-at	X	FW-AT	X
professeur*	FW-NN	**X**	NN	NOUN	fw-nn	X	Unk	Unknown
”	”	**.**	”	.	”	.	”	.
knows	VBZ	**VERB**	VBZ	VERB	vbz	VERB	VBZ	VERB
his	PP$	**DET**	PP$	DET	pp$	DET	PP$	DET
muscles	NNS	**NOUN**	NNS	NOUN	nns	NOUN	NNS	NOUN
from	IN	**ADP**	IN	ADP	in	ADP	IN	ADP
the	AT	**DET**	AT	DET	at	DET	AT	DET
sterno-cleido*	NN	**NOUN**	JJ	ADJ	jj	ADJ	Unk	Unknown
mastoideus*	NN	**NOUN**	NN	NOUN	nn	NOUN	Unk	Unknown
of	IN	**ADP**	IN	ADP	in	ADP	IN	ADP
the	AT	**DET**	AT	DET	at	DET	AT	DET
neck	NN	**NOUN**	NN	NOUN	nn	NOUN	NN	NOUN
right	QL	**ADV**	QL	ADV	nn	NOUN	NN	NOUN
down	RP	**PRT**	RP	PRT	rp	PRT	RP	PRT
to	IN	**ADP**	IN	ADP	in	ADP	IN	ADP
the	AT	**DET**	AT	DET	at	DET	AT	DET
tibialis*	FW-NN	**X**	NN	NOUN	nn	NOUN	Unk	Unknown
anticus*	FW-JJ	**X**	NN	NOUN	nns	NOUN	Unk	Unknown
of	IN	**ADP**	IN	ADP	in	ADP	IN	ADP
the	AT	**DET**	AT	DET	at	DET	AT	DET
leg	NN	**NOUN**	NN	NOUN	nn	NOUN	NN	NOUN
and	CC	**CONJ**	CC	CONJ	cc	CONJ	CC	CONJ
better	QL	**ADV**	JJR	ADJ	jjr	ADJ	JJR	ADJ
still	RB	**ADV**	RB	ADV	rb	ADV	RB	ADV
,	,	**.**	,	.	,	.	,	.
he	PPS	**PRON**	PPS	PRON	pps	PRON	PPS	PRON
knows	VBZ	**VERB**	VBZ	VERB	vbz	VERB	VBZ	VERB
just	RB	**ADV**	RB	ADV	rb	ADV	RB	ADV
what	WDT	**DET**	WDT	DET	wdt	DET	WDT	DET
exercises	NNS	**NOUN**	VBZ	VERB	nns	NOUN	NNS	NOUN
work	VB	**VERB**	JJ	ADJ	vb	VERB	VB	VERB
best	RBT	**ADV**	JJT	ADJ	jjt	ADJ	RBT	ADV

Texto	**Etiqueta *gold***		**Etiquetado Perceptron**		**Etiquetado MaxEnt Stanford**		**Etiquetado TnT**	
	Brown	**Universal**	**Brown**	**Universal**	**Brown**	**Universal**	**Brown**	**Universal**
for	IN	**ADP**	IN	ADP	in	ADP	IN	ADP
them	PPO	**PRON**	PPO	PRON	ppo	PRON	PPO	PRON
and	CC	**CONJ**	CC	CONJ	cc	CONJ	CC	CONJ
what	WDT	**DET**	WDT	DET	wdt	DET	WDT	DET
Weider*	NP	**NOUN**	NN-TL	NOUN	np	NOUN	Unk	Unknown
principles	NNS	**NOUN**	VBZ	VERB	nns	NOUN	NNS	NOUN
to	TO	**PRT**	TO	PRT	to	PRT	TO	PRT
combine	VB	**VERB**	VB	VERB	vb	VERB	VB	VERB
them	PPO	**PRON**	PPO	PRON	ppo	PRON	PPO	PRON
with	IN	**ADP**	IN	ADP	in	ADP	IN	ADP
for	IN	**ADP**	IN	ADP	in	ADP	IN	ADP
fast	JJ	**ADJ**	JJ	ADJ	jj	ADJ	JJ	ADJ
,	,	**.**	,	.	,	.	,	.
fast	JJ	**ADJ**	JJ	ADJ	jj	ADJ	JJ	ADJ
muscle	NN	**NOUN**	NN	NOUN	nn	NOUN	NN	NOUN
growth	NN	**NOUN**	NN	NOUN	nn	NOUN	NN	NOUN
.	.	**.**	.	.	.	.	.	.
That's	DT+BEZ	**PRT**	DT+BEZ	PRT	dt+bez	PRT	DT+BEZ	PRT
because	CS	**ADP**	CS	ADP	cs	ADP	CS	ADP
the	AT	**DET**	AT	DET	at	DET	AT	DET
good	JJ	**ADJ**	JJ	ADJ	jj	ADJ	JJ	ADJ
professor	NN	**NOUN**	NN	NOUN	nn	NOUN	NN	NOUN
teaches	VBZ	**VERB**	VBZ	VERB	vbz	VERB	VBZ	VERB
only	RB	**ADV**	RB	ADV	rb	ADV	RB	ADV
Weider*	NP	**NOUN**	JJR	ADJ	np	NOUN	Unk	Unknown
methods	NNS	**NOUN**	NNS	NOUN	nns	NOUN	NNS	NOUN
at	IN	**ADP**	IN	ADP	in	ADP	IN	ADP
his	PP$	**DET**	PP$	DET	pp$	DET	PP$	DET
famous	JJ	**ADJ**	JJ	ADJ	jj	ADJ	JJ	ADJ
Montreal*	NP-TL	**NOUN**	NP	NOUN	np	NOUN	Unk	Unknown
Health	NN-TL	**NOUN**	NP	NOUN	nn-tl	NOUN	NN-TL	NOUN
Studio	NN-TL	**NOUN**	NN-TL	NOUN	nn-tl	NOUN	NN-TL	NOUN
which	WDT	**DET**	WDT	DET	wdt	DET	WDT	DET
is	BEZ	**VERB**	BEZ	VERB	bez	VERB	BEZ	VERB
located	VBN	**VERB**	VBN	VERB	vbn	VERB	VBN	VERB
at	IN	**ADP**	IN	ADP	in	ADP	IN	ADP
1821	CD	**NUM**	CD	NUM	cd	NUM	CD	NUM
Mt.	NN-TL	**NOUN**	NP	NOUN	nn-tl	NOUN	NN-TL	NOUN
Royal	JJ-TL	**ADJ**	JJ-TL	ADJ	jj-tl	ADJ	JJ-TL	ADJ
East	JJ-TL	**ADJ**	NR-TL	NOUN	jj-tl	ADJ	JJ-TL	ADJ
in	IN	**ADP**	IN	ADP	in	ADP	IN	ADP
Montreal*	NP	**NOUN**	NP	NOUN	np	NOUN	Unk	Unknown
.	.	**.**	.	.	.	.	.	.
Undoubtedly*	RB	**ADV**	RB	ADV	rb	ADV	Unk	Unknown
you	PPSS	**PRON**	PPSS	PRON	ppss	PRON	PPSS	PRON
have	HV	**VERB**	HV	VERB	hv	VERB	HV	VERB
read	VBN	**VERB**	VBN	VERB	vbn	VERB	VBN	VERB
the	AT	**DET**	AT	DET	at	DET	AT	DET
case	NN	**NOUN**	NN	NOUN	nn	NOUN	NN	NOUN
histories	NNS	**NOUN**	NNS	NOUN	nns	NOUN	NNS	NOUN

Texto	**Etiqueta *gold***		**Etiquetado Perceptron**		**Etiquetado MaxEnt Stanford**		**Etiquetado TnT**	
	Brown	**Universal**	**Brown**	**Universal**	**Brown**	**Universal**	**Brown**	**Universal**
of	IN	**ADP**	IN	ADP	in	ADP	IN	ADP
some	DTI	**DET**	DTI	DET	dti	DET	DTI	DET
of	IN	**ADP**	IN	ADP	in	ADP	IN	ADP
his	PP$	**DET**	PP$	DET	pp$	DET	PP$	DET
prize-winning*	JJ	**ADJ**	JJ	ADJ	nn	NOUN	Unk	Unknown
pupils	NNS	**NOUN**	NNS	NOUN	nns	NOUN	NNS	NOUN
(	(	**.**	(	.	(	.	(	.
every	AT	**DET**	AT	DET	at	DET	AT	DET
pupil*	NN	**NOUN**	NN	NOUN	nn	NOUN	Unk	Unknown
has	HVZ	**VERB**	HVZ	VERB	hvz	VERB	HVZ	VERB
a	AT	**DET**	AT	DET	at	DET	AT	DET
physique*	NN	**NOUN**	JJ	ADJ	nn	NOUN	Unk	Unknown
title	NN	**NOUN**	NN	NOUN	nn	NOUN	NN	NOUN
of	IN	**ADP**	IN	ADP	in	ADP	IN	ADP
some	DTI	**DET**	DTI	DET	dti	DET	DTI	DET
kind	NN	**NOUN**	NN	NOUN	nn	NOUN	NN	NOUN
or	CC	**CONJ**	CC	CONJ	cc	CONJ	CC	CONJ
other	AP	**ADJ**	AP	ADJ	ap	ADJ	AP	ADJ
)	)	**.**	)	.	)	.	)	.
.	.	**.**	.	.	.	.	.	.
There's	EX+BEZ	**PRT**	EX+BEZ	PRT	ex+bez	PRT	EX+BEZ	PRT
Gaetan*	NP	**NOUN**	NP	NOUN	np	NOUN	Unk	Unknown
D'Amours*	NP	**NOUN**	NP	NOUN	np	NOUN	Unk	Unknown
who	WPS	**PRON**	WPS	PRON	wps	PRON	WPS	PRON
is	BEZ	**VERB**	BEZ	VERB	bez	VERB	BEZ	VERB
our	PP$	**DET**	PP$	DET	pp$	DET	PP$	DET
newest	JJT	**ADJ**	JJT	ADJ	jjt	ADJ	JJT	ADJ
Mr.	NP	**NOUN**	NP	NOUN	np	NOUN	NP	NOUN
Canada	NP	**NOUN**	NP	NOUN	np	NOUN	NP	NOUN
;	.	**.**	.	.	.	.	.	.
Jean-Paul*	NP	**NOUN**	NP	NOUN	np	NOUN	Unk	Unknown
Senesac*	NP	**NOUN**	NP	NOUN	np	NOUN	Unk	Unknown
,	,	**.**	,	.	,	.	,	.
whose	WP$	**DET**	WP$	DET	wp$	DET	WP$	DET
story	NN	**NOUN**	NN	NOUN	nn	NOUN	NN	NOUN
appeared	VBD	**VERB**	VBD	VERB	vbd	VERB	VBD	VERB
here	RB	**ADV**	RB	ADV	rb	ADV	RB	ADV
two	CD	**NUM**	CD	NUM	cd	NUM	CD	NUM
issues	NNS	**NOUN**	NNS	NOUN	nns	NOUN	NNS	NOUN
ago	RB	**ADV**	RB	ADV	rb	ADV	RB	ADV
;	.	**.**	.	.	.	.	.	.
Jack	NP	**NOUN**	NP	NOUN	np	NOUN	NP	NOUN
Boissoneault*	NP	**NOUN**	NP	NOUN	np	NOUN	Unk	Unknown
,	,	**.**	,	.	,	.	,	.
who	WPS	**PRON**	WPS	PRON	wps	PRON	WPS	PRON
was	BEDZ	**VERB**	BEDZ	VERB	bedz	VERB	BEDZ	VERB
with	IN	**ADP**	IN	ADP	in	ADP	IN	ADP
us	PPO	**PRON**	PPO	PRON	ppo	PRON	PPO	PRON
last	AP	**ADJ**	AP	ADJ	ap	ADJ	AP	ADJ

Texto	**Etiqueta *gold***		**Etiquetado Perceptron**		**Etiquetado MaxEnt Stanford**		**Etiquetado TnT**	
	Brown	**Universal**	**Brown**	**Universal**	**Brown**	**Universal**	**Brown**	**Universal**
month	NN	**NOUN**	NN	NOUN	nn	NOUN	NN	NOUN
;	.	**.**	.	.	.	.	.	.
Charles	NP	**NOUN**	NP	NOUN	np	NOUN	NP	NOUN
Harve*	NP	**NOUN**	NP	NOUN	np	NOUN	Unk	Unknown
,	,	**.**	,	.	,	.	,	.
who	WPS	**PRON**	WPS	PRON	wps	PRON	WPS	PRON
recently	RB	**ADV**	RB	ADV	rb	ADV	RB	ADV
won	VBD	**VERB**	VBD	VERB	vbd	VERB	VBD	VERB
the	AT	**DET**	AT	DET	at	DET	AT	DET
“	“	**.**	“	.	“	.	“	.
Most	QL-TL	**ADV**	QL	ADV	ap	ADJ	QL-TL	ADV
Muscular*	JJ-TL	**ADJ**	JJ	ADJ	jj-tl	ADJ	Unk	Unknown
Man	NN-TL	**NOUN**	NN-TL	NOUN	nn-tl	NOUN	NN-TL	NOUN
”	”	**.**	”	.	”	.	”	.
subdivision	NN	**NOUN**	NN	NOUN	nn	NOUN	NN	NOUN
award	NN	**NOUN**	NN	NOUN	nn	NOUN	NN	NOUN
in	IN	**ADP**	IN	ADP	in	ADP	IN	ADP
the	AT	**DET**	AT	DET	at	DET	AT	DET
Mr.	NP	**NOUN**	NP	NOUN	np	NOUN	NP	NOUN
Canada	NP	**NOUN**	NP	NOUN	np	NOUN	NP	NOUN
event	NN	**NOUN**	NN	NOUN	nn	NOUN	NN	NOUN
;	.	**.**	.	.	.	.	.	.
and	CC	**CONJ**	CC	CONJ	cc	CONJ	CC	CONJ
a	AT	**DET**	AT	DET	at	DET	AT	DET
host	NN	**NOUN**	NN	NOUN	nn	NOUN	NN	NOUN
of	IN	**ADP**	IN	ADP	in	ADP	IN	ADP
others	NNS	**NOUN**	NNS	NOUN	nns	NOUN	NNS	NOUN
.	.	.	.	.	.	.	.	.

Referencias

[Berger 1996] Berger, A.L.; Della Pietra, S.A.; Della Pietra, V.J. (1996). *A Maximum Entropy Approach to Natural Language Processing.* Computational Linguistics 22, p. 39–71.

[Brants 2000] Brants, Thorsten. 2000. TnT – A Statistical Part-ofSpeech Tagger. In Proceedings of the Sixth Applied Natural Language Processing Conference (ANLP 2000), Seattle, WA, pp. 224–231.

[Francis 1979] Francis, W.N.; Kruceera, H. (1979). *Brown Corpus Manual*, `http://clu.uni.no/icame/manuals/BROWN/INDEX.HTM#bc6`

[Honnibal 2013A] Honnibal, M (2013). A Good Part-of-Speech Tagger in about 200 Lines of Python, `https://explosion.ai/blog/part-of-speech-pos-tagger-in-python`

[Honnibal 2013B] Honnibal, M.; Duong, L. (2013). *Source code for nltk.tag.perceptron*, `https://www.nltk.org/_modules/nltk/tag/perceptron.html`

[Jurafsky 2019] Jurafsky, D.; Martin, J.H. (2019). *Speech and Language Processing. An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition.* Third Edition draft, `https://web.stanford.edu/~jurafsky/slp3/ed3book.pdf`

[Manning 2000] Manning, C.D.; Schütze, H. (2000). *Foundations of Statistical Natural Language Processing*, MIT Press.

[Manning 2014] Manning, C. (2014), *Statistical natural language processing and corpus-based computational linguistics: An annotated list of resources*, `http://nlp.stanford.edu/links/statnlp.html`

[Ng 2012] Ng, A. (2012). *Machine Learning.* Coursera, `https://www.coursera.org/learn/machine-learning`

[nltk.corpus - Doc.] *nltk.corpus package* `https://www.nltk.org/api/nltk.corpus.html`

[nltk.tag - Code] *Source code for nltk.tag*, `https://www.nltk.org/_modules/nltk/tag.html`

[nltk.tag - Doc.] nltk.tag package, `https://www.nltk.org/api/nltk.tag.html`

[nltk.tag.tnt - Code] *Source code for nltk.tag.tnt,* `https://www.nltk.org/_modules/nltk/tag/tnt.html`

[Petrov 2012] Petrov, S.; Das, D.; McDonald, R. (2012). A Universal Part-of-Speech Tagset. Proceedings of the Eighth International Conference on Language Resources and Evaluation (LREC'12), `http://www.lrec-conf.org/proceedings/lrec2012/pdf/274_Paper.pdf`

[Petrov 2014] Petrov, S (2014). Universal-pos-tags (2014), Repositorio GitHub, `https://github.com/slavpetrov/universal-pos-tags`

[Ratnaparkhi 1998] Ratnaparkhi, A. 1998. *Maximum Entropy Models for Natural Language Ambiguity Resolution.* PhD Thesis, University of Pennsylvania.

[Ratnaparkhi 1996] Ratnaparkhi, A. (1996). *A maximum entropy model for part-of-speech tagging. In Proceedings of the Conference on Empirical Methods in Natural Language Processing*, University of Pennsylvania, pp. 133–142 [citado por [Toutanova 2000]]

[Stanford MaxEnt - download] The Stanford Natural Language Processing Group, *Stanford Log-linear Part-Of-Speech Tagger - Download* https://nlp.stanford.edu/software/stanford-postagger-2018-10-16.zip

[Stanford MaxEnt - code] The Stanford Natural Language Processing Group, *Source code for MaxentTagger -- StanfordMaxEnt, A Maximum Entropy Toolkit,* https://github.com/stanfordnlp/CoreNLP/tree/master/src/edu/stanford/nlp/tagger/maxent(clase principal: https://github.com/stanfordnlp/CoreNLP/blob/master/src/edu/stanford/nlp/tagger/maxent/MaxentTagger.java)

[Stanford MaxEnt - Doc.] The Stanford Natural Language Processing Group*Documentación for MaxentTagger -- StanfordMaxEnt, A Maximum Entropy Toolkit*, https://nlp.stanford.edu/nlp/javadoc/javanlp-3.5.0/edu/stanford/nlp/tagger/maxent/

[Stanford MaxEnt - FAQs] The Stanford Natural Language Processing Group. *Stanford POS tagger FAQ*, https://nlp.stanford.edu/software/pos-tagger-faq.html

[Toutanova 2000] Toutanova, K; Manning, C.D (2000). *Enriching the Knowledge Sources Used in a Maximum Entropy Part-of-Speech Tagger*. Proceedings of the Joint SIGDAT Conference on Empirical Methods in Natural Language Processing and Very Large Corpora (EMNLP/VLC-2000), pp. 63-70.

[Toutanova 2003] Toutanova, K.; Klein, D.; Manning, C.; Singer, Y. (2003). *Feature-Rich Part-of-Speech Tagging with a Cyclic Dependency Network*. Proceedings of HLT-NAACL 2003, pp. 252-259.