Máster en Tecnologías del Lenguaje
Técnicas Basadas en Grafos Aplicadas al Procesamiento del Lenguaje Natural

Tarea del tema 2: Estudio de distintos corpus

Ariadna Frutos Javierre
14 de noviembre de 2019

Introducción

En esta tarea se analizan cuatro grafos utilizando la herramienta Gephi y Microsoft Excel. Para cada grafo se incluye una visualización de la red y una tabla con algunas de sus características más relevantes. A continuación se estudia la distribución del grado mediante la representación gráfica en escalas convenientes y el ajuste de funciones adecuadas. Finalmente, a modo de conclusión, se añade una descripción cualitativa de la red, clasificándola según los modelos de red propuestos en el material de estudio del curso.

Características

Se describen a continuación los parámetros utilizados para caracterizar los grafos, según se incluyen en las tablas. Las definiciones de los parámetros proporcionados por Gephi se han obtenido de [Khokhar]. Algunas relaciones entre el valor de estos parámetros y los modelos propuestos, se han obtenido de [Araujo & Martínez Romo]; otras son propias. A parte de estos, se incluyen parámetros estadísticos que serán de ayuda para el análisis de la distribución del grado.

Dirigido: Sí/No. Un grafo es dirigido si los enlaces entre nodos tienen una dirección marcada, es decir, no son simétricos

Bipartito: Sí/No. Un grafo es bipartito si sus nodos pueden dividirse en dos conjuntos disjuntos U y V tales que cada enlace conecta a un nodo de U con un nodo de V.

Multigrafo: Sí/No. Un grafo es un multigrafo si puede existir más de un enlace entre los mismos nodos.

Con autoenlaces: Sí/No. Los autoenlaces son enlaces que salen y llegan al mismo nodo.

Con pesos: Sí/No. Los enlaces de un grafo tienen peso si tienen un valor asociado que determina la fuerza del enlace, que no es el mismo para todos ellos.

Nº nodos (N): Número de vértices del grafo. Se corresponde con el número de filas de la tabla de datos de nodos. A efectos de la descripción de la red, se considerará que una red es **pequeña** cuando $N \leq 100$, **mediana** cuando $100 < N \leq 1.000$, **grande** cuando $1.000 < N \leq 10.000$, **muy grande** cuando $10.000 < N \leq 100.000$ y **gigante** cuando $N > 100.000$.

ln(N): Logaritmo neperiano del número de nodos. Para modelos del tipo “mundos pequeños”, su valor es del orden del de la longitud media del camino entre nodos.

log(N): Logaritmo decimal del número de nodos. Para grafos aleatorios generados siguiendo el modelo Erdös-Renyi, variante $G_{n,p}$, su valor es del orden de la longitud media del camino entre nodos.

Nº enlaces (L): Número de aristas (enlaces entre nodos) del grafo. Se corresponde con el número de filas de la tabla de datos de aristas.

Grado medio: Número medio de enlaces que salen de (o entran en) un nodo. En grafos dirigidos, en que los enlaces son simétricos (entran y salen al mismo tiempo), su valor es $\bar{g} = 2 \cdot \frac{L}{N}$. En grafos dirigidos, en que los enlaces no son simétricos (los enlaces o bien salen, o bien entran), su valor es $\bar{g} = \frac{L'}{N}$, donde L' es el número total de enlaces de entrada (o de salida, pues es el mismo) del grafo.

Grado mínimo: Número de enlaces que salen de (o entran en) el nodo con menos aristas de salida (o de entrada, respectivamente) del grafo. A diferencia del grado medio, en grafos dirigidos su valor es distinto para el grado de entrada y el de salida. En la tabla se indica primero el valor correspondiente al grado de entrada, seguido del de salida.

Grado máximo: Número de enlaces que salen de (o entran en) el nodo con más aristas de salida (o de entrada, respectivamente) del grafo. A diferencia del grado medio, en grafos dirigidos su valor es distinto para el grado de entrada y el de salida. En la tabla se indica primero el valor correspondiente al grado de entrada, seguido del de salida.

Desviación típica del grado: Medida que cuantifica la variación del grado de los nodos del grafo. Su valor es $\sigma = \sqrt{\frac{\sum_i^N (g_i - \bar{g})^2}{N-1}}$. En grafos dirigidos, el valor de la desviación es distinta para el grado de entrada y el de salida. En la tabla se indica primero el valor correspondiente al grado de entrada, seguido del de salida.

Grado medio con pesos: Para grafos con pesos, media del grado con pesos de cada nodo, siendo esta la suma de los enlaces que entran o salen del nodo, ponderada según el peso de cada enlace.

Grado mínimo con pesos: Para grafos con pesos, grado con pesos del nodo cuyo grado con pesos es el menor de la red.

Grado máximo con pesos: Para grafos con pesos, grado con pesos del nodo cuyo grado con pesos es el mayor de la red.

Desviación típica del grado con pesos: Medida que cuantifica la variación del grado con pesos de los nodos del grafo. Se calcula de forma análoga a la desviación típica del grado.

Diámetro de la red: Distancia máxima entre cualquier par de nodos del grafo. La distancia entre dos nodos es el número mínimo de enlaces que hay que saltar para llegar de uno al otro.

Longitud media del camino entre nodos: Número medio de enlaces que hay que saltar para ir de un nodo cualquiera de la red a otro, siguiendo el camino más corto (con el menor número de saltos).

Densidad: Relación entre el número total de aristas que existen en el grafo y el número máximo de aristas que, dado el número de nodos, podría tener el grafo[1]. Esta medida da una indicación de lo próximo que está el grafo de ser un grafo completo (con todos sus nodos interconectados).

Modularidad: En un grafo dividido en comunidades, fracción de aristas que caen dentro de una de las comunidades. Su valor es $M = \sum_{i=1}^{k}\left(x_i - y_i^2\right)$, donde x_i es la probabilidad de que una arista esté dentro de la comunidad *i* e y_i^2 es la probabilidad de que una arista colocada aleatoriamente cayera dentro de la comunidad *i*. La detección de comunidades debe realizarse de manera que maximice el valor de la modularidad. Un valor alto de la modularidad es señal de que la red no está muy cohesionada y puede ser desintegrada fácilmente en comunidades. En todas las operaciones realizadas por Gephi para determinar comunidades y calcular la modularidad se han utilizado siempre los siguientes valores de los parámetros: *randomize* = *On*; *use edge weights* = *On*; *resolution*: 1.0.

Número de comunidades: Número de comunidades que resultan de dividir el grafo de modo que el valor de la modularidad sea máximo.

Número de componentes conexas fuertemente conectadas: Una componente conexa fuertemente conectada es un subconjunto de nodos del grafo, incluyendo aristas, tal que entre cualquier pareja de nodos existe un camino posible para ir del uno al otro, en cualquiera de los sentidos.

Número de componentes conexas débilmente conectadas: Una componente conexa débilmente conectada es un subconjunto de nodos del grafo, incluyendo aristas, tal que entre cualquier pareja de nodos existe un camino posible para ir del uno al otro, si no tenemos en cuenta la dirección de los enlaces.

Coeficiente de *clustering* medio: Media del coeficiente de *clustering* de cada uno de los nodos, $C = \frac{1}{N}\sum_{i}^{N} C_i$. El coeficiente de *clustering* de un nodo *i* es la proporción de vecinos directos de *i* que están conectados entre ellos. Su valor es $C_i = \frac{2e}{N(N-1)}$, donde *e* es el número de enlaces entre los nodos vecinos de *i*. El coeficiente de *clustering* medio es un indicador del grado en que los nodos tienden a aglutinarse.

[1] De lo que se deduce que su valor es $d = \frac{L}{N(N-1)}$ para grafos dirigidos y $d = \frac{2L}{N(N-1)}$ para grafos no dirigidos.

1. EuroSiSGenerale

La figura 1 muestra una visualización adecuada para hacerse una idea del mismo. Las características principales se listan en la tabla 1.

Figura 1: Grafo original del proyecto EuroSisGenerale.gephi

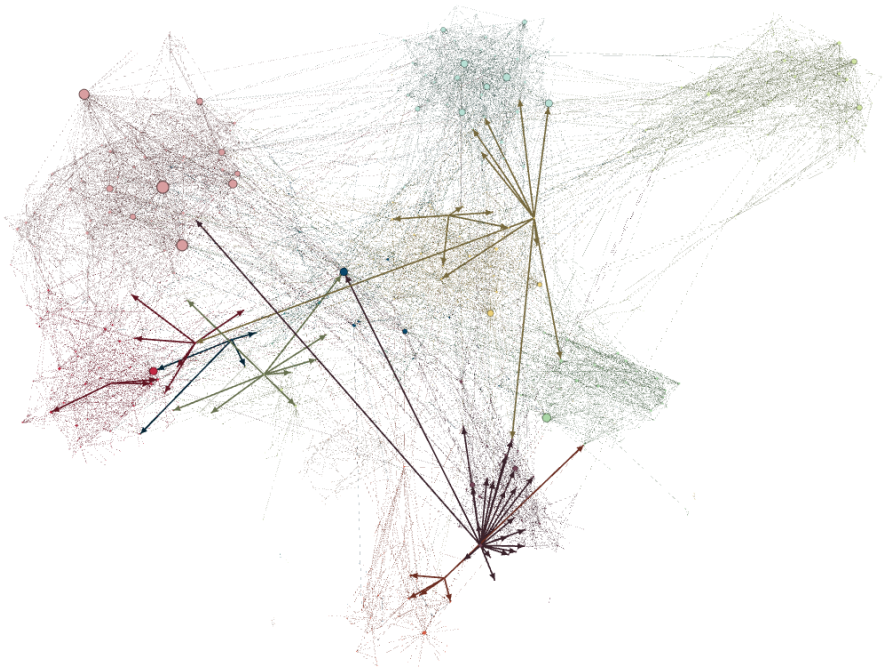

Esta versión del grafo se corresponde con la "Vista general" de la versión original incluido en el proyecto EuroSiSGenerale.gephi, proporcionado como material de la tarea. Las aristas gruesas corresponden a enlaces con peso 2; el resto tiene peso 1. Las zonas coloreadas resaltan la existencia de zonas más densas (comunidades)[2].

[2] La distribución de nodos en agrupaciones más densas muestra que el grafo se ha obtenido aplicando algún algoritmo de fuerza, en concreto Fruchterman Reingold pues, como muestran las siguientes imágenes, una nueva aplicación de este algoritmo no modifica de forma significativa la distribución original:

Distribución original

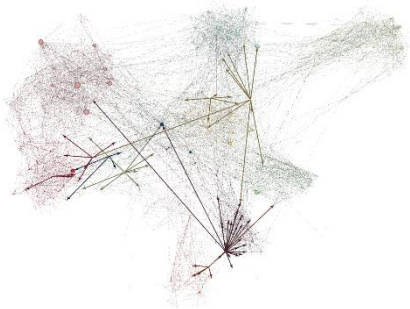

Distribución tras la aplicación del algoritmo Fruchterman Reingold sobre la distribución original. La visualización no cambia.

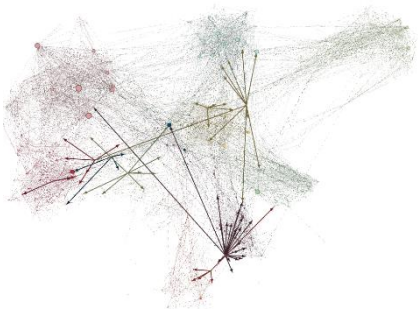

Distribución tras la aplicación del algoritmo Force Atlas sobre la distribución original. La visualización cambia.

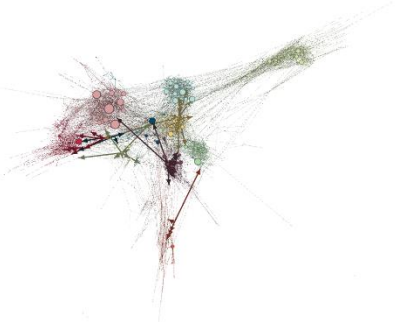

Tabla 1: Características principales del grafo EuroSisGenerale

Dirigido	Sí	**Grado medio con pesos**	5,904
Bipartito	No	**Grado mínimo con pesos**	0 / 0
Multigrafo	No	**Grado máximo con pesos**	83 / 98
Con autoenlaces	No	**Desviación típica del grado con pesos**	8,274 / 9,113
Con pesos	Con pesos, {1, 2}[3]	**Diámetro de la red**	14,000
Nº nodos (*N*)	1285	**Longitud media del camino entre nodos**	4,943
ln(*N*)	7,159	**Densidad**	0,005
log(*N*)	3,109	**Modularidad**	0,719
Nº de aristas (*L*)	7524	**Número de comunidades**	17
Grado medio	5,855	**Número de componentes conexas débilmente conectadas**	6
Grado mínimo	0 / 0	**Número de componentes conexas fuertemente conectadas**	511
Grado máximo	83 / 98	**Coeficiente medio de clustering medio**	0,213
Desviación típica del grado	8,220 / 9,049		

Distribución del grado

En la figura 2 se han representado las distintas distribuciones del grado en escalas normal y logarítmica. La forma de las distintas distribuciones es parecida en todos los casos (total/de entrada/de salida; con /sin peso). Las representaciones en escala logarítmica, cercanas a una recta, indican que la distribución sigue, aproximadamente, una ley de potencias. Es decir, la red sigue un modelo próximo a una red libre de escala.

Para la distribución del grado total ponderado, se ha calculado esta ley de potencias ajustando los datos a la regresión lineal:

$$\log(N_{k_pesos}) = \log(a) - C\cdot\log(k_pesos)$$

en dos rangos de k. Los valores de los parámetros obtenidos han sido:

- Rango *k_pesos* = 1 a 12 --> $\log(a) = 2.36$; $C = 0.77$ --> $N_{k_pesos} = 228\cdot k^{-0,77}$
- Rango *k_pesos* = 10 a 50 --> $\ln(a) = 3.47$; $C = 1.80$ --> $N_{k_pesos} = 2964\cdot k^{-1,80}$

[3] De los 7524 enlaces, solo 62 tienen peso 2.

Figura 2: Distribución del grado en el grafo EuroSiSGenerale

(a)

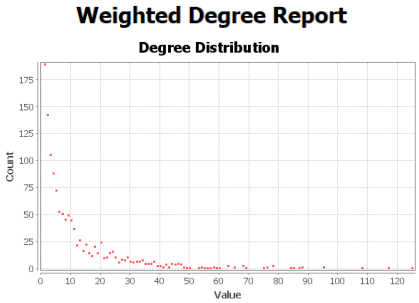

(b)

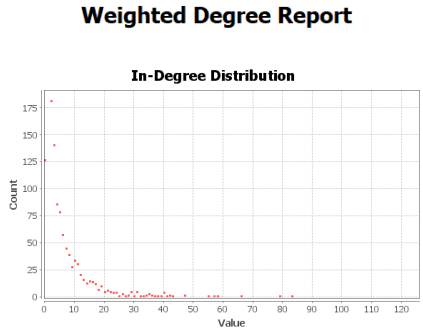

(c)

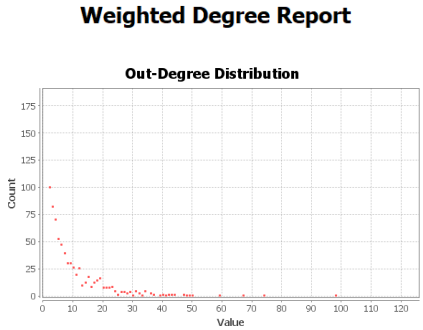

(d)

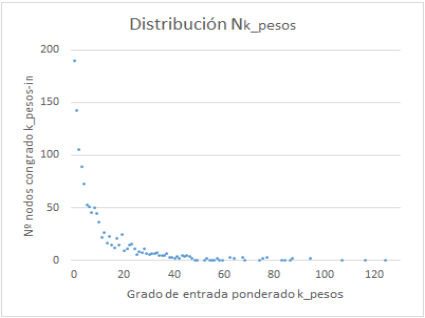

(e)

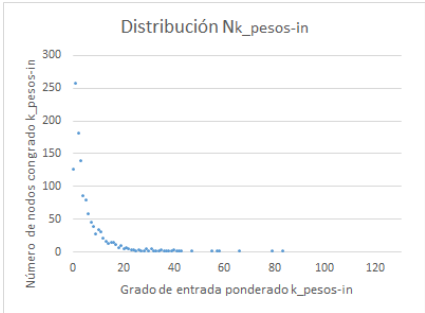

(f)

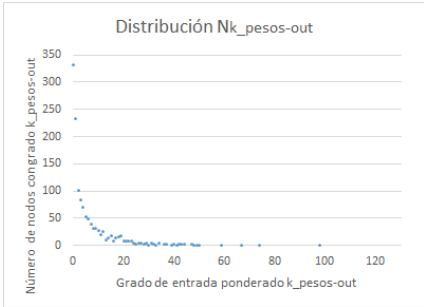

(g)

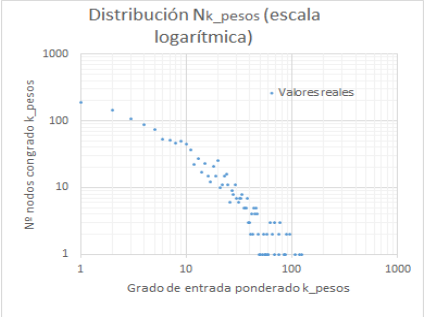

(h)

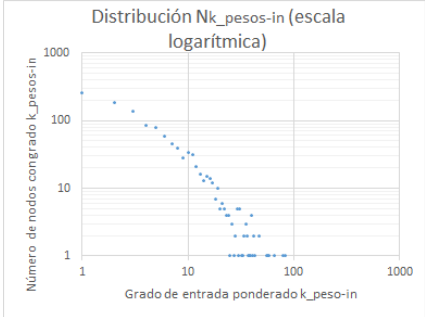

(i)

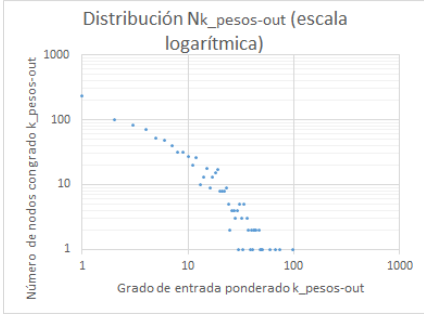

(j)

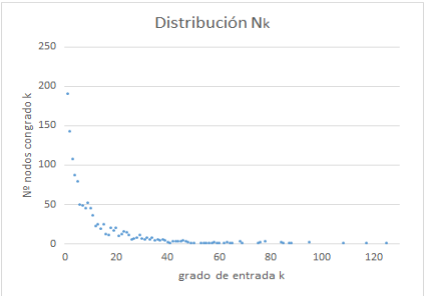

(k)

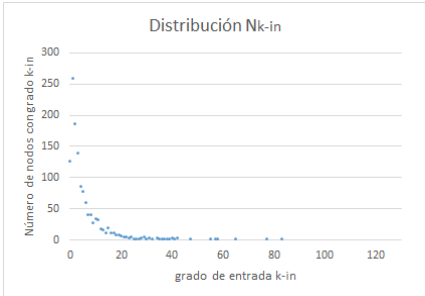

(l)

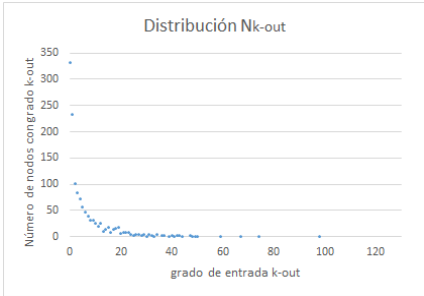

(m) *(n)* *(o)*

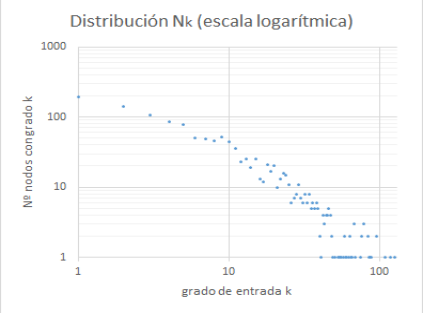

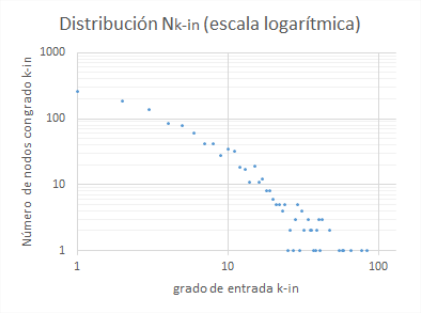

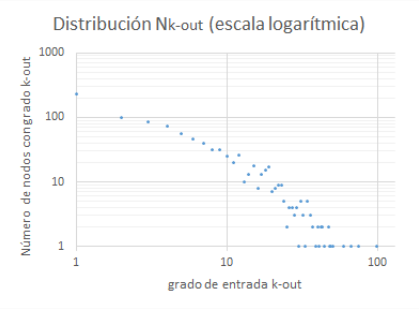

Las gráficas (a), (b) y (c), correspondientes a las distribuciones del grado con pesos total, de entrada y de salida, respectivamente, provienen del informe proporcionado por Gephi. En el eje de abscisas se indican los valores del grado ponderado, que en este grafo toma valores enteros entre 1 y 125 (los pesos de los enlaces no están normalizados, sino que pueden tomar los valores {1, 2}); en el eje de ordenadas se indica el número de nodos de la red cuyo valor del grado ponderado es el indicado en el eje de abscisas. Las gráficas (d), (e) y (f) corresponden a la misma distribución, pero representada utilizando el programa MS Excel. Nótese que, a diferencia de las gráficas proporcionadas por Gephi, en las generadas con MS Excel se han incluido los valores $N_{k_pesos\text{-}in}(0) = 258$ *y* $N_{k_pesos\text{-}out}(0) = 332$. *Los valores nulos, como* $N_{k_pesos}(0) = 0$ *no se han incluido en ninguna de las gráficas. Las gráficas (g), (h) e (i) corresponden a las distribuciones anteriores en escala logarítmica. Las gráficas (j) a (o) son análogas a las gráficas (d) a (i) pero en lugar del grado con peso, se ha tomado el grado sin pesos, es decir, el número neto de enlaces k.*

En la figura 3 se muestran los datos estimados según esta ley de potencia en dos tramos, junto con los datos reales de la distribución N_{k_pesos}

Figura 3: Ajuste de una ley de potencias a la distribución del grado con pesos de la red EuroSiSGenerale

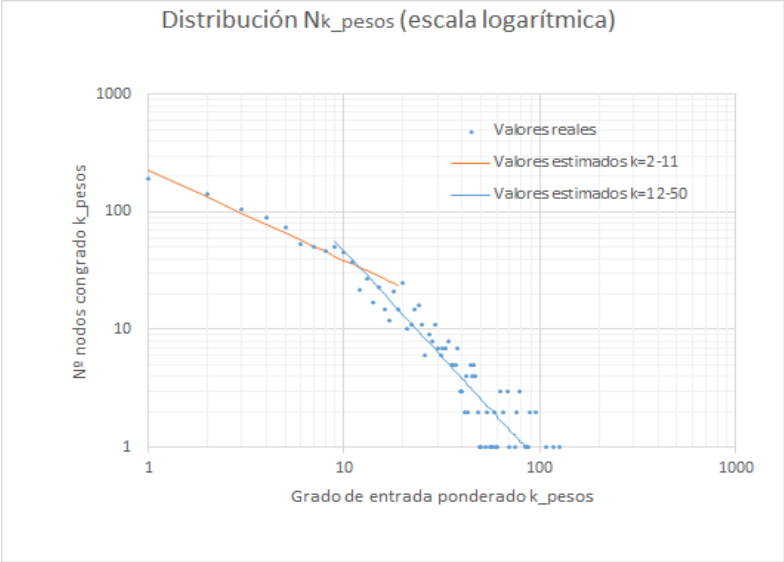

Clasificación

Como se indica en la tabla 1, EuroSiSGenerale es un grafo dirigido y con pesos. Se trata de una red relativamente grande y muy incompleta: la densidad es de tan solo 0,005. El grado medio de la red (5,9) es muy inferior al número de nodos (1285).

Como puede verse en la figura 4, en la que se han coloreado los nodos según su pertenencia a una componente conexa, la red está compuesta por una componente gigante que integra prácticamente la totalidad de la red y cinco componentes casi inapreciables (entre 2 y 4 nodos). El alto valor de la modularidad (0,719) nos indica que se trata de una red poco cohesionada; es decir, dentro de la componente gigante existen distintas comunidades enlazadas débilmente entre ellas. Por otro lado, el elevado coeficiente de *clustering* es signo de aglutinamiento en el sí de las comunidades. Esto, junto con el hecho de que tanto el camino medio entre nodos como el diámetro total de la red (4.9 y 14, respectivamente) sean significativamente pequeños en relación al número total de nodos, nos permite clasificar la red dentro del modelo de mundos pequeños. Asimismo, la distribución de grados, cercana a una ley de potencias[4], nos indica que la red también sigue un modelo de red libre de escala.

Figura 4: Red EuroSysGenerale, en la que se han coloreado las componentes débilmente conexas

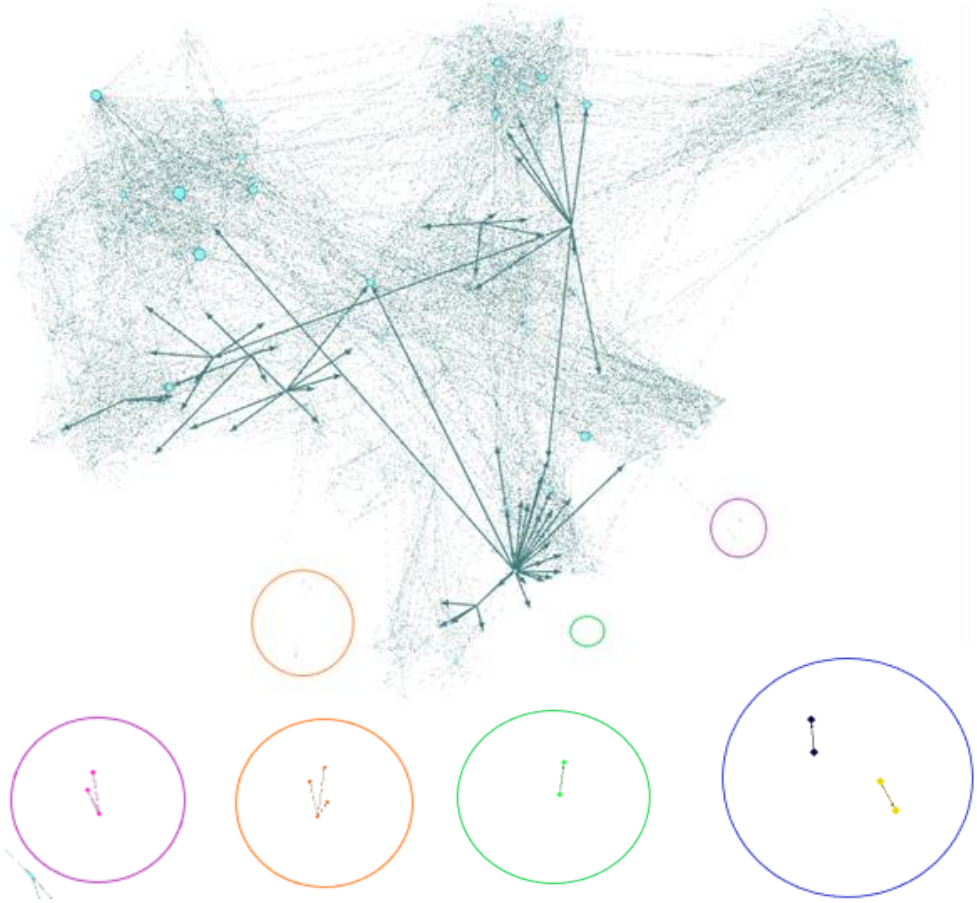

La red original se ha coloreado según el identificador de componente débilmente no conexa proporcionado por Gephis tras ejecutar el algoritmo Robert Tarjan, que identifica dichas componentes.

[4] En la sección anterior se ha ajustado una ley de potencias en 2 tramos. Aunque no tan bien ajustada, también podríamos haber ajustado los datos utilizando un rango único.

RetGraph

La figura 1 y la tabla muestran la representación y las características principales, respectivamente.

Figura 5: Grafo original del proyecto RetGraph.gephi

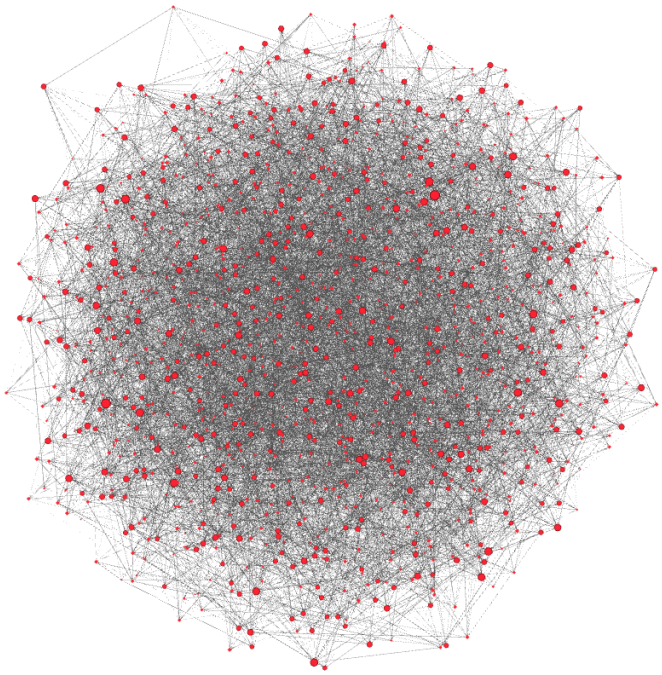

Esta versión del grafo se corresponde con la "Vista general" de la versión original incluida en el proyecto RetGraph.gephi, proporcionado como material para la realización de la tarea.

Tabla 2: Características principales del grafo RetGraph

Dirigido	Sí	**Grado medio con pesos**	0,26
Bipartito	No	**Grado mínimo con pesos**	0 / 0
Multigrafo	No	**Grado máximo con pesos**	0,77 / 0,82
Con autoenlaces	No	**Desviación típica del grado con pesos**	0,13 / 0,13
Con pesos	Con pesos, $[7{,}88\cdot10^{-6}, 9{,}9993\cdot10^{-2}]$	**Diámetro de la red**	10
Nº nodos (*N*)	1300	**Longitud media del camino entre nodos**	4,544
ln(*N*)	7,170	**Densidad**	0,004
log(*L*)	3,114	**Modularidad**	0,352
Nº aristas (*L*)	6708	**Número de comunidades**	19
Grado medio	5,16	**Número de componentes conexas débilmente conectadas**	1
Grado mínimo	0 / 0	**Número de componentes conexas fuertemente conectadas**	14

Grado máximo	15 / 15	**Coeficiente medio de *clustering* medio**	0,004
Desviación típica del grado	2,25 / 2,32		

Distribución del grado

En la figura 6 se han representado las distribuciones del grado total, de entrada y de salida, con pesos y sin pesos respectivamente, utilizando tipos de gráficas adecuados para facilitar la interpretación de los datos.

Figura 6: Distribución del grado en el grafo RetGraph

(a)

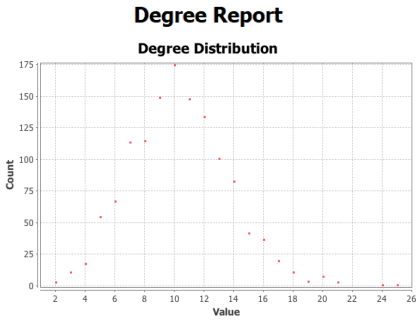

(b)

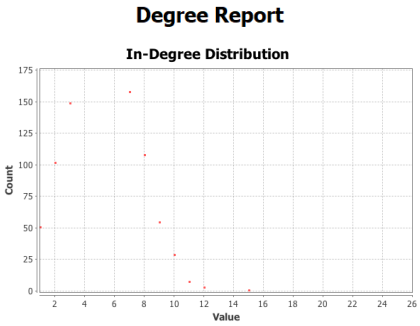

(c)

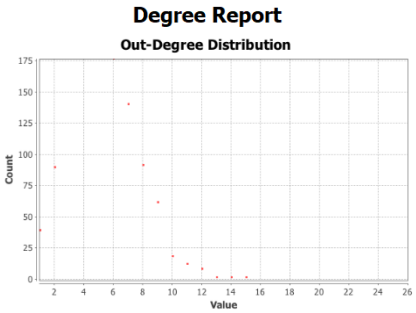

(d)

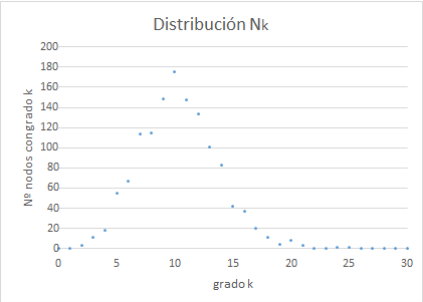

(e)

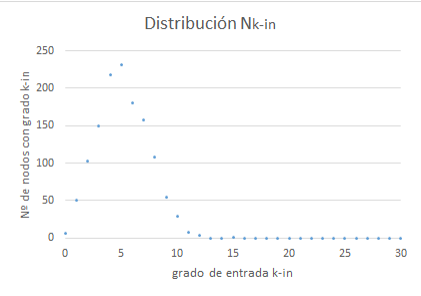

(f)

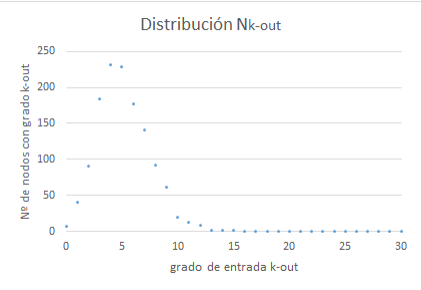

(g)

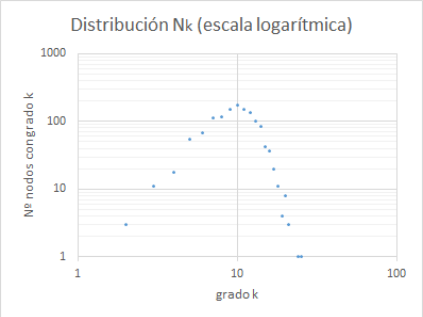

(h)

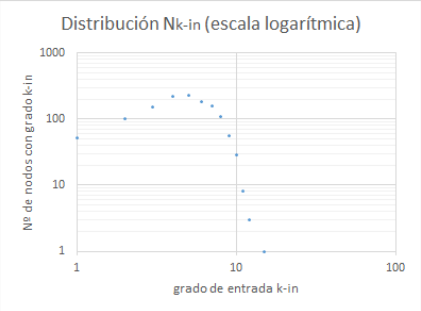

(i)

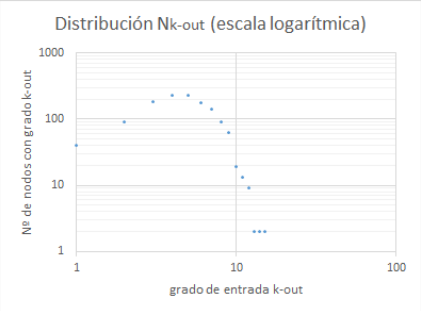

(j) *(k)* *(l)*

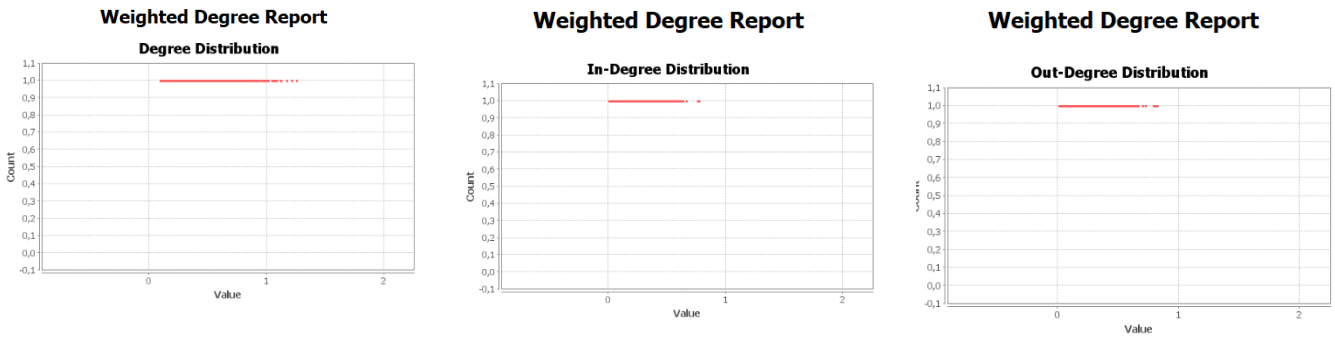

(m) *(n)* *(o)*

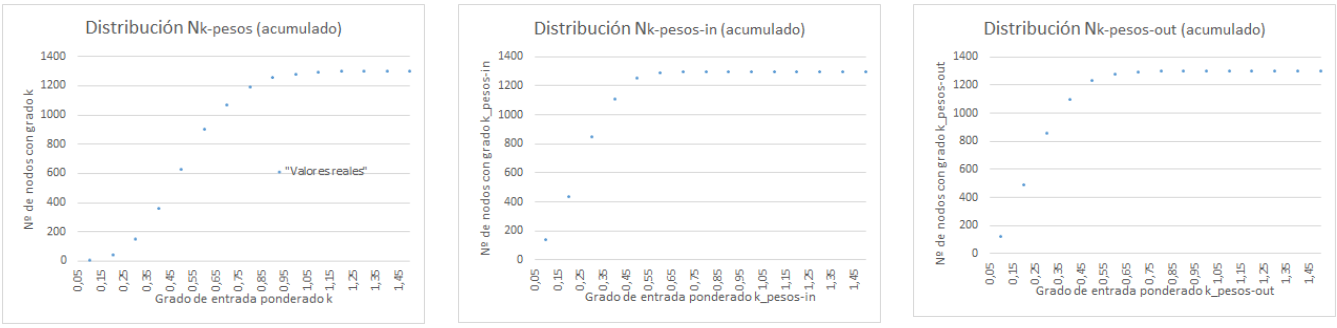

Las gráficas (a), (b) y (c), correspondientes a las distribuciones del grado neto (sin pesos) total, de entrada y de salida, respectivamente, provienen del informe proporcionado por Gephi. Las gráficas (d), (e) y (f) representan la misma distribución, pero se han construido utilizando MS Excel. En el eje de abscisas se indican los valores del grado y en el de ordenadas, el número de nodos que toman ese valor del grado. Nótese que en las gráficas correspondientes al grado total, (a) y (d), el máximo no se encuentra en el valor $\bar{g}$ proporcionado en la tabla 2, sino en $g = 2\bar{g}$. *Esto se debe a que el valor de $\bar{g}$ de la tabla se ha calculado contando o bien enlaces de salida, o bien enlaces de entrada ($\bar{g} = \frac{L}{N}$), mientras que en la distribución del grado total se está considerando la suma de enlaces de entrada y salida (lo que equivale a tratar el grafo como no dirigido, de modo que $\bar{g} = 2\frac{L}{N}$). . Las gráficas (h) a (j) son iguales a las anteriores, pero en este caso los datos se muestran en escala logarítmica.*

Las gráficas j, k y l corresponden a las distribuciones con pesos, en la versión proporcionada por Gephi. En el eje de abscisas se indican los valores del grado total ponderado, que en este grafo toma valores reales dentro del rango [0.094822673, 1.253663649]. (Los pesos de los enlaces individuales del grafo toman valores dentro del rango [0.00000789, 0.09999338].) En el eje de ordenadas se indica el número de nodos de la red cuyo valor del grado ponderado es el indicado en el eje de abscisas. Como los nodos toman valores reales de hasta 9 decimales, no existen dos nodos que tengan exactamente el mismo grado: todos los casos se dan una única vez, por lo que la distribución es una recta de ecuación y = 1. En las gráficas (m) a (n) se han representado los mismos datos, pero acumulados: para cada valor del grado representado en el eje de abscisas se han contabilizado los nodos que tienen un grado menor a ese valor.

Empezaremos el análisis considerando las distribuciones del grado sin pesos, más fáciles de interpretar. Las distribuciones del grado sin pesos total, de entrada y de salida se han representado en escala lineal en las gráficas (d), (e) y (f), respectivamente, de la figura 6. Las gráficas (g), (h) e (i) muestran las mismas distribuciones, pero en escala logarítmica. El hecho de que estas últimas gráficas no tengan forma de recta, nos permite afirmar que la distribución no sigue una ley de potencias. En cambio, la forma de campana de las representaciones lineales nos sugiere una

distribución probabilística. Como se muestra en la figura 7, la distribución del grado neto N_k se ajusta bastante bien a una distribución binomial de parámetros N = 1299 y p = 0.008. El valor n se ha calculado a partir del número total de nodos n, $N = n$ -1; el valor de p se ha encontrado manualmente, ajustando distintos valores hasta encontrar el óptimo.

Figura 7: Ajuste de una distribución binomial a la distribución del grado sin pesos de la red RetGrad

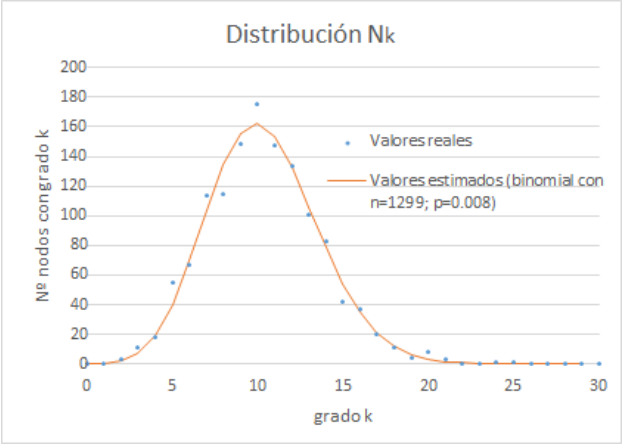

Al ser el número de nodos grande y la probabilidad pequeña, la distribución también puede ajustarse según una distribución de Poisson, como muestra la figura 8.

Figura 8: Ajuste de una distribución de Poisson a la distribución del grado sin pesos de la red RetGrad

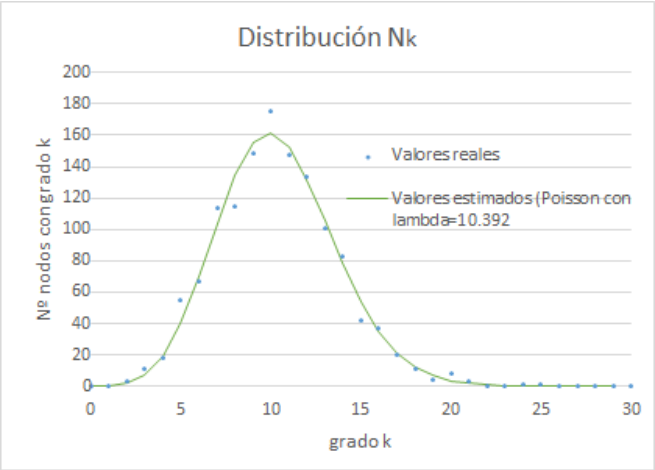

La distribución del grado ponderado acumulado (gráficas (m), (n) y (o)) también se asemeja a una distribución de probabilidad. Sin embargo, como en este caso el dominio no es natural, sino real, no podemos ajustar distribuciones binomial o de Poisson. En su lugar, se ha ajustado una gaussiana, utilizando como parámetros la media y la desviación típica de la red:

Figura 9: Ajuste de una campana de Gauss a la distribución del grado con pesos de la red RetGrad

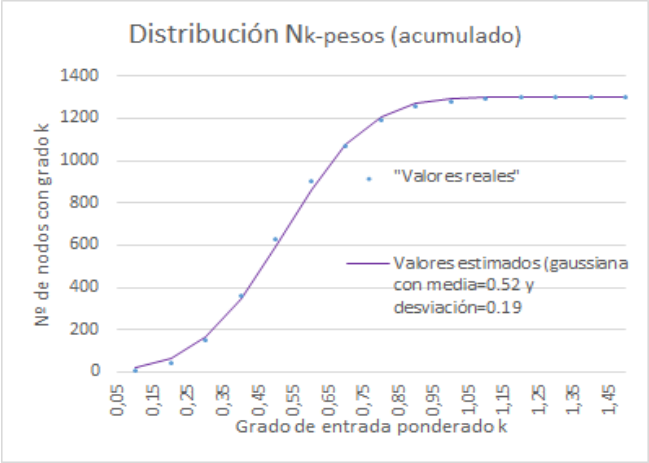

Clasificación

RetGraph es un multigrafo dirigido (hay 5 autoenlaces, véase la figura 10), con pesos, relativamente grande y muy incompleto: la densidad es de 0,004 (grado medio de 5,16 para 1300 nodos). Igual que el grafo anterior, EuroSiSGenerale, RetGraph está compuesto por una componente gigante, que en este caso incluye todos los nodos, sin excluir ninguno. No obstante, esta red está mucho más cohesionada que aquella, como indica el bajo coeficiente de modularidad (0,352). Esta cohesión también se aprecia en la visualización, en la que no se distinguen comunidades.

Se trata, asimismo, de una red muy regular: la desviación típica del grado neto es de tan solo 2.3 y la del grado ponderado, de 0.13. Este hecho, junto con el bajo valor del coeficiente de *clustering* medio (0.004), es indicativo de un posible modelo aleatorio. La longitud media del camino entre nodos (4,5) es del orden del logaritmo del número de nodos (3,1), lo cual es compatible con el modelo aleatorio Erdös-Renyi en la variante $G_{n,p}$. La forma de la distribución del grado también se ajusta perfectamente al modelo $G_{n,p}$, cuya distribución del grado es binomial, con parámetros $n = N$ y $p = C$. El valor del coeficiente de *clustering C* (0.004) de la red real no coincide exactamente con el valor de p que mejor ajusta la distribución (0.008), pero tampoco difiere de forma alarmante. Podemos concluir, pues, que RetGraph no es una red generada aleatoriamente pero, en muchos aspectos, puede ser analizada como tal.

Figura 10: Vista aumentada de los nodos con multienlaces de la red RetGraph

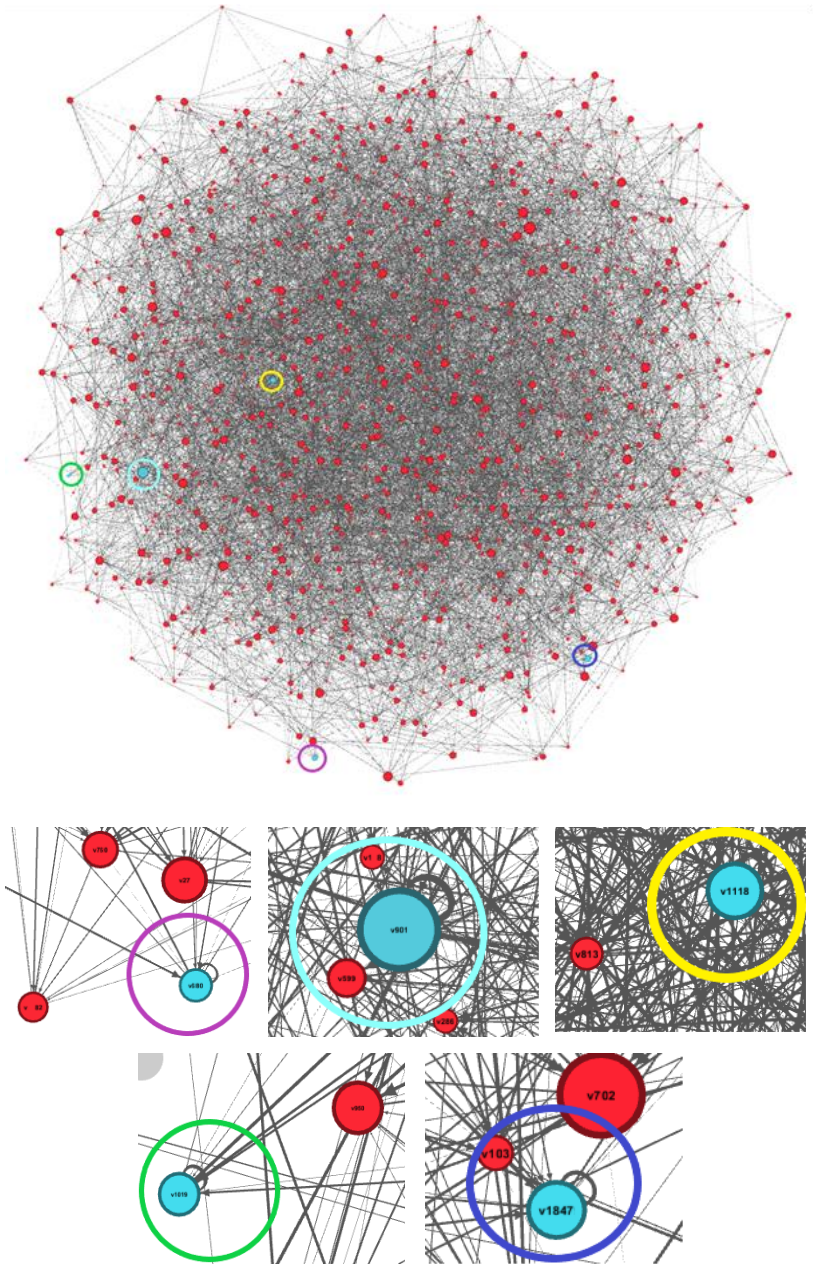

LesMiserables

La figura 11 muestra una visualización adecuada para hacerse una idea del mismo. Las características principales se listan en la tabla 3.

Figura 11: Grafo modificado del proyecto LesMiserables.gephi

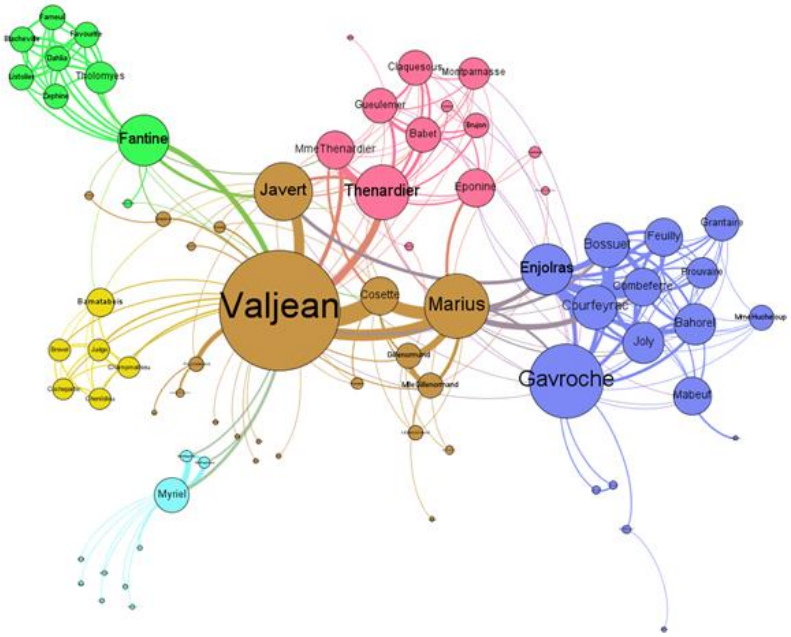

El grafo se ha obtenido aplicando un coloreado basado en los resultados obtenidos tras aplicar el algoritmo de asignación de comunidades a efectos de optimización del valor de la modularidad, con la opción "aleatorio" seleccionada y una resolución de 1,0[5].

[5]El grafo original incluido en el proyecto LesMiserables.gephi es:

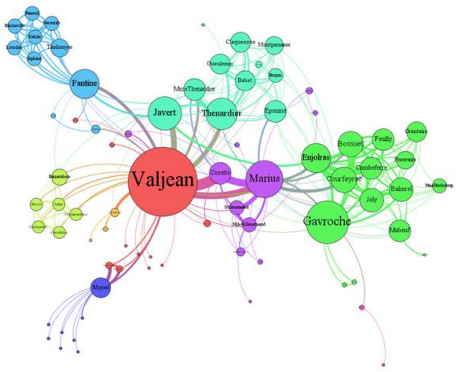

Tabla 3: Características principales del grafo LesMiserables

Dirigido	No	**Grado medio con pesos**	21.299
Bipartito	No	**Grado mínimo con pesos**	1
Multigrafo	No	**Grado máximo con pesos**	158
Con autoenlaces	No	**Desviación típica del grado con pesos**	22.75
Con pesos	Con pesos, [1, 158]	**Diámetro de la red**	5
Nº nodos (*n*)	77	**Longitud media del camino entre nodos**	2.641
ln(*n*)	4.344	**Densidad**	0.087
log(*n*)	1.886	**Modularidad**	0.565
Nº de aristas	254	**Número de comunidades**	6
Grado medio	6.597	**Número de componentes conexas débilmente conectadas**	1
Grado mínimo	1	**Número de componentes conexas fuertemente conectadas**	-
Grado máximo	36	**Coeficiente medio de *clustering* medio**	0.736
Desviación típica del grado	20.65		

Distribución del grado

En la figura 11 se han representado las distribuciones del grado con y sin pesos, respectivamente, utilizando tipos de gráficas adecuados para facilitar la interpretación de los datos. Vemos en las gráficas (b) y (c) que tanto la distribución del grado ponderado como la del grado neto son muy irregulares, con subidas y bajadas significativas. Claramente, no siguen ni una ley de potencia ni una distribución aleatoria claramente definidas. En las gráfica (e) se han agrupado los cómputos del grado ponderado en cajas de cinco. Es decir, se han sumado los nodos cuyo grado con peso está en el rango [0, 5), [5, 10), etc. Esta representación muestra de forma más clara el carácter decreciente de la distribución. En la gráfica (f) se han agrupado los cómputos del grado neto de forma análoga, aunque en cajas de 10. Vemos que, a pesar de haber agrupado los datos en cajas relativamente grandes, la distribución aún presenta un carácter bastante irregular: hay saltos muy pronunciados entre el número de personajes que aparecen poco o tienen poca interacción con otros personajes (menos de 10), el número de personajes que tienen entre 10 y 70 interacciones, y los que tienen más de 70.

Figura 12: Distribución del grado en el grafo LesMiserables

(a)

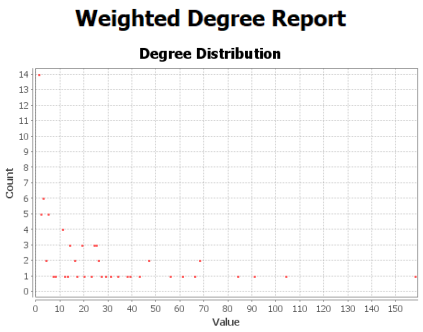

(b)

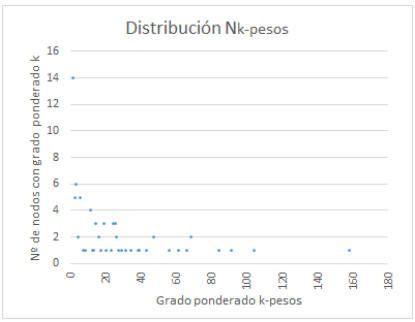

(c)

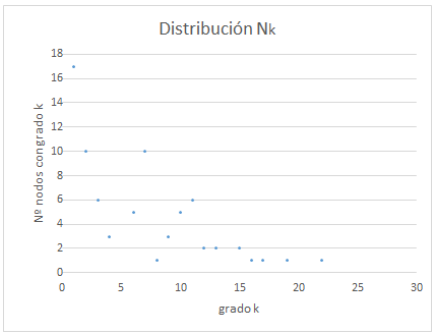

(d)

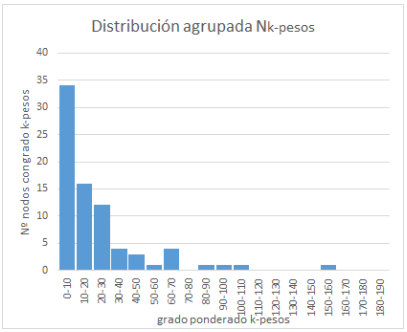

(e)

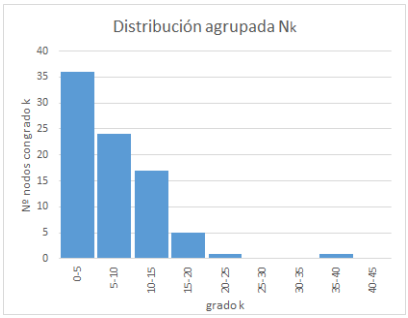

(f)

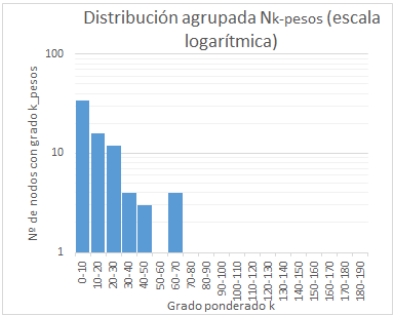

(g)

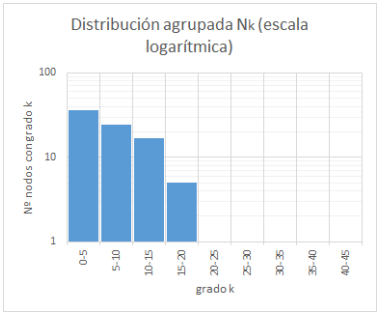

La primera gráfica, (a), corresponde a la distribución con pesos proporcionada por Gephi. Los pesos, que representan el número de veces que co-aparecen los dos nodos enlazados, toman valores naturales en el rango [1, 158]. La segunda gráfica, (b), es la versión en Excel de la primera. La tercera (c) es la distribución sin pesos; el dominio es el rango [1, 31] de los números naturales. En estas tres gráficas se aprecia el carácter irregular de la distribución. En las gráficas (d) y (e) se han agrupado los datos de las dos gráficas anteriores en cajas de 5 y 10 unidades respectivamente, para poder visualizar más fácilmente la tendencia de las distribuciones. Las gráficas (f) y (g) representan también los datos agrupados, pero en escala logarítmica.

Descripción y clasificación

El grafo LesMiserables es un grafo pequeño (77 nodos), no dirigido y con pesos. Como se aprecia en la visualización del grafo (figura 11), la red sigue un modelo de mundos pequeños bien definido. Los datos calculados confirman el modelo: tiene un diámetro pequeño (5), el camino medio entre nodos (2.6) es significativamente menor que el logaritmo neperiano del número de nodos (4.3) y el coeficiente medio de *clustering* es grande (0.74).

El grafo entero está compuesto por una sola componente gigante. Esta componente, sin embargo, no está muy cohesionada: de las 6 comunidades coloreadas en la figura 11, algunas están muy débilmente unidas al resto de la red. De hecho, una de ellas quedaría totalmente separada si desapareciera el nodo puente que la une a la comunidad, Myriel. Destaca, por su centralidad, el nodo Valjean, con enlaces a hacia todas las comunidades. No se trata, sin embargo de un nodo puente: si desapareciera, la red continuaría estando totalmente conectada.

Como en los casos anteriores, se trata de una red incompleta, aunque no tanto aquellas: la densidad es de 0.087 (77 nodos, grado medio de 6.60). En cambio, es una red muy irregular: la desviación típica del grado neto es de 21.3, y la del grado medio con pesos, de 22.8. Este valor no debe sorprendernos, teniendo en cuenta que habiendo solo 77 nodos, el grado ponderado de estos varía entre 1 y 151. Este carácter irregular también se aprecia en las gráficas de la distribución del grado (figura 12, gráficas (b) y (c)), para las cuales parece difícil ajustar un modelo. Se ha visto en el apartado anterior que, si reducimos la variabilidad del grado agrupando los datos en cajas (gráficas (d) y (e) en escala lineal y (f) y (g) en escala logarítmica), la distribución toma una forma decreciente un poco más definida, aunque no lo suficiente para poder aplicar un modelo libre de escala.

BoundaryCountries

La figura 13 muestra una visualización adecuada para hacerse una idea del mismo. Las características principales se listan en la tabla 4.

Figura 13: Grafo modificado del proyecto Boundary Countries.gephi

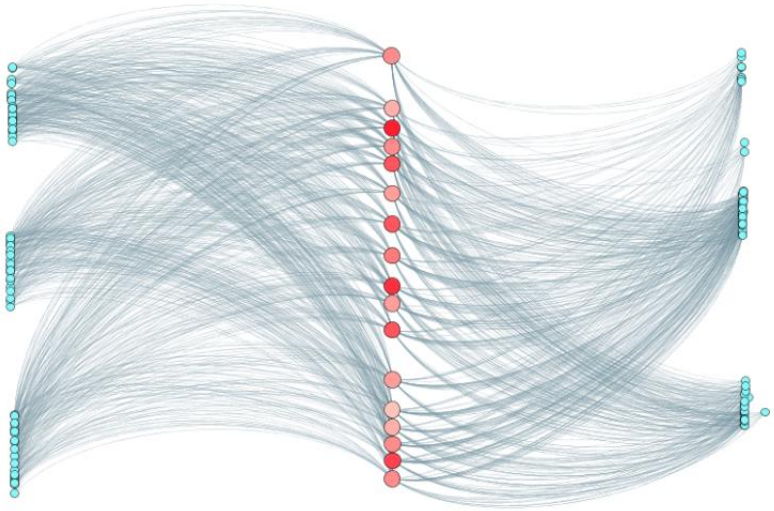

El grafo original incluido en el proyecto Boundary Countries.gephi ha sido modificado en varios aspectos para facilitar su interpretación. En concreto:

- *Se han repintado los nodos con los siguientes colores:*
  - *En escala turquesa, los nodos con grado de salida no nulo (paises)*[6].
  - *En escala rosa-rojo, los nodos con grado de entrada no nulo (distrito). Colores más claros corrresponden a grados más bajos.*
- *Se han separado más los nodos tipo país de los nodos tipo distrito, para dar más espacio a los enlaces.*
- *Se han separado los nodos tipo categoría entre ellos.*
- *Se ha generado una previsualización con los enlaces dibujados con curvas cuya curvatura indica la dirección del enlace, que sigue el sentido de las agujas del reloj.*

Tabla 4: Características principales del grafo BoundaryCountries

Dirigido	Sí	**Grado máximo**	Distrito: 81 / 0 País: 0 / 10
Bipartito	Sí	**Desviación típica del grado**	Distrito: 2,564 / 0 País: 0 / 0
Multigrafo	No	**Diámetro de la red**	1
Con autoenlaces	No	**Longitud media del camino entre nodos**	1

[6] Como consecuencia de esta operación se han pintado tres nodos grises del grafo original: se trata de los nodos "Mozambique", "Myanmar" y "Nagorno-Karabakh", que en la tabla de datos no están categorizados, probablemente por error, como país.

Con pesos	Sin pesos	**Densidad**	0.122[7]
Nº nodos (*n*)	Distrito: 17 País: 126 + 3[8]	**Modularidad**	0.155
ln(*n*)	4.984	**Número de comunidades**	3
log(*n*)	2.164	**Número de componentes conexas débilmente conectadas**	1
Nº de aristas	1290	**Número de componentes conexas fuertemente conectadas**	146
Grado medio	Distrito: 75,88 País: 10	**Coeficiente medio de clustering medio**	0
Grado mínimo	Distrito: 72 / 0 País: 0 / 10		

Distribución del grado

Como se indica en la tabla 4, el grafo BoundaryCountries es un grafo bipartito. Sus enlaces tienen una dirección única bien definida: desde un nodo de la categoría "País" hasta un nodo de categoría "Distrito". El grado de entrada de los nodos tipo "País" es, pues, siempre cero, al igual que el grado de salida de los nodos tipo "Distrito". La distribución del grado de salida en los nodos tipo "País" y la del grado de entrada de los nodos tipo "Distrito" se muestran en la figura 14. Esta última distribución, es, de hecho, un simple punto: los 126 nodos de la categoría país tienen el mismo grado, 10. Los puntos de la distribución del grado de salida, cuya media es 75.88, se distribuyen alrededor del valor medio de forma aproximadamente piramidal, con el máximo cerca del valor medio. Claramente, la distribución no sigue una ley de potencias. Por otro lado, el número de puntos es demasiado pequeño, para intentar ajustar un modelo aleatorio.

Figura 14: Distribución del grado en el grafo BoundaryCountries

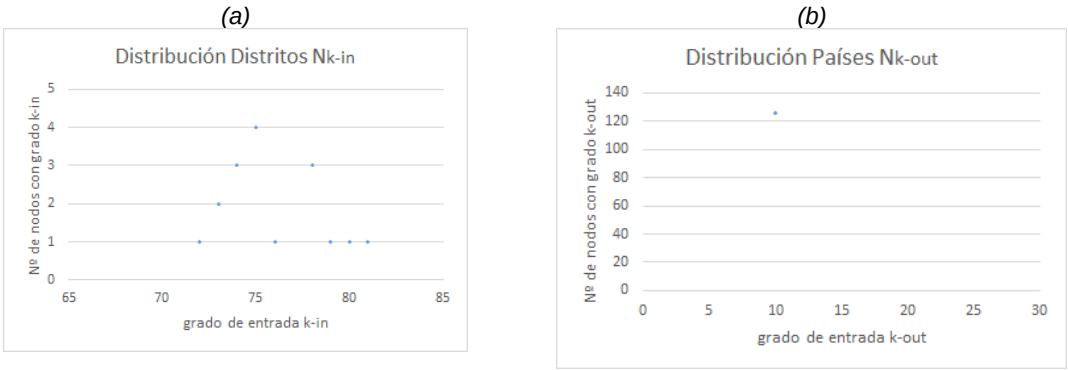

(a) Distribución del grado de entrada de los nodos de categoría "Distrito". (b) Distribución del grado de salida de los nodos de categoría "País".

[7] Este es el valor resultante de considerar que el grafo es no dirigido. Al tratarse de un grafo bipartito los enlaces, aunque dirigidos, tienen una dirección definida entre dos subconjuntos, no son simétricos. Por lo tanto, la fórmula correcta es la correspondiente a grafos no dirigidos.
[8] El 3 se refiere a los países de la nota anterior.

Clasificación

BoundaryCountries es un grafo dirigido, bipartito, totalmente regular en lo que respecta al grado de salida (que tiene siempre el mismo valor) y muy regular en lo que respecta al grado de entrada: la desviación típica relativa de este último es tan solo el 3,4% ($\frac{\alpha}{\bar{g}} = \frac{2,56}{75,88} = 3,4$). Es un grafo muy completo: siendo una red mucho más pequeña que EuroSisGenerale y RetGraph (146 nodos), tiene un grado medio muy superior al de aquellos (10 en el caso de los países y 75,88 para los distritos)[9]. La densidad (0,122) es, ciertamente, mayor que en el resto de grafos estudiados hasta ahora. Por último, la visualización de la figura 13 ya deja entrever que se trata de una red muy cohesionada, lo cual confirma cuantitativamente el valor de la modularidad (0,155). En la figura 14 se incluye una nueva visualización que muestra de forma todavía más patente esta estructura cohesionada.

Figura 15: Nueva visualización del grafo BoundaryCountries

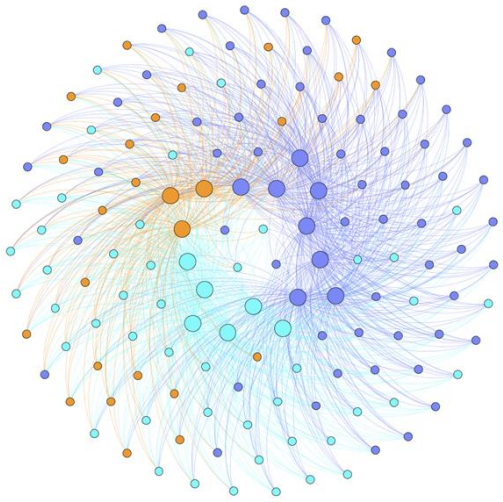

Esta visualización se ha conseguido tras aplicar el algoritmo de fuerza gravitatoria Fruchterman Reingold a la red original. Se han coloreado los nodos según la comunidad asignada por Gephi al ejecutar el algoritmo de cálculo de la modularidad.

Bibliografía

[Khokhar] Khokhar, D. (2015). *Gephi Cookbook*. Packt Publishing, Birmingham – Mumbai.

[Araujo & Martínez Romo]. *TEMA 2: Redes y grafos, definiciones y conceptos*. Material de estudio de la asignatura, descargado de la plataforma Alf de la Universidad Nacional de Educación a Distancia (UNED)

[9] Aquí no tenemos en cuenta la densidad del grafo por considerarla mal definida. Según [Khokhar], la densidad es la relación entre el número de enlaces del grafo y el número de enlaces posibles. Pero aquí