Máster en Tecnologías del Lenguaje
Técnicas Basadas en Grafos Aplicadas al Procesamiento del Lenguaje Natural

Tarea del tema 5: Instrucciones del programa coapariciones.py

Ariadna Frutos Javierre
19 de mayo de 2020

Índice

Índice 1
1. Introducción 2
2. Requerimientos 2
3. Uso del programa 2
   3.1. Inicio del programa 2
   3.2. Salida 3
   3.3. Ejecución del programa 4
4. Bibliografía 6

1. Introducción

El programa coapariciones.py, implementado en Python, genera un grafo de co-ocurrencias de parejas de términos en un corpus de documentos. Los nodos del grafo son los términos del corpus de las categorías gramaticales seleccionadas. Entre dos términos existe un enlace si los dos términos se dan en un mismo documento a una distancia inferior de la delimitada por una ventana de texto de *n* palabras, a seleccionar por el usuario. El peso de los enlaces es el número de documentos en que se da la co-ocurrencia.

El programa constituye la primera fase del algoritmo TextRank [Mihalcea 2004], un algoritmo de clasificación basado en grafos que se utiliza en distintas aplicaciones del lenguaje natural, en particular en extracción de palabras y frases clave para generación de resúmenes. El grafo proporcionado por coocurrecias.py puede utilizarse como material de entrada de este algoritmo.

2. Requerimientos

Los sistemas operativos admitidos son Windows y Linux. Se requiere tener Python instalado, así como los siguientes módulos:

- getopt
- sys
- tkinter
- glob
- nltk
- re
- datetime

3. Uso del programa

3.1. Inicio del programa

El programa debe iniciarse desde la línea de comandos utilizando la siguiente orden:

pythonr *ruta_al_programa*/coocurrencias.py -i <*ruta_carpeta_entrada*> -o <*ruta_carpeta_salida*> -w <*ventana*> -t <*etiquetas*>

Si no se incluyen los argumentos de entrada al llamar el programa, éste los requerirá explícitamente o utilizará los fijados por defecto. Para la selección de la carpeta donde se ubican los archivos, si el usuario no la incluye al principio el programa abrirá el explorador de archivos del cliente para que pueda seleccionarla una vez iniciado.

Los argumentos de entrada son:

-h, --help: Consulta de la ayuda

-i --input_path: Ruta de la carpeta de los documentos a analizar. Si no se informa, el programa abrirá el explorador de archivos.

Los documentos deben ser textos etiquetados con mediante el formalismo término/etiqueta. Por ejemplo:

A/DT challenging/JJ problem/NN faced/VBN by/IN researchers/NNS and/CC developers/NNS

Para obtener textos etiquetados en este formato, puede utilizarse el etiquetador de Standford, http://nlp.stanford.edu/software/tagger.shtml.

-o, --output: Ruta de la carpeta donde se guardará la red. Si no se informa, el fichero se guardará en la carpeta donde se encuentre el fichero coocurrencias.py.

-w, --window Ventana de co-ocurrencia. Debe ser un número entero. El programa lo utilizará para definir la ventana de términos entre los que debe darse entre una pareja de términos para que se considere que co-ocurren.

-t, --tags: Listado de etiquetas del Penn Treebank [Marcus 1993] aceptadas como nodos del grafo. Por ejemplo:

["NN", "NNS", "JJ", "JJR", "JJS"].

Si no se informa, o si se informa con la cadena “all”, se incluirán todas las etiquetas (no se filtrará).

Las etiquetas del Penn Treebank pueden consultarse en https://www.ling.upenn.edu/courses/Fall_2003/ling001/penn_treebank_pos.html.

3.2. Salida

La salida es un fichero de texto con el grafo de concurrencias en formato Pajek:

```
*Vertices 3
1 "Term1"
2 "Term2"
3 "Term3"
*Edges
1 3 56
1 2 34
2 3 21
```

Es decir, primero se indican los nodos y después los enlaces. Los nodos se indican con una numeración incremental, mostrando un identificador numérico y el término al que corresponde, a un término por línea. Los enlaces se muestran con tres números, indicando los dos primeros los identificadores de los nodos a los que corresponde el enlace, y el tercero el peso del enlace (número de documentos de la colección en que hay coocurrencia de los términos). Si el peso del enlace es cero, no se muestra. En la siguiente figura se muestran trozos de un grafo real generado por el programa:

```
*Vertices 135
1 "accuraci"
2 "adapt"
3 "analysi"
4 "applic"
5 "approach"
6 "assimil"
7 "avail"
8 "basic"
9 "behavior"
10 "c"
...

*Edges
1 15 2
1 34 2
1 50 2
1 57 2
1 61 2
1 62 2
1 66 2
1 72 2
1 88 2
1 109 2

...
```

3.3. Ejecución del programa

A continuación se describe los pasos que sigue el programa y la información que muestra por pantalla. Todos estos pasos son sin intervención del usuario.

El programa empieza anotando por pantalla los parámetros de entrada utilizados para la generación del grafo, incluyendo la lista de documentos importados para el análisis, de los cuales se muestran los 50 primeros caracteres:

```
La red se calculará utilizando los siguientes valores:
*****************************************
Ruta de entrada: entrada_pruebas
Ruta de salida: ./
Ventana: 5
Etiquetas aceptadas: ['NN', 'NNS', 'JJ', 'JJR', 'JJS']
*****************************************

Importando textos...
8 textos importados:
*****************************************
'entrada_pruebas\1C-41.txt.tagged' '<s> A/DT challenging/JJ problem/NN faced/VBN by/IN...'
'entrada_pruebas\2C-42.txt.tagged' '<s> Ensemble/NNP Kalman/NNP filter/NN data/NNS ass...'
'entrada_pruebas\3C-44.txt.tagged' '<s> Wireless/NNP Sensor/NNP Networks/NNP have/VBP ...'
'entrada_pruebas\4C-41.txt - copia.tagged' '<s> A/DT challenging/JJ problem/NN faced/VBN by/IN...'
'entrada_pruebas\5C-42.txt - copia.tagged' '<s> Ensemble/NNP Kalman/NNP filter/NN data/NNS ass...'
'entrada_pruebas\6C-44.txt - copia.tagged' '<s> Wireless/NNP Sensor/NNP Networks/NNP have/VBP ...'
'entrada_pruebas\7Caracteres no permitidos.tagged' '<s> 1234/NNP Sens3or/NNP Netw*orks/NNP 55/VBP 4$/V...'
'entrada_pruebas\Caracteres no permitidos.tagged' '<s> 1234/NNP Sens3or/NNP Netw*orks/NNP 55/VBP 4$/V...'
*****************************************
```

Tras importar los textos, la aplicación los transforma en listas de tuplas (término, etiqueta) y normaliza y trunca los términos. La normalización incluye las siguientes acciones:

- Eliminación de los caracteres no alfabéticos
- Conversión mayúsculas a minúsculas
- Eliminación de términos censurados, como los elementos de inicio y final de texto <s> y <f>, y las palabras vacías (*stopwords*)

El truncado se realiza utilizando el algoritmo de Porter.

Una vez realizada la limpieza, se filtran las tuplas según las etiquetas permitidas y, con los términos resultantes, se genera el vocabulario, el conjunto de los términos, sin duplicados, que

constituirán los nodos del grafo. Del vocabulario se elimina el término vacío, que puede haberse generado durante la limpieza, al eliminar caracteres no alfabéticos. Tras este proceso, el programa muestra por pantalla el número de términos del vocabulario y los diez primeros términos, en orden alfabético:

```
Conversión el corpus en una lista de documentos con los tokens en formato lista
y generación del vocabulario...
Vocabulario generado: 135 términos. Mostrando los 10 primeros:
****************************************
accuraci
adapt
analysi
applic
approach
assimil
avail
basic
behavior
c
...
****************************************
```

El siguiente paso es la generación de una matriz de índices 2x2 en formato lista de listas: las filas se corresponden con las palabras del vocabulario y las columnas, con los documentos de la colección. El elemento [*i*][*j*] de la matriz es la lista localizaciones del término [*i*] del vocabulario en el documento [*j*] del corpus. Tras la generación, el programa muestra las localizaciones de los 10 primeros términos del vocabulario en los primeros 3 documentos. Véase el ejemplo de la figura siguiente. El término “accuraci” no aparece en el primer documento, en el segundo aparece en la posición 76 y en el tercero, en la posición 73. El término “adapt” aparece 6 veces en el primer documento, en las posiciones 13, 31, 41, 46, 53 y 60, y no aparece ninguna vez en el segundo y tercer documento.

```
Generando matriz de índices...
Matriz de índices generada. Mostrando índices de los 10 primeros terminos en los 3 primeros documentos
****************************************
Término 0(accuraci): [[], [76], [73]]
Término 1(adapt): [[13, 31, 41, 46, 53, 60], [], []]
Término 2(analysi): [[], [], [92]]
Término 3(applic): [[], [], [7]]
Término 4(approach): [[101, 107], [7, 13], [116, 122]]
Término 5(assimil): [[98], [4, 57], [113]]
Término 6(avail): [[57, 85], [51], []]
Término 7(basic): [[], [], [63]]
Término 8(behavior): [[61], [], []]
Término 9(c): [[89], [], []]
****************************************
```

El programa calcula el número de concurrencias de parejas de términos en la ventana *n* a partir de la matriz de índices, rastreando las parejas de términos para cada documento y contabilizando +1 si existe al menos una pareja de índices, uno para cada término, cuya diferencia sea menor o iqual que *n*. Por ejemplo, según la figura anterior, con una ventana *n*=10, la pareja “approach” y “assimil” tiene concurrencia en el primer documento (índices 101 y 98, respectivamente), en el segundo (índices 7 y 4) y en el tercero (índices 116 y 113); cada una de estas concurrencias suma +1 en el total de la pareja. La pareja “assimil” y “avail” tiene concurrencia en el segundo documento (índices 57 y 51). Las parejas “accuraci” y “adapt”, o “accuraci” y “approach”, no tienen concurrencia en los primeros tres documentos de la colección. Si se da más de una concurrencia en un mismo documento, solo se contabiliza la primera.

El programa genera el grafo de concurrencia a partir del vocabulario y los contajes de concurrencia entre parejas de términos. Este es el paso más lento, si el vocabulario es grande, la ejecución puede tardar unas horas. Una vez generado el grafo, se muestra por pantalla la ruta del fichero de salida y el número de vértices y enlaces del grafo. El nombre del fichero de salida se construye con la siguiente información, en este orden:

1. Fecha, en formato yyyy-mm-dd
2. Hora, en formato hh-mm-ss
3. Texto "Grafo"
4. Texto "Ventana", seguido del valor *n* de la ventana de texto utilizada.
5. Texto "Etiquetas", seguido de la lista de etiquetas aceptadas.

```
Calculando e imprimiendo el grafo...
Grafo generado
*****************************************
Ruta del grafo: ./2020-05-18_14-35-17_Grafo_Ventana_5_Etiquetas_['NN', 'NNS', 'JJ', 'JJR', 'JJS'].txt
Número de vértices: 135
Número de enlaces: 760
```

```
Calculando e imprimiendo el grafo...
Grafo generado
*****************************************
Ruta del grafo: ./2020-05-18_13-03-30_Grafo_Ventana_5_Etiquetas_.txt
Número de vértices: 135
Número de enlaces: 760
```

4. Bibliografía

[Marcus 1993] Marcus, M.; Santorini, B. y Marcinkiewicz, M.A (1993). *Building a Large Annotated Corpus of English: The Penn Treebank*" (1993), Association for Computational Linguistics

[Mihalcea 2004] Mihalcea, R y Tarau, P. (2004). *TextRank: Bringing Order into Texts.* Proceedings of the 2004 Conference on Empirical Methods in Natural Language Processing

[Pajek 1998], Batagelj, V. y MrvarPajek, A. (1998). *Program for Large Network Analysis*, Connections 21, p. 47. Para una descripción del formato Pajek, http://vlado.fmf.uni-lj.si/pub/networks/pajek/howto/text2pajek.htm