Máster en Tecnologías del Lenguaje
Descubrimiento de información en textos

Tarea del tema 6: Técnicas de minería de textos

Ariadna Frutos Javierre
26 de abril de 2020

Contenidos

Contenidos 1
0. Introducción 2
1. Colecciones utilizadas 2
1.1 La colección Reuters-21578 2
1.2 Las colecciones re0 y re1 de Cluto 2
2. Algoritmos y parámetros de *clustering* 3
2.1 Algoritmos 3
2.1.1 Bisecciones repetidas (repeated bisections, RB) 3
2.1.2 Método aglomerativo (AGGLO) 4
2.2 Funciones de similitud 4
2.2.1 Distancia coseno 4
2.2.2 Coeficiente de correlación 4
2.3 Funciones de criterio 4
2.3.1 Maximizar I2 5
2.3.2 Maximizar H2 5
2.4 Otros parámetros 6
3. Información de calidad estadística 6
3.1 Medidas internas 6
3.1.1 Valor de la función criterio 6
3.2 Medidas externas 6
3.2.1 Entropía 6
3.2.2 Pureza 7
4. Resultados 7
5. Análisis de los resultados 10
6. Bibliografía 12

0. Introducción

En esta tarea de utiliza la herramienta Cluto para calcular distintas soluciones de *clustering* de dos colecciones de documentos. En concreto se obtienen, para cada colección, ocho soluciones, combinando dos algoritmos, dos funciones de similitud y dos funciones de criterio distintas.

En la primera sección se describen las colecciones de documentos utilizadas. En la segunda, se presentan los algoritmos funciones de similitud y funciones de criterio seleccionadas. En la tercera se introducen las funciones estadísticas utilizadas para valorar la calidad de los resultados. En la cuarta se presentan los resultados. En la quinta se analizan los resultados y se indican, a modo de conclusión, las principales observaciones.

1. Colecciones utilizadas

1.1 La colección Reuters-21578

La colección Reuters-21578 es un conjunto de 21.578 documentos publicados por la agencia de noticias Reuters en 1987. Además, incluye 5 ficheros con listados de categorías de los siguientes tipos: temas (135), lugares (175), personas (267), intercambios (*exchanges*) (39) y organizaciones (56).

1.2 Las colecciones re0 y re1 de Cluto

Las colecciones utilizadas en este trabajo, re0 y re1 de Cluto, son una selección de documentos de la colección Reuters-21578 realizada por [Zhao 2002] que contienen una única categoría, los cuales han sido procesados para representarlos en un modelo de espacio vectorial. Además, se han eliminado palabras vacías y se han recortado las terminaciones morfológicas utilizando el algoritmo de Porter. Re0 contiene contiene 1504 documentos, 2886 términos y 13 categorías, mientras que re1 contiene 1657 documentos, 3758 términos y 25 categorías.

La información de cada subcolección se encuentra almacenada en 3 ficheros:

- Un fichero con extensión .mat.clabel, con los términos de cada subcolección. Cada fila del fichero corresponde a un término, el cual constituye una dimensión del espacio vectorial en que se representarán los documentos. Por ejemplo, las 5 primeras filas del fichero re0.mat.clabel son:

```
depart
sloane
sudden
imbal
subsidis6
```

- Un fichero con extensión .mat, con la representación de los documentos de la colección en el espacio de términos. Cada fila corresponde a un documento, para el cual se indica la frecuencia en que aparece cada término. Por ejemplo, la fila 889 del fichero re0.mat empieza por:

```
889      1 1.00    4 1.00   15 1.00   34 1.00   38 3.00
```

Es decir, el documento 889 de la subcolección contiene una instancia del término “depart”, una instancia del término “imbal”, etc., y 3 instancias del término “jump”, que es el que aparece en la fila 38 del fichero re0.mat.clabel. Como puede observarse, no se incluyen los términos con cero instancias en el documento. Es decir, las coordeandas “sloane”, “sudden y subsidis5 tienen valor 0 para este documento.

- Un fichero con extensión .mat.rclass, con la categoría asignada a cada uno de los documentos de la subcolección. Cada fila corresponde a un documento, del cual se incluye la categoría. Las 5 primeras filas del fichero re0.mat.rclass son:

```
housing
money
trade
reserves
money
```

indicando que la categoría del primer documento de la colección es “housing”, el de la segunda, “money”, etc.

2. Algoritmos y parámetros de *clustering*

Con cada una de las colecciones se han ejecutado distintos algoritmos de *clustering*, utilizando también distintas funciones de similitud y criterio. A continuación se describen los algoritmos y variables aplicadas.

2.1 Algoritmos

Tal como se pide en la descripción de la tarea proporcionado por el profesorado de la asignatura, se han seleccionado dos algoritmos, uno de partición y otro aglomerativo. La selección del algoritmo de *clustering* en Cluto se realiza mediante el parámetro –clmethod. Ambos algoritmos requieren que se incluya como parámetro el número de agrupaciones en que quiere dividir la colección, *k*. Se han comparado dos soluciones: *k=10* (la opción por defecto) y el número de clases *gold* de la colección, *k*=13 para la subcolección re0 y *k*=25 para re1.

2.1.1 Bisecciones repetidas (repeated bisections, RB)

Como algoritmo de partición se ha seleccionado el algoritmo bisecciones repetidas (*repeated bisections*, RB) por ser el método por defecto de la herramienta y porque da muy buenos resultados según [Zhao 2002]. Existe una variante que mejora los resultados (–clmethod=rbr), pero se ha descartado porque la mejora se debe a un refinamiento realizado tras aplicar el algoritmo RB.

Este método empieza dividiendo la matriz de similitud en dos grupos, se selecciona uno de ellos para ser biseccionado en el siguiente paso, y así hasta obtener el número de grupos deseado. La división en dos grupos se realiza de manera que se optimiza la función criterio seleccionada a nivel local. La selección del grupo a dividir puede hacerse de distintas maneras; en los cálculos de este trabajo se ha elegido la opción por defecto, –cstype=best, que selecciona el clúster cuya bisección optimizará el valor de criterio general de *clustering*.

2.1.2 Método aglomerativo (AGGLO)

El método AGGLO se ha seleccionado por ser el único algoritmo disponible en Cluto que es puramente aglomerativo. Se empieza agrupando los elementos por parejas de manera que se optimice la función criterio. Los grupos resultantes se vuelven a aparejar siguiendo el mismo criterio, y así sucesivamente hasta obtener el número de grupos deseado.

2.2 Funciones de similitud

Como se ha mencionado en el apartado 1.2, los documentos de las subcolecciones re0 y re1 se representan en un modelo de espacio vectorial, donde las dimensiones son los términos de la colección y las representaciones vectores cuyas coordenadas en cada dimensión son la frecuencia del término que corresponde a esa dimensión. Las funciones de similitud se definen a partir de este espacio vectorial.

Cluto solo ofrece dos funciones de similitud que sean aplicables a los algoritmos seleccionados, la distancia coseno y el coeficiente de correlación; las otras dos opciones, la distancia euclídea y el coeficiente extendido de Jaccard, solo están permitidas usando el método gráfico. Estas dos distancias son, pues, las que se han utilizado. La distancia coseno como función de similitud es, además, la opción por defecto en Cluto, y una de las más usadas en minería de textos.

2.2.1 Distancia coseno

La distancia coseno entre dos documentos es el coseno que forman sus respectivos vectores representación, es decir:

$$\cos(d_i, d_j) = \frac{d_i^t d_j}{\|d_i\| [\![d_j]\!]}$$

2.2.2 Coeficiente de correlación

El coeficiente de correlación de dos vectores es [Wikipedia 2020]:

$$\mathrm{corr}(d_i, d_j) = \frac{\sum_{p=1}^{n} (d_{i_p} - \bar{d}_i)(d_{j_p} - \bar{\bar{d}}_j)}{\sqrt{\sum_{p=1}^{n} (d_{i_p} - \bar{d}_i)^2} \sqrt{\sum_{p=1}^{n} (d_{j_p} - \bar{d}_j)^2}}$$

donde $\bar{d}_i$ y $\bar{d}_j$ son la media de las componentes de los documentos d_i y d_j, respectivamente. Cuando los vectores están centrados (la media de las componentes es cero) esta medida coincide con la distancia coseno. Este no es el caso aquí porque las componentes de las representaciones vectoriales de los documentos, $\bar{d}_i$ y $\bar{d}_j$ son positivas o iguales a cero.

2.3 Funciones de criterio

De las 11 funciones de criterio disponibles en Cluto, se han seleccionado las dos que dieron mejores resultados en [Zhao 2002]: maximizar I2 y maximizar H2. El manual de Cluto [Karypis 2003] coincide en recomendar estas dos funciones, siendo maximizar I2 la que ofrece el programa por

defecto. Además, estas dos métricas pueden aplicarse a los dos métodos utilizados, bisecciones repetidas y método aglomerativo, facilitando la comparativa.

2.3.1 Maximizar I2

La métrica I2 es una medida de la separación de los distintos documentos de un cluster a su centroide. En Cluto, la definición matemática es[1]:

$$\text{maximizar}(I_2) = \text{maximizar}\left(\sum_{i=1}^{k} \sum_{v,u \in S_i} \text{sim}(v,u)_2\right)$$

donde k es el número de clusters, S_i el número de documentos asignados al i-avo clúster y n_i el número de objetos del i-avo clúster.

Como puede verse, se trata de una métrica interna, ya que solo tiene en cuenta distancias dentro de un mismo clúster, no distancias entre clústers distintos.

2.3.2 Maximizar H2

La métrica H2 es una métrica híbrida, que combina la medida interna anterior, I2, con una medida externa, E1[2]:

$$\text{maximizar}(H_2) = \text{maximizar}\frac{I_2}{E_2}$$

donde

$$E_2 = \sum_{i=1}^{k} n_i \frac{\sum_{v \in S_i} \text{sim}(v,u)}{\sum_{v,u \in S_i} \text{sim}(v,u)_2}$$

---

[1] En [Zhao 2002] la definición matemática de I2 es algo distinta:

$$\text{maximizar } I_2 = \sum_{r=1}^{k} \sum_{d_i \in S_r} \cos(d_i, C_r),$$

siendo C_r el centroide del *cluster r*, definido como

$$C_r = \frac{\sum_{d \in r} d}{|r|}$$

[2] En [Zhao 2002] la definición de H2 es la misma, pero las definiciones de I2 y E1 difieren de las de Cluto. Véase la nota anterior para la primera; E2 es:

$$E_2 = \sum_{r=1}^{k} n_r \, \|C_r - C\|$$

donde C es el vector centroide de la colección y C_r el vector centroide de cada agrupación (media de todos los documentos que lo conforman

2.4 Otros parámetros

Además de la selección del algoritmo, la función de similitud y la función de criterio, Cluto permite modificar las siguientes opciones de cálculo:

- El número de veces que se realiza la operación de *clustering* antes de seleccionar la mejor, que es la que se guarda (parámetro –ntrials). Se ha mantenido el valor por defecto, 10.

- El número máximo de iteraciones de refirnamiento se realizan en cada paso de *clustering* (-niter). Se ha mantenido el valor por defecto, 10.

También es posible realizar algunas operaciones con la matriz de similitud antes de la ejecución del *clustering*, para refinar la distribución de los documentos, como:

- Escalado de filas y columnas (parámetros –rowmodel y –columnmodel)
- Poda de columnas que no contribuyen de forma relevante a la similitud entre filas (parámetro -colprune)

Para mantener la comparativa simple, no se han utilizado estas opciones.

3. Información de calidad estadística

Para valorar la calidad de las soluciones resultantes se utilizaran tres medidas proporcionadas por Cluto, una interna, el valor de la función criterio, y dos externas, la entropía y la pureza. Estas últimas requieren de información externa, de allí su categorización. En concreto, se requiere la distribución en clases *gold* de los términos, lo cual se encuentra en los ficheros re0.mat.rclass y re1.mat.rclass.

3.1 Medidas internas

3.1.1 Valor de la función criterio

La primera calidad de media es el valor de la función criterio, que en nuestro caso es I2 o H2 (véase apartado 2.3).

3.2 Medidas externas

3.2.1 Entropía

La entropía de una agrupación S_r de tamaño n_r es [Zhao 2002]:

$$E(S_r) = -\frac{1}{\log q}\sum_{i=1}^{q}\frac{n_r^i}{n_r}\log\frac{n_r^i}{n_r}$$

donde q es el número de clases de la colección y n_r^i es el número de documentos de la clase i que fueron asignados a la agrupación r.

La entropía de una determinada solución de *clustering S* es la suma ponderada de las entropías de cada agrupación:

$$E(S) = \sum_{i=1}^{k} \frac{n_r}{n_r} E(S_r)$$

Cuanto menor la entropía, mejor la solución de *clustering*. La solución perfecta es la de entropía cero. Esta solución corresponde a agrupaciones de documentos de una sola clase, sin existir más de una agrupación para cada clase.

3.2.2 Pureza

La pureza de una agrupación S_r de tamaño n_r es [Zhao 2002]:

$$P(S_r) = \frac{1}{n_r} \max_i (n_r^i)$$

La pureza de la solución global de *clustering* es de nuevo la suma ponderada:

$$P(S) = \sum_{i=1}^{k} \frac{n_r}{n_r} P(S_r)$$

En esta medida la relación de calidad es la contraria a la entropía: cuánto mayor es la pureza, mejor es la solución.

4. Resultados

En todos los casos el programa ha conseguido incluir todos los nodos en alguna agrupación. En general, este es el propósito de vcluster, pero cuando existen nodos que no comparten enlaces ningún otro modo, estos quedan excluidos. Las tablas 1 y 2 muestran las medidas de calidad para las soluciones con *k*=10 y *k*=número de clases originales; en las figuras 1 a 4 se han representado los datos gráficamente.

Tabla 1: Medidas de calidad de las soluciones de clustering con k=10 agrupaciones.

							Tiempo		
Algoritmo	**Función similitud**	**Función criterio**	**fichero**	**Entropía**	**Pureza**	**Valor de la función criterio**	**I/O**	**Clustering**	**Reporting**
rb	Coseno	Maximizar I2	re0	0,412	0,622	566	0,032	0,095	0,029
			re1	0,41	0,625	486	0,026	0,11	0,037
		Maximizar H2	re0	0,417	0,625	0,00204	0,036	0,11	0,23
			re1	0,419	0,62	0,00188	0,031	0,129	0,037
	Correlación	Maximizar I2	re0	0,405	0,644	825	0,023	3,811	0,093
			re1	0,493	0,575	655	0,043	6,195	0,121
		Maximizar H2	re0	0,427	0,608	0,00176	0,049	7,099	0,15

			re1	0,5	0,568	0,00167	0,051	7,137	0,127
agglo	Coseno	Maximizar I2	re0	0,481	0,548	547	0,032	0,349	0,045
			re1	0,47	0,552	464	0,05	0,466	0,061
		Maximizar H2	re0	0,478	0,561	0,00186	0,034	6,556	0,021
			re1	0,466	0,565	0,00170	0,04	14,65	0,069
	Correlación	Maximizar I2	re0	0,388	0,624	812	0,048	9,322	0,1
			re1	0,48	0,491	633	0,049	14,791	0,147
		Maximizar H2	re0	0,407	0,636	0,00172	0,035	25,472	0,171
			re1	0,491	0,559	0,00153	0,041	37896	0,251

Tabla 2: Medidas de calidad de las soluciones de clustering con tantas agrupaciones como clases hay en la colección.

								Tiempo		
Algoritmo	**Función similitud**	**Función criterio**	**fichero**	**k**	**Entropía**	**Pureza**	**Valor de la función criterio**	**I/O**	**Clustering**	**Reporting**
rb	Coseno	Maximizar I2	re0	13	0,389	0,656	596	0,101	0,168	0,26
			re1	25	0,31	0,686	628	0,154	0,18	0,117
		Maximizar H2	re0	13	0,39	0,654	0,00225	0,035	0,139	0,046
			re1	25	0,312	0,687	0,00309	0,117	0,25	0,119
	Correlación	Maximizar I2	re0	13	0,393	0,66	850	0,045	4,727	0,115
			re1	25	0,392	0,638	774	0,102	17,467	0,255
		Maximizar H2	re0	13	0,404	0,644	0,00187	0,033	5,814	0,108
			re1	25	0,394	0,635	0,00230	0,039	11,562	0,238
agglo	Coseno	Maximizar I2	re0	13	0,443	0,577	579	0,114	0,475	0,036
			re1	25	0,348	0,631	606	0,107	0,576	0,131
		Maximizar H2	re0	13	0,449	0,578	0,00211	0,115	12,869	0,061
			re1	25	0,361	0,639	0,00292	0,125	18,367	0,244
	Correlación	Maximizar I2	re0	13	0,374	0,651	836	0,073	18,044	0,18
			re1	25	0,36	0,65	771	0,137	33,594	0,366
		Maximizar H2	re0	13	0,377	0,662	0,00183	0,078	21,424	0,114
			re1	25	0,378	0,619	0,00230	0,133	33,463	0,351

Figura 1: Entropía.

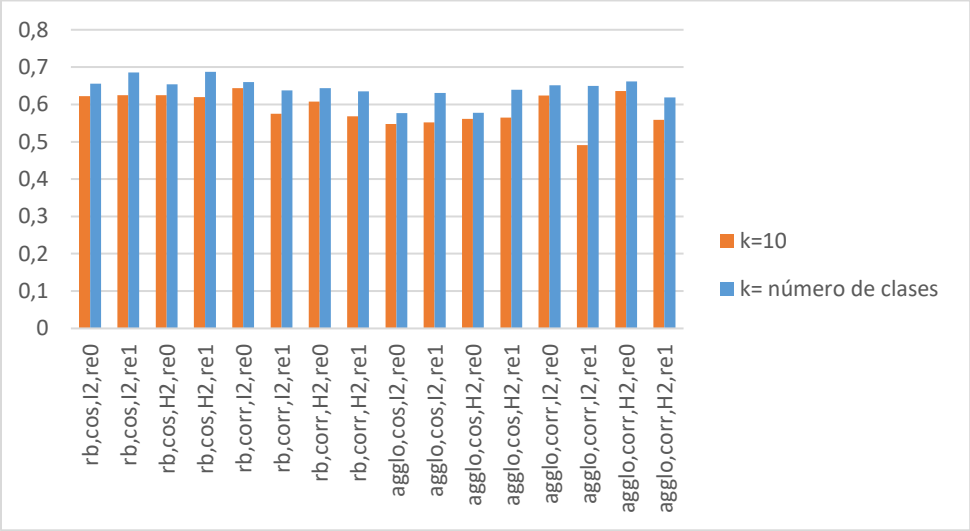

Figura 2: Pureza

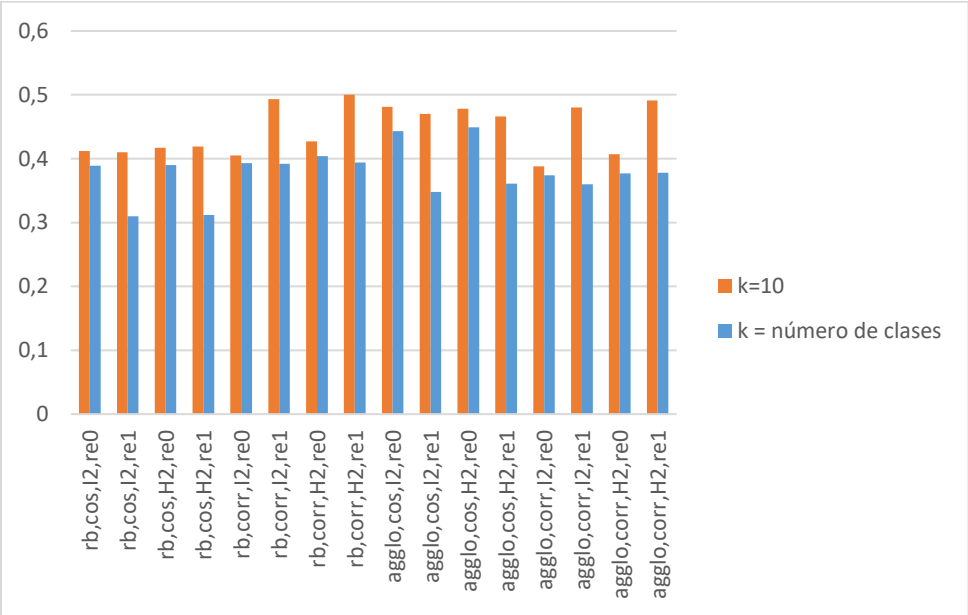

Figura 3: I2 (solo para soluciones donde se ha aplicado esta función de criterio)

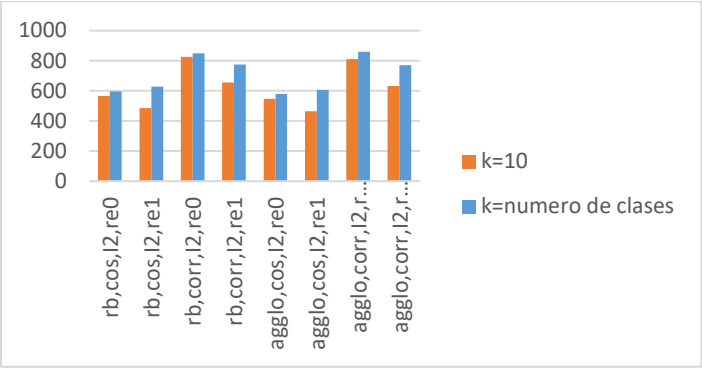

Figura 3: I2 (solo para soluciones donde se ha aplicado esta función de criterio)

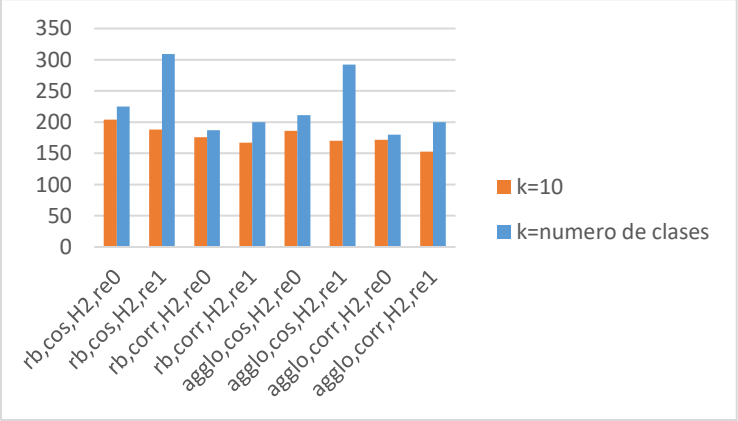

5. Análisis de los resultados

A continuación se indican algunas observaciones sobre el efecto que tienen cada una de las variables.

Número de agrupaciones

Los resultados son significativamente mejores cuando se aumentar el número de agrupaciones de manera que sea igual al número de clases *gold* mejora los resultados (véase la tabla 3). En el caso de la entropía y la pureza la mejora es de esperar, pues se definen a partir de las clases *gold*: si el número de agrupaciones seleccionado es menor o mayor, en la solución de *clustering* habrá necesariamente elementos que no estarán en la clase correcta. En el caso de los valores de la función criterio, la mejora es, de hecho, poco significativa; en algunos casos su valor incluso disminuye.

Tabla 3: Incremento de la medida de calidad al aplicar una solución con un número de agrupaciones k *igual al número de clases, en relación a utilizar k=10.*

Algoritmo	**Función similitud**	**Función criterio**	**fichero**	**Entropía**	**Pureza**	**Valor de la función criterio**
rb	Coseno	Maximizar I2	re0	5,91%	-5,18%	1,80%
			re1	32,26%	-8,89%	3,74%
		Maximizar H2	re0	6,92%	-4,43%	5,07%
			re1	34,29%	-9,75%	-1,61%
	Correlación	Maximizar I2	re0	3,05%	-2,42%	2,01%
			re1	25,77%	-9,87%	4,46%
		Maximizar H2	re0	5,69%	-5,59%	5,41%
			re1	26,90%	-10,55%	0,66%
agglo	Coseno	Maximizar I2	re0	8,58%	-5,03%	1,76%
			re1	35,06%	-12,52%	3,66%
		Maximizar H2	re0	6,46%	-2,94%	4,82%
			re1	29,09%	-11,58%	-1,87%
	Correlación	Maximizar I2	re0	3,74%	-4,15%	1,75%
			re1	33,33%	-24,46%	4,21%
		Maximizar H2	re0	7,96%	-3,93%	5,56%
			re1	29,89%	-9,69%	-0,04%

Algoritmo

El algoritmo de aglomeración tiende a dar mejores resultados, aunque con el coste de aumentar el tiempo de cálculo de la solución[3].

Función de similitud

El efecto de la función de similitud en la calidad de la solución no es fácil de determinar, ya que no se mantiene una relación constante. En la colección re1 el uso del coeficiente de correlación mejora significativamente los resultados respecto a la función coseno cuando se utiliza con el algoritmo RB; en cambio, los resultados cuando se utiliza esta función con el método aglomerativo en la colección re0 son de los peores.

Función criterio

En general, la función criterio maximizar H2 da mejores resultados, tanto en la entropía como en la pureza.

[3] Se ha observado que el tiempo de computación de una misma solución puede variar significativamente entre ejecución y ejecución, por causas ajenas al algoritmo, como puede observarse comparando los tiempos de I/O.

6. Bibliografía

[Zhao 2002] Zhao, Y. y Karypis, G. (2002). Criterion Functions for Document Clustering. Experiments and Analysis, http://glaros.dtc.umn.edu/gkhome/node/165

[Karypis 2003] Karypis, G. (2003). CLUTO. A Clustering Toolkit. Release 2.1.1. http://glaros.dtc.umn.edu/gkhome/fetch/sw/cluto/manual.pdf

[Wikipedia 2020] Wikipedia contributors (2020, April 22). *Pearson correlation coefficient*. En Wikipedia, The Free Encyclopedia. Consultado 00:45, 27 de abril de 2020, https://en.wikipedia.org/w/index.php?title=Pearson_correlation_coefficient&oldid=952416662