Máster en Tecnologías del Lenguaje
Descubrimiento de información en textos

Tarea del tema 5: Estudio de diferentes representaciones vectoriales

Ariadna Frutos Javierre
1 de abril de 2020

Contenidos

Contenidos 1
0. Introducción 2
1. Obtención de los textos 2
2. Limpieza 3
3. Tokenización 3
4. Normalización y eliminación de palabras vacías 4
5. Truncado 4
6. Generación de representaciones. Funciones de pesado 4
6.1 Vocabulario 4
6.2 Frecuencias 4
6.3 Funciones de pesado 5
Funciones locales 5
Funciones globales 5
7. Resultados 5
Vocabulario 6
Representaciones 6
8. Conclusiones 6
Bibliografía 8
Artículos de El País 8
Anexo 1: Stopwords 12

0. Introducción

En este trabajo se han creado distintas representaciones de un conjunto de documentos html en el modelo de espacio vectorial, utilizando distintas funciones de pesado. Para definir criterios claros para el tratamiento de los textos y la selección de rasgos se ha imaginado que el objetivo de las representaciones es la clasificación de textos en áreas temáticas. Los textos, publicados en la portada de El País digital del día 7 de marzo de 2020 [REFERENCIA], se presentan en la portada clasificados en categorías (excepto los primeros, que aparecen al principio de la portada por su relevancia). También contienen meta-etiquetas donde se informa de su categoría. El objetivo imaginado es clasificar los documentos de forma no supervisada, a partir de la coexistencia de términos, para ver si la clasificación obtenida coincide con la realizada por el periódico.

El análisis léxico o normalización se ha realizado en tres etapas:

1- Limpieza anterior a la *tokenización*
2- Selección de patrones durante la *tokenización*
3- Transformaciones posteriores a la *tokenización*: normalización, eliminación de palabras vacías y truncado.

Tras el análisis léxico, se ha creado el vocabulario y, a partir de este, las representaciones de cada documento en el espacio vectorial definido por él utilizando cinco funciones de pesado distintas, tres locales y dos globales.

El trabajo contiene ocho apartados. En el primero se describe el procedimiento seguido para obtener el texto plano a partir de los documentos html. En los apartados 2 a 5 se describen los procedimientos seguidos para realizar el análisis léxico: limpieza, *tokenización*, normalización y eliminación de palabras vacías, y truncado. En el apartado 6 se muestran los objetos generados para generar las representaciones y se presentan las funciones de pesado utilizadas. En el apartado 7 se informa de cómo consultar los ficheros resultantes (vocabulario, representaciones de los documentos y fichero inverso). Finalmente, en el apartado 8 se ofrece un pequeño análisis de los problemas encontrados y posibilidades de mejora, a modo de conclusión.

1. Obtención de los textos

Los textos se han descargado manualmente de la página web del periódico El País. En concreto, se han seleccionado los primeros 50 artículos que aparecían en la página principal (*Home*) del periódico el día 7 de marzo de 2020 a las 22:17 CET.

De los ficheros originales, en formato html complejo (con grandes apartados de código javascript y css), se ha extraído el contenido textual semánticamente relevante, cuya localización se ha obtenido tras analizar manualmente 3 ficheros del corpus. En concreto, se han extraído los textos de:

1. Las etiquetas `<meta>` cuyo atributo `name` es `description`, `keywords` o `news_keywords`. En concreto, se ha extraído el contenido del atributo `content`. Por ejemplo:

```
<meta name="description" content="El Gobierno de La Rioja pone en marcha “medidas
excepcionales” | Los casos de contagio de coronavirus en España son ya 477, de los
que 10 han fallecido" />
```

```
<meta name="news_keywords" content="Coronavirus, Coronavirus de Wuhan, Enfermedades respiratorias, Vitoria, La Rioja, Cuarentena, Haro, Guardia Civil" />
```

2. Las etiquetas `<meta>` cuyo atributo `property` es `article:tag`. Se ha extraído el contenido del atributo `content`. Por ejemplo:

```
<meta property="article:tag" content="Coronavirus" />
<meta property="article:tag" content="Coronavirus de Wuhan" />
```

3. Las etiquetas `<article>` y `<title>`. Se ha extraído el texto incluido entre las etiquetas de abertura (`< >`) y cierre (`</ >`), excluyendo los comentarios y el texto situado entre etiquetas hijas del tipo `input`, `script`, `noscript` y `style`. Por ejemplo:

```
<title>La Guardia Civil vigila Haro para mantener aislados a los afectados por coronavirus del funeral de Vitoria | Sociedad | EL PAÍS</title>

<article class="flex_grid background_white">
    <header class="col desktop_12 tablet_8 mobile_4">
        <div class="article-header basic | " id="article_header"><a class="kicker | flex align_items_center uppercase color_blue" href="https://elpais.com/noticias/ncov/"><span>Coronavirus de Wuhan</span><svg class="icon_comments_next | margin_left" viewBox="0 0 17 30"><path d="M1.864 0L.02 2.07 12.937 15 .019 27.93 1.864 30l15-15z"></path></svg></a>
             <h1 class="font_secondary color_gray_ultra_dark ">La Guardia Civil vigila Haro para mantener aislados a los afectados por coronavirus del funeral de Vitoria</h1>
             <h2 class="font_secondary color_gray_dark ">El Gobierno de La Rioja pone en marcha “medidas excepcionales” | Los casos de contagio de coronavirus en España son ya 477, de los que 10 han fallecido</h2></div>

...


</article>
```

2. Limpieza

La limpieza anterior a la *tokenización* ha consistido en:

1- La eliminación de cifras en formato aislado (ej: 2; 30,2; 15.697,25 ...)
2- La eliminación de fechas en formato comprimido (números separados por “/”, “-“ o “.”. Ej: 30/01/2020, 30.01.2020, 30-01-2020)
3- La sustitución de *emojis* por su nombre, precedido de “:” para su posterior identificación. Para ello se ha utilizado el módulo `emoji`[1].

3. Tokenización

La *tokenización* consiste en transformar el texto inicial en una lista de palabras o *tokens* (pueden ser palabras o símbolos). Para ello se ha utilizado la función `regexp_tokenize` de la librería NLTK, que permite definir, mediante expresiones regulares, los patrones que se aceptarán para formar un

[1] Este módulo proporciona los nombres en inglés. No ha sido posible realizar la traducción ni el tratamiento posterior de estos textos, por lo que en el contexto de este trabajo los emojis serán tokens independientes. En un trabajo con finalidades prácticas reales deberíamos plantearnos traducirlos e identificarlos con el vocabulario general.

único *token*. Todos los elementos de la cadena analizada que no cumplen ningún patrón son descartados. Los patrones aceptados han sido:

- Cadenas de palabras y números, con guion interior opcional: `[\w\d]+(?:-[\w\d]+)*`. Se ha decidido aceptar números dentro de las cadenas para identificar palabras como "b2b", "4YFN" o "covid-19". Recuérdese que las cifras aisladas y las fechas en formato comprimido se han eliminado previamente.
- Abreviaciones tipo "U.S.A." : `(?:[A-Z]\.)+`
- Palabras precedidas de : (emojis): `(?::\w+)(?:_\w+)*`

4. Normalización y eliminación de palabras vacías

La normalización ha consistido en transformar los *tokens* en formas que permitieran la identificación de *tokens* iguales con diferencias tipográficas irrelevantes. En concreto se ha:

- Convertido las mayúsculas a minúsculas.
- Eliminado los puntos interiores (recuérdese que se habían aceptado para patrones tipo "U.S.A")

Tras esta transformación, se han eliminado las palabras vacías (*stopwords*). Para ello se ha utilizado la lista incluida en el módulo corpus.stopwords de la librería NLTK (véase Anexo 1).

5. Truncado

El truncado consiste en eliminar la terminación morfológica de los *tokens*, que no tiene significado semántico. Para ello se ha utilizado el algoritmo `SnowballStemmer`, también conocido como "algoritmo de Porter", en su versión en español [Spanish stemmer].

6. Generación de representaciones. Funciones de pesado

6.1 Vocabulario

Una vez procesados los textos del corpus se han juntado todas las listas de términos obtenidos tras el truncado y se ha generado una nueva lista con términos únicos, ordenados alfabéticamente. Esta lista constituye el vocabulario. Cada posición de la lista representará, en el espacio vectorial de los documentos, la coordenada correspondiente al término que ocupa esa posición.

6.2 Frecuencias

A partir del vocabulario se han generado los siguientes objetos, cuyos valores se requerirán en el cálculo de las funciones de pesado:

- **Frecuencias absolutas**: Diccionario con los *tokens* del vocabulario y la frecuencia con que se dan en el corpus.
- **Documentos con *tokens***: Diccionario con los *tokens* del vocabulario y el número de documentos del corpus en que aparecen.
- **Matriz del corpus**: Lista de diccionarios, uno para cada documento del corpus, con los *tokens* del vocabulario que aparecen en el documento y el número de veces que se dan. Se ha utilizado

el formato lista de diccionarios, en vez de lista de listas, para ahorrar la memoria necesaria para guardar los valores nulos de los *tokens* que no se dan en el documento.
A partir de esta matriz se ha generado también el **fichero invertido** requerido en la tarea. Se trata de un fichero de texto en el que se indican las frecuencias de *cada* token del vocabulario en cada documento del corpus en el siguiente formato:

term_1 --> doc1:FT1,1 doc2:FT1,2 doc3:FT1,3 ... doc10:FT1,10
term_2 --> doc1:FT2,1 doc2:FT2,2 doc3:FT2,3 ... doc10:FT2,10

donde "term_1" indica el primer término del vocabulario, "doc1" el primer documento del corpus, "FT1,1" el número de veces que aparece el primer término en el primer documento, etc.

6.3 Funciones de pesado

Finalmente se han generado 5 representaciones vectoriales para cada documento, utilizando distintas funciones de pesado[2], 3 locales y 2 globales

Funciones locales

- **Binaria**: $\mathrm{Bin}(\overrightarrow{t_i}, \overrightarrow{d_j}) = \begin{cases} 1 & \text{si el rasgo } t_i \text{ aparece en el documento } d_i \\ 0 & \text{si no aparece} \end{cases}$
- **Term Frequency**: $\mathrm{TF}(\overrightarrow{t_i}, \overrightarrow{d_j}) = f_{ij}$,
  donde f_{ij} es la frecuencia del rasgo t_i en el documento d_j
- **Weigthed Term Frequency:** $\mathrm{WTF}(\overrightarrow{t_i}, \overrightarrow{d_j}) = \frac{f_{ij}}{\sum_{t_p \in d_j} f_{pj}}$

  Es decir, se trata de la frecuencia f_{ij} normalizada según el número de términos que contiene el documento j.

Funciones globales

- **Frecuencia Inversa del Documento**: $\mathrm{BinIDF}(\overrightarrow{t_i}, \overrightarrow{d_j}) = \begin{cases} 1 + log\left(\frac{N}{df(\overrightarrow{t_i})}\right) & \text{si } f_{ij} \neq 0 \\ 0 & \text{si } f_{ij} = 0 \end{cases}$,

  donde $df(\overrightarrow{t_i})$ es el número de documentos del corpus en los que aparece el rasgo t_i y N la dimensión del corpus (número de términos del vocabulario)
- **Frecuencia del término x Frecuencia inversa de documento**: $\text{TF-IDF}(\overrightarrow{t_i}, \overrightarrow{d_j}) = f_{ij} \times \log \frac{N}{df(\overrightarrow{t_i})}$

7. Resultados

Tras la ejecución del programa, se han generado los siguientes ficheros de texto[3].

---

[2] En el enunciado del ejercicio se pide utilizar únicamente 2 funciones de pesado, una local y una global. He utilizado más funciones por interés personal. Para la evaluación del ejercicio, tómense las representaciones que se consideren oportunas.
[3] Los ficheros mencionados se encuentran en la carpeta "output", incluida en la carpeta comprimida en que se encuentra este documento.

Vocabulario

Se trata de un único fichero, `vocabulario.txt`, con los términos del corpus obtenidos tras el proceso de limpieza, *tokenización*, normalización, truncado y ordenación alfabética, escritos en una sola línea y separados por espacios. Cada término representa una dimensión del espacio vectorial en que se han representado los documentos. El número total de términos del vocabulario, es decir, la dimensión del espacio vectorial de documentos, es 4849.

Representaciones

Las representaciones de los documentos se incluyen en subcarpetas, una para cada función de pesado. Cada carpeta contiene 50 ficheros de texto, uno para cada documento del corpus. Los ficheros consisten en una fila 4849 números, que son las componentes del vector representación del documento para la función de pesado correspondiente. Las carpetas son:

- **bin:** Incluye 50 ficheros, uno para cada documento, con el vector representación del documento aplicando la función de pesado binaria. Los valores son, por la definición de esta función, siempre cero o uno.
- **tf:** Incluye 50 ficheros, uno para cada documento, con el vector representación del documento aplicando la función de pesado *Term Frequency*. Los valores son, por la definición de esta función, números enteros positivos.
- **wtf:** Incluye 50 ficheros, uno para cada documento, con el vector representación del documento aplicando la función de pesado *Weighted Term Frequency*. Los valores son, por la definición de esta función, números decimales entre cero y uno.
- **bin_idf:** Incluye 50 ficheros, uno para cada documento, con el vector representación del documento aplicando la función de pesado *Frecuencia Inversa del Documento*. En este caso los valores son números decimales positivos.
- **tf_idf:** Incluye 50 ficheros, uno para cada documento, con el vector representación del documento aplicando la función de pesado *Frecuencia del término x Frecuencia Inversa del Documento*. De nuevo, los valores son números decimales positivos.

Fichero invertido

El fichero invertido es un fichero de texto, `fichero_invertido.txt`, con los términos del vocabulario y las frecuencias en que aparecen en cada documento del corpus. Cada fila corresponde a un término del vocabulario, según el formato descrito en el apartado 6.2. Es decir, en la primera fila:

```
aaron -> doc_0:0 doc_1:0 doc_2:0  ...   doc_26:2  ...   doc_48:0 doc_49:0
```

se lee que la palabra “aaron” aparece cero veces en los documentos 0, 1, 2 y 2 veces en el documento 26. Nótese que la numeración de los documentos empieza en cero, de manera que el último documento es el 49.

8. Conclusiones

La generación de representaciones vectoriales de documentos es una operación relativamente sencilla a nivel de algoritmo, pero la obtención de representaciones fiables que sirvan aplicaciones

concretas conlleva dificultades a varios niveles. Este tipo de dificultades pueden clasificarse en dos tipos: a nivel de texto y a nivel de computación.

A nivel de texto, el primer problema radica en el tratamiento de ficheros complejos. Si la fuente son páginas web, este problema se traduce en la obtención del texto semánticamente relevante a partir de la estructura html, que no siempre es la misma. Aquí hemos basado la extracción de texto en el análisis de la estructura html de 3 documentos del corpus. Al aplicar el algoritmo se ha visto que este análisis no era suficiente, ya que en algunos de los documentos no contenían la etiqueta `<article>`, sino que el texto del cuerpo de la página se encontraba en otro sitio. En estos casos, el algoritmo solo ha incluido el texto entre etiquetas `<title>` y en los meta-tags.

En segundo lugar, una vez se tiene el texto plano, el problema es la selección de rasgos y la normalización. Obtener un vocabulario óptimo no es una tarea sencilla. Probablemente, para la aplicación que se ha imaginado, categorizar los artículos, se podría ampliar la bolsa de palabras vacías a descartar. También podría realizarse una limpieza más exhaustiva, para detectar faltas ortográficas u otras variantes de un mismo *token*. También podría valorarse la opción de realizar una lematización en lugar de un truncado, para aumentar la precisión semántica de los tokens.

A nivel computacional, el problema radica, sobre todo, en el gran tamaño del vocabulario, que aumenta exponencialmente el número de operaciones a realizar a la hora de realizar las distintas operaciones necesarias para obtener las representaciones. El corpus inicial contenía 103 documentos, que hemos tenido que reducir a 50 porque la generación de representaciones a partir del vocabulario generado por los 103 documentos era demasiado lenta, incluso utilizando diccionarios en vez de listas allí donde ha sido posible. La reducción del vocabulario mediante una mejor selección de rasgos, como se ha propuesto más arriba, no solo mejoraría la especificidad de las representaciones, sino también la eficiencia computacional.

Bibliografía

[Spanish stemmer] *Spanish stemming algorithm*, http://snowball.tartarus.org/algorithms/spanish/stemmer.html

Artículos de El País

[El País 1] Andrea Rizzi (2020). *Comparando a Sanders con la socialdemocracia europea: objetivos parecidos, medidas más radicales | Internacional | EL PAÍS*, https://elpais.com/internacional/2020-03-06/comparando-a-sanders-con-la-socialdemocracia-europea-objetivos-parecidos-medidas-mas-radicales.html

[El País 2] Ángeles Espinosa (2020). *Dos destacados príncipes saudíes detenidos y acusados de traición | Internacional | EL PAÍS*, https://elpais.com/internacional/2020-03-07/dos-destacados-principes-saudies-detenidos-y-acusados-de-traicion.html

[El País 3] Begoña Gómez Urzaiz (2020). *Entrevista: Jia Tolentino: "La autosatisfacción debería hacer sonar las alarmas en el feminismo" | EL PAÍS Semanal*, https://elpais.com/elpais/2020/03/03/eps/1583252144_799284.html

[El País 4] Ediciones El País (2020). *Radiografía de los cuidados en España: femeninos y no remunerados | Verne EL PAÍS*, https://verne.elpais.com/verne/2020/03/06/articulo/1583506436_281565.html

[El País 5] Ediciones El País (2020). *Los cinco libros de la semana | Babelia | EL PAÍS*, https://elpais.com/cultura/2020/03/06/babelia/1583507809_936162.html

[El País 6] Ediciones El País (2020). *Vídeo: 'Un violador en tu camino', el himno feminista global, suena en la Plaza Mayor de Madrid | Verne EL PAÍS*, https://verne.elpais.com/verne/2020/03/07/articulo/1583594749_227509.html

[El País 7] Ediciones EL PAÍS (2020). *Newsletter qué se sabe hoy del coronavirus | EL PAÍS*, https://plus.elpais.com/newsletters/lnp/1/387

[El País 8] Ediciones EL PAÍS (2020). *Artículos escritos por Fernando Savater | EL PAÍS*, https://elpais.com/autor/fernando_savater/a

[El País 9] Ediciones EL PAÍS (2020). *Artículos escritos por Ana Fuentes | EL PAÍS*, https://elpais.com/autor/ana_fuentes_fernandez/a

[El País 10] EFE (2020). *El Liverpool sufre ante el Bournemouth, en descenso, antes de recibir al Atlético | Deportes | EL PAÍS*, https://elpais.com/deportes/2020-03-07/el-liverpool-sufre-ante-el-bournemouth-en-descenso-antes-de-recibir-al-atletico.html

[El País 11] El País (2020). *Gobierno de coalición: Tejer y destejer | Opinión | EL PAÍS*, https://elpais.com/elpais/2020/03/06/opinion/1583518511_068685.html

[El País 12] El País (2020). *Fotos: Atlético Madrid - Sevilla, la Liga Santander en imágenes | Deportes | EL PAÍS*, https://elpais.com/elpais/2020/03/07/album/1583592156_000800.html

[El País 13] El País (2020). *Día de la Mujer: horarios y recorridos de las marchas del 8M | Día de la Mujer | EL PAÍS*, https://elpais.com/sociedad/2020-03-07/dia-de-la-mujer-horarios-y-recorridos-de-las-marchas-del-8m.html

[El País 14] El País (2020). *El feminismo convoca en las calles de nuevo: preguntas y respuestas sobre este 8-M | Día de la Mujer | EL PAÍS*, https://elpais.com/sociedad/2020-03-06/el-feminismo-convoca-en-las-calles-de-nuevo-preguntas-y-respuestas-sobre-este-8m.html

[El País 15] Elsa García de Blas (2020). *Ciudadanos elige entre continuidad o ruptura con Rivera | España | EL PAÍS*, https://elpais.com/espana/2020-03-06/ciudadanos-elige-entre-continuidad-o-ruptura-con-rivera.html

[El País 16] ICON, Óscar Tévez (2020). *La modelo Gigi Hadid cocina paella y le da una lección de cómo enfadar a un español a Jamie Oliver | ICON | EL PAÍS*, https://elpais.com/elpais/2020/03/06/icon/1583499171_117399.html

[El País 17] Jacinto Antón (2020). *Viaje al interior del cuerpo humano con Bill Bryson | Babelia | EL PAÍS*, https://elpais.com/cultura/2020/03/06/babelia/1583509569_055792.html

[El País 18] Javier Martín-Arroyo (2020). *El limbo legal de los menores inmigrantes que se hacen adultos | España | EL PAÍS*, https://elpais.com/espana/2020-03-06/el-limbo-legal-de-los-menores-inmigrantes-que-se-hacen-adultos.html

[El País 19] Jon Rivas (2020). *El Mallorca mete en apuros al Eibar | Deportes | EL PAÍS*, https://elpais.com

[El País 20] Juan Morenilla (2020). *Alarma por Tiger: la espalda le tumba a un mes del Masters | Deportes | EL PAÍS*, https://elpais.com/deportes/2020-03-07/alarma-por-tiger-la-espalda-le-tumba-a-un-mes-del-masters.html

[El País 21] Juan Navarro, El País (2020). *La Guardia Civil vigila Haro para mantener aislados a los afectados por coronavirus del funeral de Vitoria | Sociedad | EL PAÍS*, https://elpais.com/sociedad/2020-03-07/cuarentena-en-varias-zonas-de-la-rioja-tras-contagio-por-coronavirus-en-un-funeral-en-vitoria.html

[El País 22] Julio Llamazares (2020). *Los cementerios de Luxemburgo | Opinión | EL PAÍS*, https://elpais.com/elpais/2020/03/06/opinion/1583516300_432706.html

[El País 23] Leontxo García (2020). *El español que se enfrentó a Bobby Fischer | Babelia | EL PAÍS*, https://elpais.com/cultura/2020/03/06/babelia/1583493877_990755.html

[El País 24] María Martín (2020). *El Gobierno facilitará el permiso de trabajo a los menores migrantes | España | EL PAÍS*, https://elpais.com/espana/2020-03-06/el-gobierno-facilitara-el-permiso-de-trabajo-a-los-menores-migrantes.html

[El País 25] Montserrat Domínguez (2020). *Podcast | Moda, política y feminismo | EL PAÍS Semanal*, https://elpais.com/elpais/2020/03/06/eps/1583496410_649922.html

[El País 26] Peridis (2020). *Peridis | Opinión | EL PAÍS*, https://elpais.com/elpais/2020/03/06/opinion/1583510581_364241.html

[El País 27] Reuters, El País (2020). *El misterio del MH370 se mantiene seis años después de la tragedia | Internacional | EL PAÍS*, https://elpais.com/internacional/2020-03-07/el-misterio-del-mh370-se-mantiene-seis-anos-despues-de-la-tragedia.html

[El País 28] (2020). *¿Han descubierto la pólvora? La peculiar treta de la Real para parar una falta de Messi - AS.com*, https://as.com/futbol/2020/03/07/videos/1583607147_414471.html

[El País 29] El País (2020). *EL PAÍS lanza su suscripción digital | Modelo de suscripción | EL PAÍS*, https://elpais.com/sociedad/modelo-de-suscripcion/2020-02-29/el-pais-lanza-su-suscripcion-digital.html

[El País 30] Rafa de Miguel (2020). *El Reino Unido ha gastado ya más de 4.600 millones de euros para preparar el Brexit | Internacional | EL PAÍS*, https://elpais.com/internacional/2020-03-06/el-reino-unido-ha-gastado-ya-mas-de-4600-millones-de-euros-para-preparar-el-brexit.html

[El País 31] Ladislao J. Moñino (2020). *El Sevilla doma al Atlético | Deportes | EL PAÍS*, https://elpais.com/deportes/2020-03-07/el-sevilla-doma-al-atletico.html

[El País 32] Ramon Besa (2020). *El VAR salva a un deprimente Barça | Deportes | EL PAÍS*, https://elpais.com/deportes/2020-03-07/el-var-salva-a-un-deprimente-barca.html

[El País 33] Bernardo Marín (2020). *Hacer las cosas de otra manera | Modelo de suscripción | EL PAÍS*, https://elpais.com/sociedad/modelo-de-suscripcion/2020-03-07/hacer-las-cosas-de-otra-manera.html

[El País 34] Carlos Marcos (2020). *Isabel Pantoja las pasa canutas, se recompone y deja extenuada a su gente con un concierto de tres horas | Cultura | EL PAÍS*, https://elpais.com/cultura/2020-03-07/isabel-pantoja-las-pasa-canutas-se-recompone-y-deja-extenuada-a-su-gente-con-un-concierto-de-tres-horas.html

[El País 35] Lorena Pacho (2020). *Italia se prepara para aislar a 16 millones de personas en el norte del país por el coronavirus | Sociedad | EL PAÍS*, https://elpais.com/sociedad/2020-03-07/italia-se-prepara-para-aislar-a-16-millones-de-personas-en-el-norte-del-pais-por-el-coronavirus.html

[El País 36] Sandra López Letón (2020). *Los nuevos fraudes en el alquiler de viviendas | Negocios | EL PAÍS*, https://elpais.com/economia/negocio/2020-03-06/los-nuevos-fraudes-en-el-alquiler-de-viviendas.html

[El País 37] Pedro del Rosal (2020). *Los verdaderos motivos del fichaje de Albert Rivera por Martínez-Echevarría | Negocios | EL PAÍS*, https://elpais.com/economia/negocio/2020-03-06/los-verdaderos-motivos-del-fichaje-de-albert-rivera-por-martinez-echevarria.html

[El País 38] Oriol Güell (2020). *Un funeral en Vitoria causó más de 60 infectados | Sociedad | EL PAÍS*, https://elpais.com/sociedad/2020-03-06/mas-de-60-personas-se-contagiaron-a-la-vez-en-un-funeral-en-vitoria.html

[El País 39] Boris Izaguirre (2020). *No hay 'filin' | Gente | EL PAÍS*, https://elpais.com/gente/2020-03-06/no-hay-filin.html

[El País 40] Pedro Gorospe (2020). *Pablo Casado: "Bildu y el PNV ya le han extendido el talón de cobro a Sánchez" | España | EL PAÍS*, https://elpais.com/espana/2020-03-07/pablo-casado-bildu-y-el-pnv-ya-le-han-extendido-el-talon-de-cobro-a-sanchez.html

[El País 41] El País (2020). *‘Podcast’ | Soledad Gallego-Díaz habla sobre el cambio de modelo en EL PAÍS hacia las suscripciones digitales | Modelo de suscripción | EL PAÍS*, https://elpais.com/sociedad/modelo-de-suscripcion/2020-02-29/soledad-gallego-diaz-habla-sobre-el-cambio-de-modelo-en-el-pais-hacia-las-suscripciones-digitales.html

[El País 42] Jessica Mouzo (2020). *¿Tengo coronavirus? La guía de Sanidad para detectar casos sospechosos y cómo proceder ante ellos | Sociedad | EL PAÍS*, https://elpais.com/sociedad/2020-03-06/tengo-coronavirus-la-guia-de-sanidad-para-detectar-casos-sospechosos-y-como-proceder-ante-ellos.html

[El País 43] Pablo Guimón (2020). *Trump cambia a su jefe de Gabinete a ocho meses de las elecciones | Internacional | EL PAÍS*, https://elpais.com/internacional/2020-03-07/trump-cambia-a-su-jefe-de-gabinete-a-ocho-meses-de-las-elecciones.html

[El País 44] Pablo Guimón (2020). *Trump recibe hoy al brasileño Bolsonaro en Florida | Internacional | EL PAÍS*, https://elpais.com/internacional/2020-03-07/trump-recibe-al-brasileno-bolsonaro-este-sabado-en-florida.html

[El País 45] El País (2020). *Noticias del coronavirus, en directo | España supera los 500 contagiados y suma 10 muertos | Sociedad | EL PAÍS*, https://elpais.com/sociedad/2020-03-06/ultimas-noticias-del-coronavirus-en-directo.html

[El País 46] El País (2020). *Vídeo | Periodismo que se ve, se cuenta y se diseña | Modelo de suscripción | EL PAÍS*, https://elpais.com/sociedad/modelo-de-suscripcion/2020-03-07/video-periodismo-que-se-ve-se-cuenta-se-disena-y-se-dibuja.html

[El País 47] Jorge Valdano (2020). *Jorge Valdano: Vinicius contra la decadencia | Deportes | EL PAÍS*, https://elpais.com/deportes/2020-03-06/vinicius-contra-la-decadencia.html

[El País 48] Miguel González (2020). *Vox, el patriotismo más rentable | España | EL PAÍS*, https://elpais.com/espana/2020-03-06/vox-el-patriotismo-mas-rentable.html

[El País 49] Miguel González (2020). *Vox reelige a Abascal sin votación en una asamblea cerrada a los críticos | España | EL PAÍS*, https://elpais.com/espana/2020-03-07/vox-reelige-a-abascal-sin-votacion-en-una-asamblea-cerrada-a-los-criticos.html

[El País 50] (2020). *Ampollas en los pies y hambre: la cara B de los desfiles de moda | Actualidad | S Moda EL PAÍS*, https://smoda.elpais.com/moda/actualidad/ampollas-en-los-pies-y-hambre-la-cara-b-de-los-desfiles-de-moda/

Anexo 1: Stopwords

a
al
algo
algunas
algunos
ante
antes
como
con
contra
cual
cuando
de
del
desde
donde
durante
e
el
él
ella
ellas
ellos
en
entre
era
erais
éramos
eran
eras
eres
es
esa
esas
ese
eso
esos
esta
está
estaba
estabais
estábamos
estaban
estabas
estad
estada
estadas
estado
estados
estáis
estamos
están
estando
estar
estará
estarán
estarás
estaré
estaréis
estaremos
estaría
estaríais
estaríamos
estarían
estarías
estas
estás
este
esté
estéis
estemos
estén
estés
esto
estos
estoy
estuve
estuviera
estuvierais
estuviéramos
estuvieran
estuvieras
estuvieron
estuviese
estuvieseis
estuviésemos
estuviesen
estuvieses
estuvimos
estuviste
estuvisteis
estuvo
fue
fuera
fuerais
fuéramos
fueran
fueras
fueron
fuese
fueseis
fuésemos
fuesen
fueses
fui
fuimos
fuiste
fuisteis
ha
habéis
había
habíais
habíamos
habían
habías
habida
habidas
habido
habidos
habiendo
habrá
habrán
habrás
habré
habréis
habremos
habría
habríais
habríamos
habrían
habrías
han
has
hasta
hay
haya
hayáis
hayamos
hayan
hayas
he
hemos
hube
hubiera
hubierais
hubiéramos
hubieran
hubieras
hubieron
hubiese
hubieseis
hubiésemos
hubiesen
hubieses
hubimos
hubiste
hubisteis
hubo
la
las
le
les
lo
los
más
me
mi
mí
mía
mías
mío
míos
mis
mucho
muchos
muy
nada
ni
no
nos
nosotras
nosotros
nuestra
nuestras
nuestro
nuestros
o
os
otra
otras
otro
otros
para
pero
poco
por
porque
que
qué
quien
quienes
se
sea
seáis
seamos
sean
seas
sentid
sentida
sentidas
sentido
sentidos
será
serán
serás

seré
seréis
seremos
sería
seríais
seríamos
serían
serías
sí
siente
sin
sintiendo
sobre
sois
somos
son
soy
su
sus
suya
suyas
suyo
suyos
también
tanto
te
tendrá
tendrán
tendrás
tendré
tendréis
tendremos
tendría
tendríais
tendríamos
tendrían
tendrías
tened
tenéis
tenemos
tenga
tengáis
tengamos
tengan
tengas
tengo
tenía
teníais
teníamos
tenían
tenías
tenida
tenidas
tenido
tenidos
teniendo
ti
tiene
tienen
tienes
todo
todos
tu
tú
tus
tuve
tuviera
tuvierais
tuviéramos
tuvieran
tuvieras
tuvieron
tuviese
tuvieseis
tuviésemos
tuviesen
tuvieses
tuvimos
tuviste
tuvisteis
tuvo
tuya
tuyas
tuyo
tuyos
un
una
uno
unos
vosostras
vosostros
vuestra
vuestras
vuestro
vuestros
y
ya
yo