Procesamiento del Lenguaje Natural

Proyecto 2018-2019 Estimación de similitud de textos

Parte 1
Aproximaciones seguidas y resultados obtenidos

Ariadna Frutos Javierre
8 de mayo de 2018

INTRODUCCIÓN

En este proyecto se han implementado varios algoritmos destinados a estimar la similitud semántica entre pares de frases combinando distintos métodos descritos en la literatura, así como algunas de las herramientas disponibles en la librería NLTK. En los apartados siguientes se describen las aproximaciones seguidas y se proporcionan los resultados obtenidos para su estudio comparativo con el trabajo realizado por otros compañeros. Se prevé redactar una nueva versión del texto con un análisis cualitativo de las aproximaciones tomadas y los resultados, incluyendo una evaluación comparativa con los métodos y resultados conseguidos por los compañeros.

El texto se divide en 5 apartados. En el primero se describe el corpus de referencia utilizado para realizar la evaluación de la tarea. En el segundo se describe el preprocesamiento realizado. En el tercer apartado se detallan los métodos aplicados para tratar la similitud de palabras a nivel léxico, para después aplicarlos en el cuarto apartado, donde se realizan los cálculos finales a nivel de frase. Finalmente, en el apartado cinco se presentan los resultados obtenidos. En este documento se incluyen solamente los resultados finales. Los interesados pueden consultar los datos en que se basan estos resultados en la carpeta https://bit.ly/2Lv49gs.

1 CORPUS

Para la evaluación de los algoritmos se ha tomado como referencia el subconjunto *train* de la colección *STSbenchmark* (Diab, Cer, Specia, Agirre, & López-Gazpio, 2017)[1], que consiste en 5749 pares de frases en lengua inglesa cuya similitud semántica ha sido anotada por humanos con puntuaciones del 0 al 5 según los siguientes criterios:

PUNTUACIÓN 5: Si las dos frases son totalmente equivalentes.
PUNTUACIÓN 4: Si las dos frases son casi equivalentes, pero difieren en algunos detalles de poca importancia.
PUNTUACIÓN 3: Si las dos frases son aproximadamente equivalentes, pero difieren en alguna información importante.
PUNTUACIÓN 2: Si las dos frases no son equivalentes, pero comparten información.

[1] De hecho se hubiera podido utilizar todo el corpus, que contiene tres subconjuntos (*train*, *development* y *test*), ya que nuestra aproximación no consiste en un entrenamiento, sino solo en una evaluación. Sin embargo, se ha preferido no incrementar el conjunto de referencia para no ralentizar excesivamente los procesos de cálculo.

PUNTUACIÓN 1: Si las dos frases no son equivalentes, pero tratan del mismo tema.
PUNTUACIÓN 0: Si las dos frases son totalmente diferentes.

Las puntuaciones de la colección de referencia (*gold score*) son números decimales porque se ha aplicado una media entre la puntuación asignada por distintos evaluadores. Las frases de la colección proceden de distintos corpus e incluyen tres tipos de género: leyendas de imágenes, noticias y comentarios en foros. Pueden consultarse algunos ejemplos de pares de frases evaluadas de los distintos géneros en la tabla 1.

row	genre	file	year	id	gold_score	sent1	sent2
0	main-captions	MSRvid	2012test	1	5	A plane is taking off.	An air plane is taking off.
4737	main-news	headlines	2014	##	5	Philippines, rebels reach wealth-sharing deal	Philippines and rebels reach 'wealth deal'
2006	main-forum	deft-forum	2014	6	5	I am OK with MEDICAL use!	I AM OK WITH MEDICAL USE!!
1209	main-captions	images	2014	##	4	A train is running on the tracks.	A train is running down the track in a rural area.
2936	main-news	MSRpar	2012test	##	4	University of Michigan President Mary Sue Coleman said in a statement on the university's Web site, "Our fundamental values haven't changed.	"Our fundamental values haven't changed," Mary Sue Coleman, president of the university, said in a statement in Ann Arbor.
2013	main-forum	deft-forum	2014	13	4	We in Britain think differently to Americans.	Originally Posted by zaf We in Britain think differently to Americans.
151	main-captions	MSRvid	2012test	##	3	A man is cutting a fish.	A man guts a fish.
2000	main-forum	deft-forum	2014	0	3	How about some testimonies from real health experts?	Also, who's to say there aren't testimonies from "real" health experts on there?
2484	main-news	MSRpar	2012test	57	3	Coupling, an American version of a hit British comedy, will get the valuable Thursday 9:30 p.m. time slot.	Coupling, an American version of a hit British comedy, will couple with Friends on Thursdays.
5138	main-news	headlines	2015	##	2	Ukraine: Nine people die in Kyiv clashes	Ukraine pressured over Kiev clashes
2007	main-forum	deft-forum	2014	7	2	The prices for everything you need have gone up due to inflation.	The prices of everything you own IE assets have gone down.
1759	main-captions	images	2015	##	1	Three dogs in the snow by a fence.	Two dogs drink water in a lake.
2786	main-news	MSRpar	2012test	##	1	The S&P/TSX composite rose 87.74 points on the week, while the TSX Venture Exchange composite gained 44.49 points.	On the week, the Dow Jones industrial average rose 11.56 points, while the Nasdaq Stock Market gained 39.42 points.
2435	main-forum	deft-forum	2014	##	1	runs victim down Got any proof?	paranoid Got any proof?
201	main-captions	MSRvid	2012test	##	0	Someone is slicing tortila's.	Someone is riding a horse.
4287	main-news	headlines	2013	##	0	20-member parliamentary, trade team leaves for India	Commerce secretary to take leave of absence
2114	main-forum	deft-forum	2014	114	0	Originally Posted by anabelle What's wrong with that?	Originally Posted by Vienna To 'say' what?

TABLA 1: Ejemplos representativos de pares de frases extraídos del subconjunto train the STSBenchmark, utilizado en el proyecto. La columna "row" ha sido añadida por nosotros al importar los datos.

2. PREPROCESAMIENTO

2.1 Limpieza y análisis del corpus

Como primer paso en el procesamiento de los datos se ha realizado la eliminación de pares duplicados. Tras la eliminación esta limpieza, número de pares del corpus de referencia es de 5706, clasificados según indica la tabla 2 [2].

genre	file	id
main-captions	MSRvid	992
	Images	999
	SUBTOTAL	1991
main-forum	deft-forum	423
	SUBTOTAL	423
main-news	MSRpar	1000
	deft-news	299
	headlines	1993
	SUBTOTAL	3292

TABLA 2: Datos de la colección de referencia, un a vez eliminados los duplicados, clasificados por género

2.2 Preprocesamiento de los textos

El pre-procesamiento de los textos se ha realizado en varias fases:

FASE 1: Anterior a la generación de *tokens*:

1. Expansión de contracciones (*I'll* → *I will*, etc.)

FASE 2: Durante la generación de *tokens*:

2. Tratamiento de las abreviaturas (aceptación de siglas tipo U.S.A. como un único *token*)
3. Tratamiento de palabras compuestas (aceptación de palabras tipo *close-up* como un único *token*)
4. Unión de símbolos de moneda a números (por ejemplo, €50)

FASE 3: Posterior a la generación de *tokens* y anterior a la asignación de *synsets* (véase el siguiente apartado):

5. Conversión de todas las letras a minúscula.
6. Asignación de categorías gramaticales.

FASE 4: Posterior a la asignación de *synsets*:

[2] Los duplicados de frases en una única columna no se han eliminado, pero existen. El número de valores nicos de la columna sent1 es 5436, y el de sent2, 5419.

7. Eliminación de palabras semánticamente pobres (*stopwords*). El conjunto de *stopwords* utilizado ha sido el proporcionado por la librería Wordnet. Pueden consultarse en el fichero stopwords.xlsx, descargable desde la carpeta https://bit.ly/2Lv49gs.

Entrada
sent1 = 'A man is playing a large flute.'
sent2 = 'A man is playing a flute.'

Salida
tokens1 = ['man', 'playing', 'large', 'flute']
tokens2 = ['man', 'playing', 'flute']
tagged_tokens1 = [('man', 'n'), ('playing', 'v'), ('large', 'a'), ('flute', 'n')]
tagged_tokens2= [('man', 'n'), ('playing', 'v'), ('flute', 'n')]
stops1 = [('a', 'DET'), ('is', 'v'), ('a', 'DET')]
stops2 = [('a', 'DET'), ('is', 'v'), ('a', 'DET')]

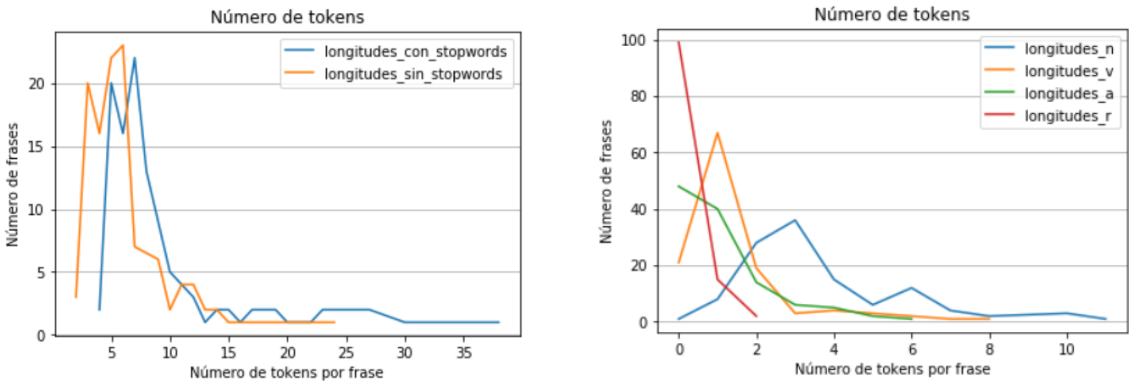

Figura 1: Distribución de frecuencias de los tokens en las frases. La primera gráfica muestra el número de frases (eje vertical) que contiene un determinado número de tokens (eje horizontal), con y sin "stopwords". La segunda gráfica muestra el número de frases que tienen un determinado número de tokens de una categoría determinada (n indica "nombres", v, "verbos", a, "adjetivos" y r, "adverbios"

3. SIMILITUD LÉXICA

3.1 Aproximaciones realizadas

Para estimar la similitud de las frases nos hemos basado la similitud léxica de los componentes (*tokens*) de las frases, dos a dos. La similitud léxica se ha calculado siguiendo dos aproximaciones:

A) Solapamiento literal

En esta aproximación se ha considerado que dos palabras son iguales si son ortográficamente idénticas. En esta aproximación, la similitud léxica es una variable binaria.

B) Solapamiento de *synsets*

En esta aproximación se ha considerado que dos palabras son iguales si sus correspondientes *synsets* de la librería Wordnet son el mismo. En esta aproximación, la similitud léxica es una variable binaria.

C) Similitud de *synsets*

En esta aproximación se han utilizado varios métodos incluidos en NLTK, los cuales realizan una estimación de la similitud entre dos palabras basándose en la ontología Wordnet. En algunos casos, estos métodos añaden información relativa a la especificidad de las palabras basándose en corpus estructurados (*information content*, IC). En estos métodos, la similitud léxica es una variable continua, cuyo rango de valores depende del método en concreto.

3.2 Asignación de *synsets*

Para poder implementar las aproximaciones B y C, ha sido necesario asignar *synsets* de la red semántica Wordnet a cada uno de los *tokens* generados durante el preprocesamiento.

La ontología Wordnet es una gran base de datos léxica que agrupa los nombres, verbos, adjetivos y adverbios en conjuntos de sinónimos llamados *synsets* , los cuales relaciona entre sí mediante distintos tipos de relación semántica (hiperonimia, homonimia, meronimia, etc.). La librería NLTK incluye toda una serie de métodos que permiten utilizar estas relaciones para realizar distintas operaciones de procesamiento del lenguaje, como establecer la similitud entre *synsets*.

En Wordnet, una misma palabra puede pertenecer a más de un *synset*, si es polisémica. Por este motivo, la asignación de *synsets* no es trivial, sino que requiere aplicar algún criterio de selección. En este proyecto se han realizado los cálculos aplicando en cada caso uno de estos dos métodos:

I. Asignación del primer *synset* proporcionado por Wordnet, que corresponde al más común para esa palabra.
II. Asignación por desambiguación utilizando la librería WSD.

Tras estas operaciones, para cada par de frases F_1 y F_2 se han obtenido dos colecciones de *synsets*, $S_1 = \{ synset_{11} , ... , synset_{1m} \}_1$ y $S_2 = \{ synset_{21} , ... , synset_{2o} \}_2$. Las palabras que para las que la librería no ha encontrado *synset* se han agrupado en dos nuevos conjuntos, $E_1 = \{ error_{11} , ... , synset_{1p} \}_1$ y $E_2 = \{ synset_{21} , ... , synset_{2q} \}_2$.

Entrada

```
tagged_tokens1 = [('man', 'n'), ('playing', 'v'), ('large', 'a'), ('flute', 'n')]
tagged_tokens2=  [('man', 'n'), ('playing', 'v'), ('flute', 'n')]
```

Salida

```
syns1 = [Synset('man.n.01'), Synset('play.v.01'), Synset('large.a.01'), Synset('flute.n.01')]
syns2 = [Synset('man.n.01'), Synset('play.v.01'), Synset('flute.n.01')]
errores1 = []
errores2 = []
```

3.3 Descripción de los métodos de similitud de synsets

Los métodos utilizados para estimar la similitud de *synsets* dos a dos de la aproximación C han sido: Longitud del camino más corto

- Leacock-Chodorow
- Wu-Palmer
- Resnik
- Jiang-Conrath
- Lin

Para los métodos Resnik, Jiang-Conrath y Lin, los cuales, para asignar valores de similitud a los *synsets* comparados requieren calcular su frecuencia relativa en algún corpus de texto, se han utilizado diccionarios *information content* basados en los corpus siguientes:

- Brown
- Semcor
- Genesis

El módulo *similarity* de la librería NLTK incluye todos estos métodos, por lo que no ha sido necesario programarlos. Sin embargo, las distintas funciones utilizan fórmulas y criterios diferentes para la asignación de valores, de modo que los resultados obtenidos para una misma pareja de *synsets* difieren significativamente, sin que esto signifique que los resultados sean contradictorios si se interpretan de forma correcta. Por ello, antes de proceder a su uso para la comparación de frases, se ha hecho un breve análisis con un 10% de los datos, cuyos resultados se muestran en la tabla 3[3].

Método	Función NLTK	Categorías gramaticales aceptadas	Rango de resultados (sin incluir valores infinitos)	Valores infinitos	Modificaciones
Longitud del camino más corto	path_similarity(synset1, synset2)	N, V (para el resto devuelve 1 si los synsets son idénticos, y "None" si son distintos	[0-1]	No	
Leacock-Chodorow	lch_similarity(synset1, synset)	N, V (para el resto devuelve None si mismos POS y error si POS distintos)	[0-3.64]	No	
Wu-Palmer	wu_similarity(synset1, synset)	N, V (para el resto devuelve None si mismos POS y error si POS distintos)	[0-1]	No	
Resnik Corpus: Brown	res_similarity(synset1, synset)	N, V (para el resto devuelve error)	[0-14.47]	Sí: cuando los dos synsets son idénticos y no se encuentran en el diccionario IC	Para valores infinitos (>100), se ha asignado el valor 9.04

[3] En algunos casos la proporción de BoS analizada ha sido ligeramente inferior al 10% debido a limitaciones en la capacidad de cálculo de nuestros recursos, pero esto no debería afectar a los resultados, de tipo orientativo, que se buscan.

Jiang-Conrath Corpus: Brown	jcn_similarity(synset1, synset)	N, V (en otros casos da infinito)	[0-1]	Sí: cuando los synsets son idénticos, independientemente de si están o no en el diccionario IC	Para valores infinitos (>100), se ha asignado el valor 1.
Lin Corpus: Brown	lin_similarity(synset1, synset)	N, V (en otros casos da error)	[0-1]	No	

Tabla 3: Análisis de las funciones de similitud incluidas en NLTK a partir de una colección de synsets obtenido a partir del 10% de nuestro fichero de referencia (544 synsets distintos, 184.418 combinaciones de synsets dos a dos). En la columna "Rango de resultados" se ha incrementado se han excluido los valores infinitos y se ha redondeado por encima.

Consideraciones

Categorías gramaticales

Las funciones de similitud de NLTK utilizadas solo funcionan cuando los *synsets* a comparar son ambos o bien nombres, o bien verbos. El resultado cuando las categorías gramaticales son distintas o cuando se trata de adjetivos o adverbios difiere en las distintas funciones (véase la tabla 3), pero salvo en reducidas excepciones, siempre es error o incorrecto[4].

Tratamiento de infinitos

Como puede verse en la tabla, las funciones Resnik y Jiang-Conrath pueden devolver valores infinitos (o, más exactamente, de 10^{300}) en caso de que los *synsets* sean idénticos. Estos valores distorsionan totalmente las estimaciones a nivel de frase, ya que determinan por completo el valor total de la similitud, que debería tener en cuenta todos los *synsets*. Por este motivo estas dos funciones han sido modificadas, limitando el valor asignado en estos casos a un valor fijo, finito, consecuente con los valores de similitud asignados a otros pares de *synsets*. Este valor ha sido asignado siguiendo los siguientes criterios:

- Función Resnik: De los cálculos hechos para los *synsets* obtenidos del 10% de los datos, se ha observado que, cuando los *synsets* son idénticos y están en el diccionario IC, los valores asignados por esta función no son siempre el máximo (14,47), sino que oscilan dentro del rango [2,3-14,47]. La media ponderada, dentro de este rango, de las similitudes entre las parejas de *synsets* analizadas es de 9.04. Este es el valor que se ha asignado a las parejas de *synsets* idénticos que no están en el corpus.
- Función Jiang-Conrath: Esta función devuelve siempre valores inferiores a 1 si los *synsets* son distintos, pero los valores se acercan asintóticamente a este límite cuando los *synsets* son semánticamente parecidos. El valor asignado a *synsets* idénticos, pues, ha sido 1.

[4] Todas las funciones de similitud de NLTK consideradas se basan en las jerarquías de la ontología Wordnet, que agrupa los nombres, verbos, adjetivos y adverbios en redes semánticas independientes. De estas redes semánticas, solo las correspondientes a nombres y verbos son jerárquicas, existiendo nodos raíz (uno en el caso de los nombres, "*entity*", y varios en el caso de los verbos) a partir de los cuales el resto de *synsets* se colocan en ramificaciones según relaciones de hiperonimia, hiponimia, meronimia y troponimia.

En la segunda parte de este proyecto se propondrán nuevas aproximaciones para abordar el problema de la similitud de *synsets* de distintas categorías gramaticales, así como de adjetivos y adverbios, las cuales, debido al alcance limitado del proyecto, no se han podido implementar.

4. SIMILITUD A NIVEL DE FRASE

Para cada aproximación léxica A, B, C mencionada en el apartado anterior, se ha calculado la similitud a nivel de frase siguiendo una aproximación adecuada, a partir de la cual se ha obtenido el valor entre cero y uno para cada para cada par de frases. Para ello, ha sido necesario crear nuevos conjuntos de palabras y *synsets*, tal como se describe a continuación.

4.1 Creación de *bags of synsets* (BoS) y *bags of words* (BoW)

A partir de los conjuntos creados según se explica en el apartado 4.1 se han creado los siguientes nuevos conjuntos:

- *Synsets* de nombres y verbos:

  $S_{1,nv}$ = {*synset* | *synset* es nombre o verbo}$_1$
  $S_{2,nv}$ = {*synset* | *synset* es nombre o verbo}$_2$

- *Synsets* de otras categorías

  $S_{1,otros} = S_{1,nv} - S_1$
  $S_{2,otros} = S_{2,nv} - S_2$

- *Bags of synsets* y *bags of words*

  $BoS = S_1 \cup S_2$

  $BoS_{nv} = S_{1,nv} \cup S_{2,nv}$

  $BoW_{errores} = E_1 \cup E_2$

Para valorar el efecto de estos errores, se han considerado dos aproximaciones:

A. Cálculo con todos los *synsets* (S_1, S_2 y BoS)
B. Cálculo con los *synsets* de las categorías N y V ($S_{1,nv}$, $S_{2,nv}$ y BoS)

Con esta ordenación de los datos, ya se ha podido proceder a calcular la similitud a nivel de frase.

4.2 Aproximación A: Solapamiento literal

En este método se cuentan las palabras que coinciden en ambas frases, y el resultado se divide por la suma de palabras que constituyen cada una de las frases (Gonzalez-Agirre, 2017):

$$sim(F_1, F_2) = \frac{2 * |Nº\ palabras\ coincidentes|}{|Nº\ palabras\ F_1| + |Nº\ palabras\ F_2|}$$

Las palabras repetidas no se han tenido en cuenta. Es decir, para cada frase, se han contado únicamente las palabras únicas.

Esta fórmula se ha implementado en Python y se ha aplicado a los conjuntos de *tokens* generados en el apartado 3, es decir, no se han incluido las *stopwords*.

Entrada
```
tokens1 = ['man', 'playing', 'large', 'flute']
```

```
tokens2 = ['man', 'playing', 'flute']

Algoritmo
   len1 = len(tokens1)
   len2 = len(tokens2)
   alineados = len([word for word in tokens1 if word in tokens2])
   similitud = 2 * alineados / (len1 + len2)

Salida
0,857142857
```

4.3 Aproximación B: Solapamiento de *synsets*

En este método se ha aplicado exactamente la misma fórmula que en la aproximación A, pero en lugar de las palabras, se han contado los *synsets* de cada frase y los *synsets* comunes.

```
Entrada
syns1 = [Synset('man.n.01'), Synset('play.v.01'), Synset('large.a.01'), Synset('flute.n.01')]
syns2 = [Synset('man.n.01'), Synset('play.v.01'), Synset('flute.n.01')]
bos =  [Synset('man.n.01'), Synset('play.v.01'), Synset('large.a.01'), Synset('flute.n.01')]

Salida
0,857142857142857
```

4.4 Aproximación B: Distancia coseno de vectores definidos según similitud léxica

En este método, para cada par de frases se crea un espacio vectorial cuyas dimensiones se corresponden a cada uno de los *synsets* del conjunto formado por la unión de *synsets* de ambas frases, y cada frase se representa mediante un vector en este espacio. El valor de cada componente del vector frase se obtiene calculando la similitud de la palabra cuya dimensión representa, con las palabras de la frase (Hongzhe & Wang, 2013) ; la similitud entre frases, se corresponde con el coseno de los dos vectores obtenidos:

$$sim(F_1, F_2) = \cos(V_1, V_2)$$

Para aplicar este método, se han seguido los siguientes pasos.

Cálculo de los vectores semánticos

Dado el espacio creado por BoS,

$$\text{BoS} = \{synset_1, \ldots, synset_n\}$$

Para cada conjunto

$$S_1 = \{synset_{11}, \ldots, synset_{1m}\}$$

$$S_2 = \{synset_{21}, \ldots, synset_{1o}\}$$

se han generado los vectores

$$V_1 = (v_{11},\ldots, v_{1n}\}$$

$$V_2 = \{v_{21},\ldots, v_{1n}\}$$

donde cada componente se ha calculado utilizando una función de similitud léxica según esta fórmula:

$$v_{ij} = \max_{k}(\text{sim_lexica}(synset_{ik}, synset_{j})$$

Entrada
syns1 = [*Synset*('man.n.01'), *Synset*('play.v.01'), *Synset*('large.a.01'), *Synset*('flute.n.01')]
syns2 = [*Synset*('man.n.01'), *Synset*('play.v.01'), *Synset*('flute.n.01')]

Salida
bow = [*Synset*('large.a.01'), *Synset*('flute.n.01'), *Synset*('play.v.01'), *Synset*('man.n.01')]
v1_ps = [1. 1. 1. 1.]
v2_ps = [0. 1. 1. 1.]
v1_lch =[0. 3.63758616 3.25809654 3.63758616]
v2_lch = [0. 3.63758616 3.25809654 3.63758616]
etc.

Los cálculos mismos se han repetido utilizando BoS_{nv}, $S_{1,nv}$, S_{2nv} en vez de BoS, S_1, S_2.

Entrada
syns1_nv = [*Synset*('man.n.01'), *Synset*('play.v.01'), *Synset*('flute.n.01')]
syns2_nv = [*Synset*('man.n.01'), *Synset*('play.v.01'), *Synset*('flute.n.01')]

Salida
bow_nv = [*Synset*('flute.n.01'), *Synset*('play.v.01'), *Synset*('man.n.01')]
v1_ps = [1. 1. 1.]
v2_ps = [1. 1. 1.]
v1_lch = [3.63758616 3.25809654 3.63758616]
v2_lch = [3.63758616 3.25809654 3.63758616]
etc.

Cálculo de la distancia coseno

Para cada par de frases, la similitud a nivel de frase se ha obtenido calculando el coseno de los vectores asociados.

```
Entrada (caso A)
v1_ps = [1.    1.    1.    1.]
v2_ps = [0.    1.    1.    1.]
v1_lch =[0.     3.63758616     3.25809654     3.63758616]
v2_lch = [0.    3.63758616     3.25809654     3.63758616]
etc.

Salida
puntuacion_lw_ps = 0,857142857
puntuacion_lw_lch = 0,972270396
```

Los cálculos mismos se han repetido utilizando BoS_{nv}, $S_{1,nv}$, S_{2nv} en vez de BoS, S_1, S_2.

```
Entrada (caso B)
v1_ps = [1.   1.   1.]
v2_ps = [1.   1.   1.]
v1_lch = [3.63758616     3.25809654     3.63758616]
v2_lch = [3.63758616     3.25809654     3.63758616]
etc.

Salida
puntuacion_lw_ps = 1
puntuacion_lw_lch = 1
```

5. RESULTADOS

Tras aplicar cada uno de los algoritmos, se ha obtenido una puntuación dentro del rango [0,1] para cada par de frases y para cada aproximación. Los resultados obtenidos en cada aproximación se han comparado con las puntuaciones *gold score* del fichero original mediante la métrica Pearson, que calcula la correlación entre dos conjuntos de valores. El valor de la correlación de Pearson para cada las distintas aproximaciones pueden consultarse en los gráficos de la página siguiente, en los que hemos clasificado los pares de frases según su género. En cada histograma se indica el valor de la correlación y el porcentaje de frases en que se basa el cálculo. Esto se ha realizado porque en algunos de los métodos aplicados, en particular cuando se consideran adjetivos y adverbios, las funciones de similitud dan error, y no se realiza el cálculo.

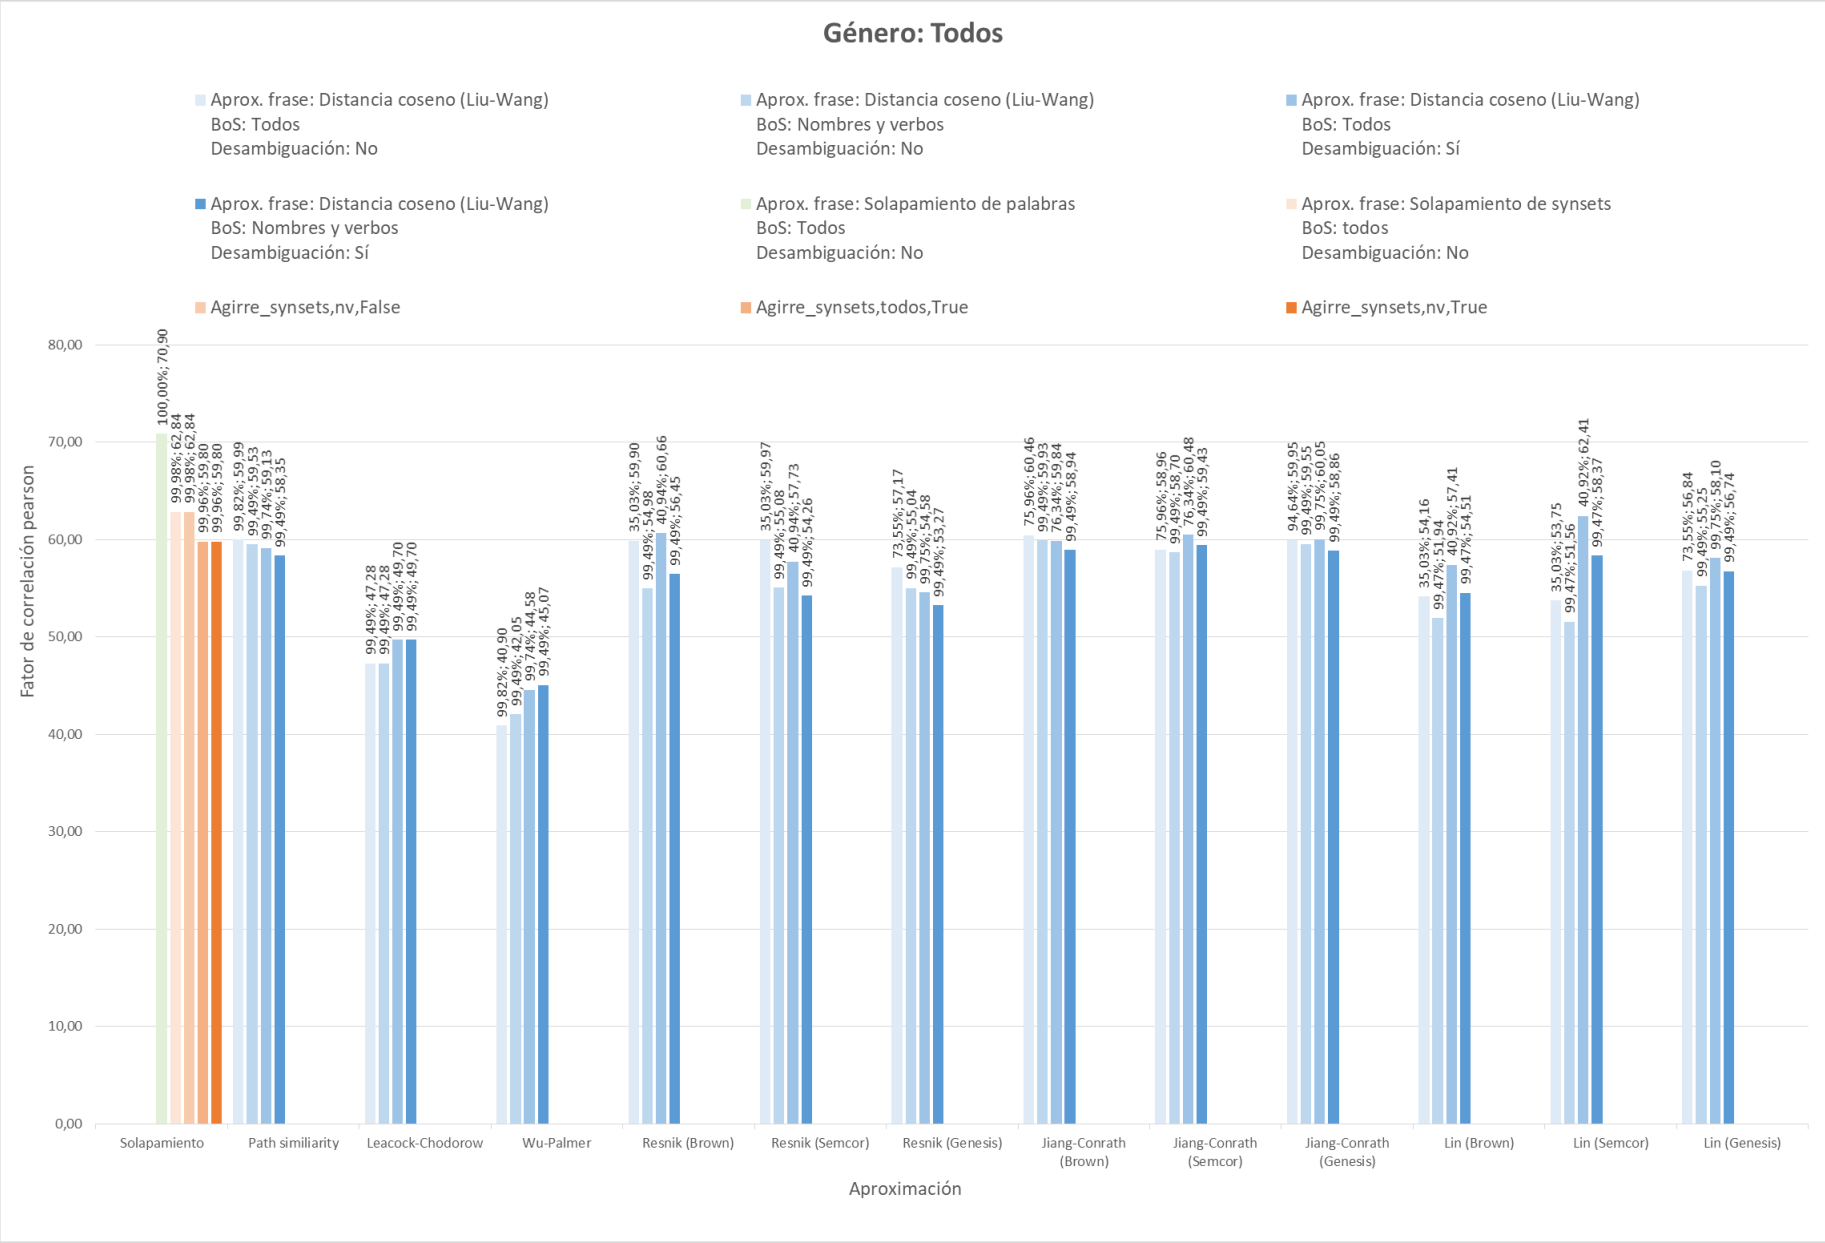
Género: Todos
Aprox. frase: Distancia coseno (Liu-Wang) BoS: Todos Desambiguación: No
Aprox. frase: Distancia coseno (Liu-Wang) BoS: Nombres y verbos Desambiguación: No
Aprox. frase: Distancia coseno (Liu-Wang) BoS: Todos Desambiguación: Sí
Aprox. frase: Distancia coseno (Liu-Wang) BoS: Nombres y verbos Desambiguación: Sí
Aprox. frase: Solapamiento de palabras BoS: Todos Desambiguación: No
Aprox. frase: Solapamiento de synsets BoS: todos Desambiguación: No
Agirre_synsets,nv,False
Agirre_synsets,todos,True
Agirre_synsets,nv,True
Fator de correlación pearson
80,00
70,00
60,00
50,00
40,00
30,00
20,00
10,00
0,00
100,00%; 70,90
99,98%; 62,84
99,98%; 62,84
99,96%; 59,80
99,96%; 59,80
99,82%; 59,99
99,49%; 59,53
99,74%; 59,13
99,49%; 58,35
99,49%; 47,28
99,49%; 47,28
99,49%; 49,70
99,49%; 49,70
99,82%; 40,90
99,49%; 42,05
99,74%; 44,58
99,49%; 45,07
35,03%; 59,90
99,49%; 54,98
40,94%; 60,66
99,49%; 56,45
35,03%; 59,97
99,49%; 55,08
40,94%; 57,73
99,49%; 54,26
73,55%; 57,17
99,49%; 55,04
99,75%; 54,58
99,49%; 53,27
75,96%; 60,46
99,49%; 59,93
76,34%; 59,84
99,49%; 58,94
75,96%; 58,96
99,49%; 58,70
76,34%; 60,48
99,49%; 59,43
94,64%; 59,95
99,49%; 59,55
99,75%; 60,05
99,49%; 58,86
35,03%; 54,16
99,47%; 51,94
40,92%; 57,41
99,47%; 54,51
35,03%; 53,75
99,47%; 51,56
40,92%; 62,41
99,47%; 58,37
73,55%; 56,84
99,49%; 55,25
99,75%; 58,10
99,49%; 56,74
Solapamiento
Path similiarity
Leacock-Chodorow
Wu-Palmer
Resnik (Brown)
Resnik (Semcor)
Resnik (Genesis)
Jiang-Conrath (Brown)
Jiang-Conrath (Semcor)
Jiang-Conrath (Genesis)
Lin (Brown)
Lin (Semcor)
Lin (Genesis)
Aproximación

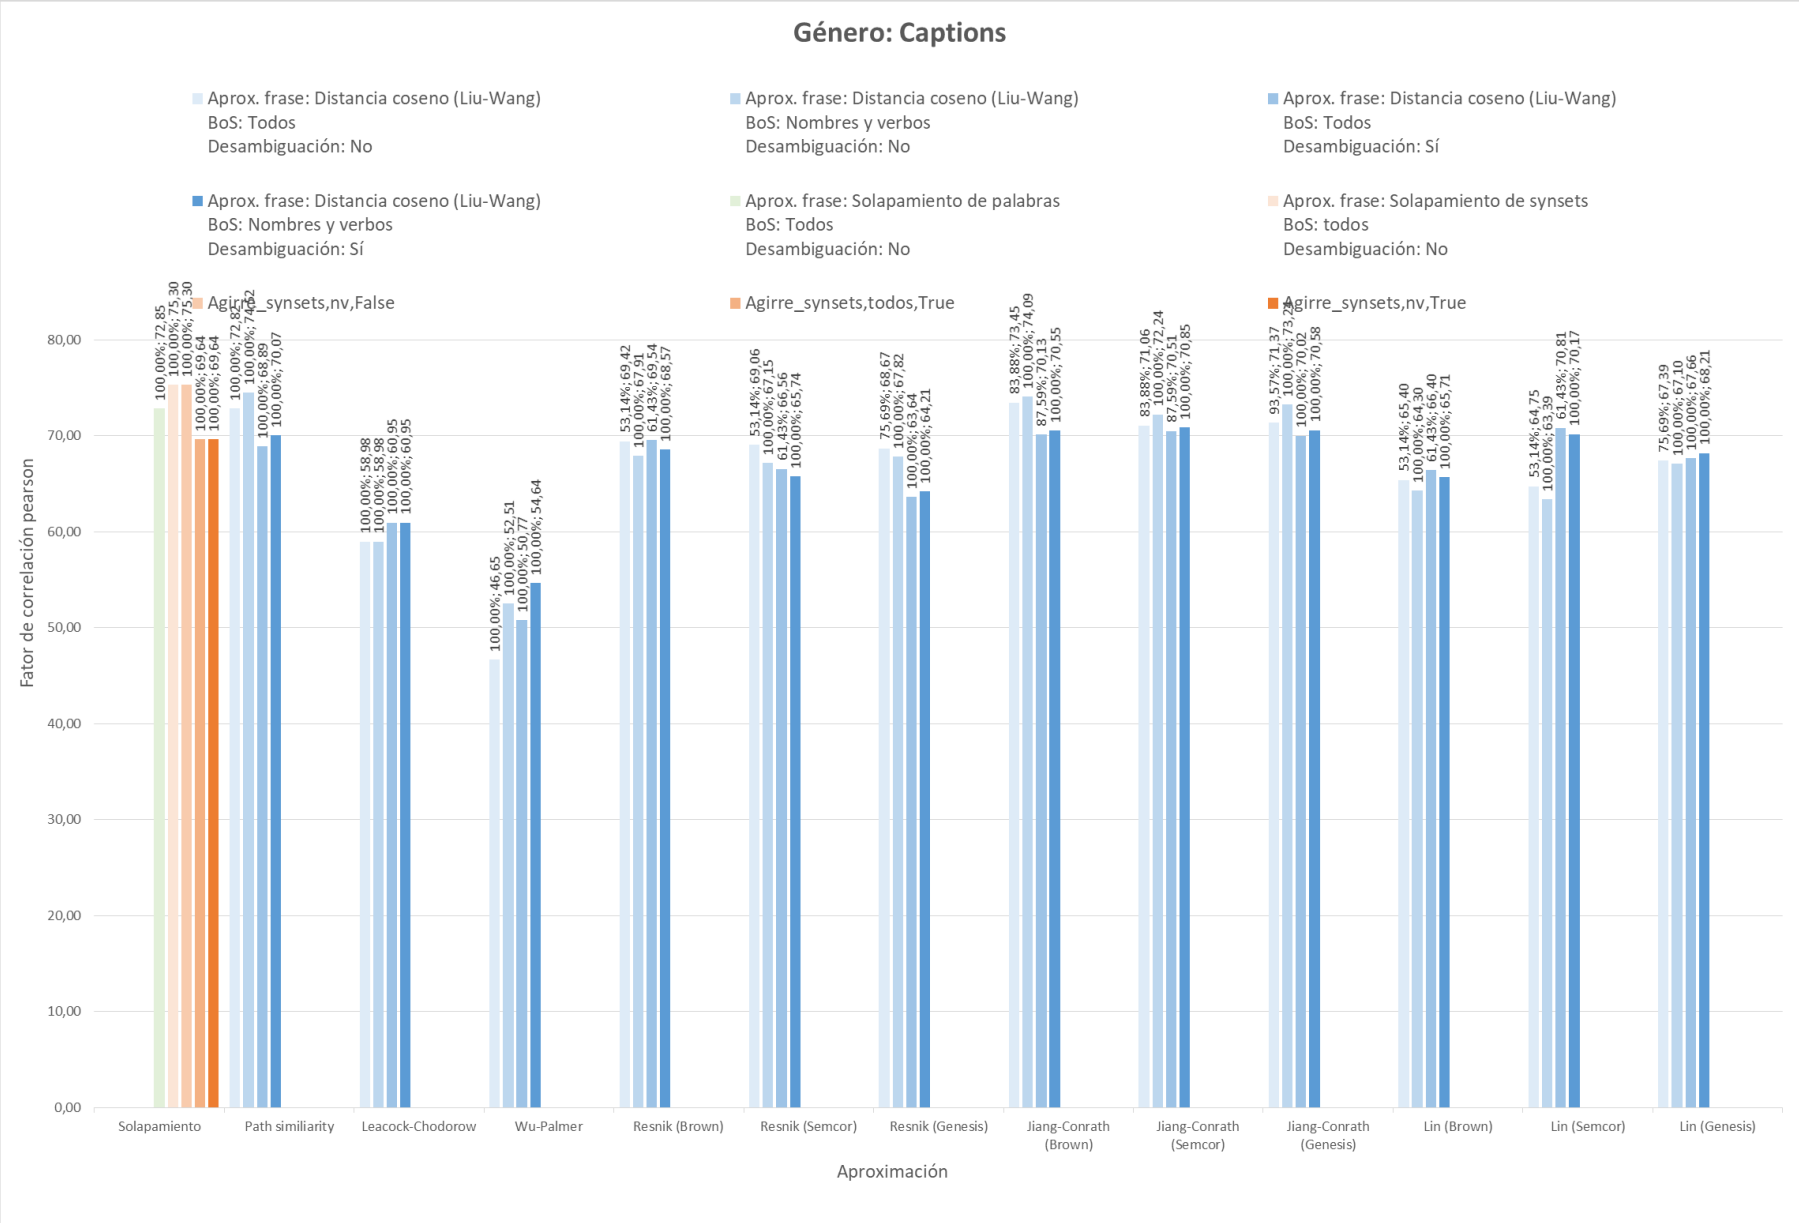
Género: Captions
Aprox. frase: Distancia coseno (Liu-Wang) BoS: Todos Desambiguación: No
Aprox. frase: Distancia coseno (Liu-Wang) BoS: Nombres y verbos Desambiguación: No
Aprox. frase: Distancia coseno (Liu-Wang) BoS: Todos Desambiguación: Sí
Aprox. frase: Distancia coseno (Liu-Wang) BoS: Nombres y verbos Desambiguación: Sí
Aprox. frase: Solapamiento de palabras BoS: Todos Desambiguación: No
Aprox. frase: Solapamiento de synsets BoS: todos Desambiguación: No
Agirre_synsets,nv,False
Agirre_synsets,todos,True
Agirre_synsets,nv,True
Fator de correlación pearson
0,00
10,00
20,00
30,00
40,00
50,00
60,00
70,00
80,00
Solapamiento
Path similiarity
Leacock-Chodorow
Wu-Palmer
Resnik (Brown)
Resnik (Semcor)
Resnik (Genesis)
Jiang-Conrath (Brown)
Jiang-Conrath (Semcor)
Jiang-Conrath (Genesis)
Lin (Brown)
Lin (Semcor)
Lin (Genesis)
Aproximación

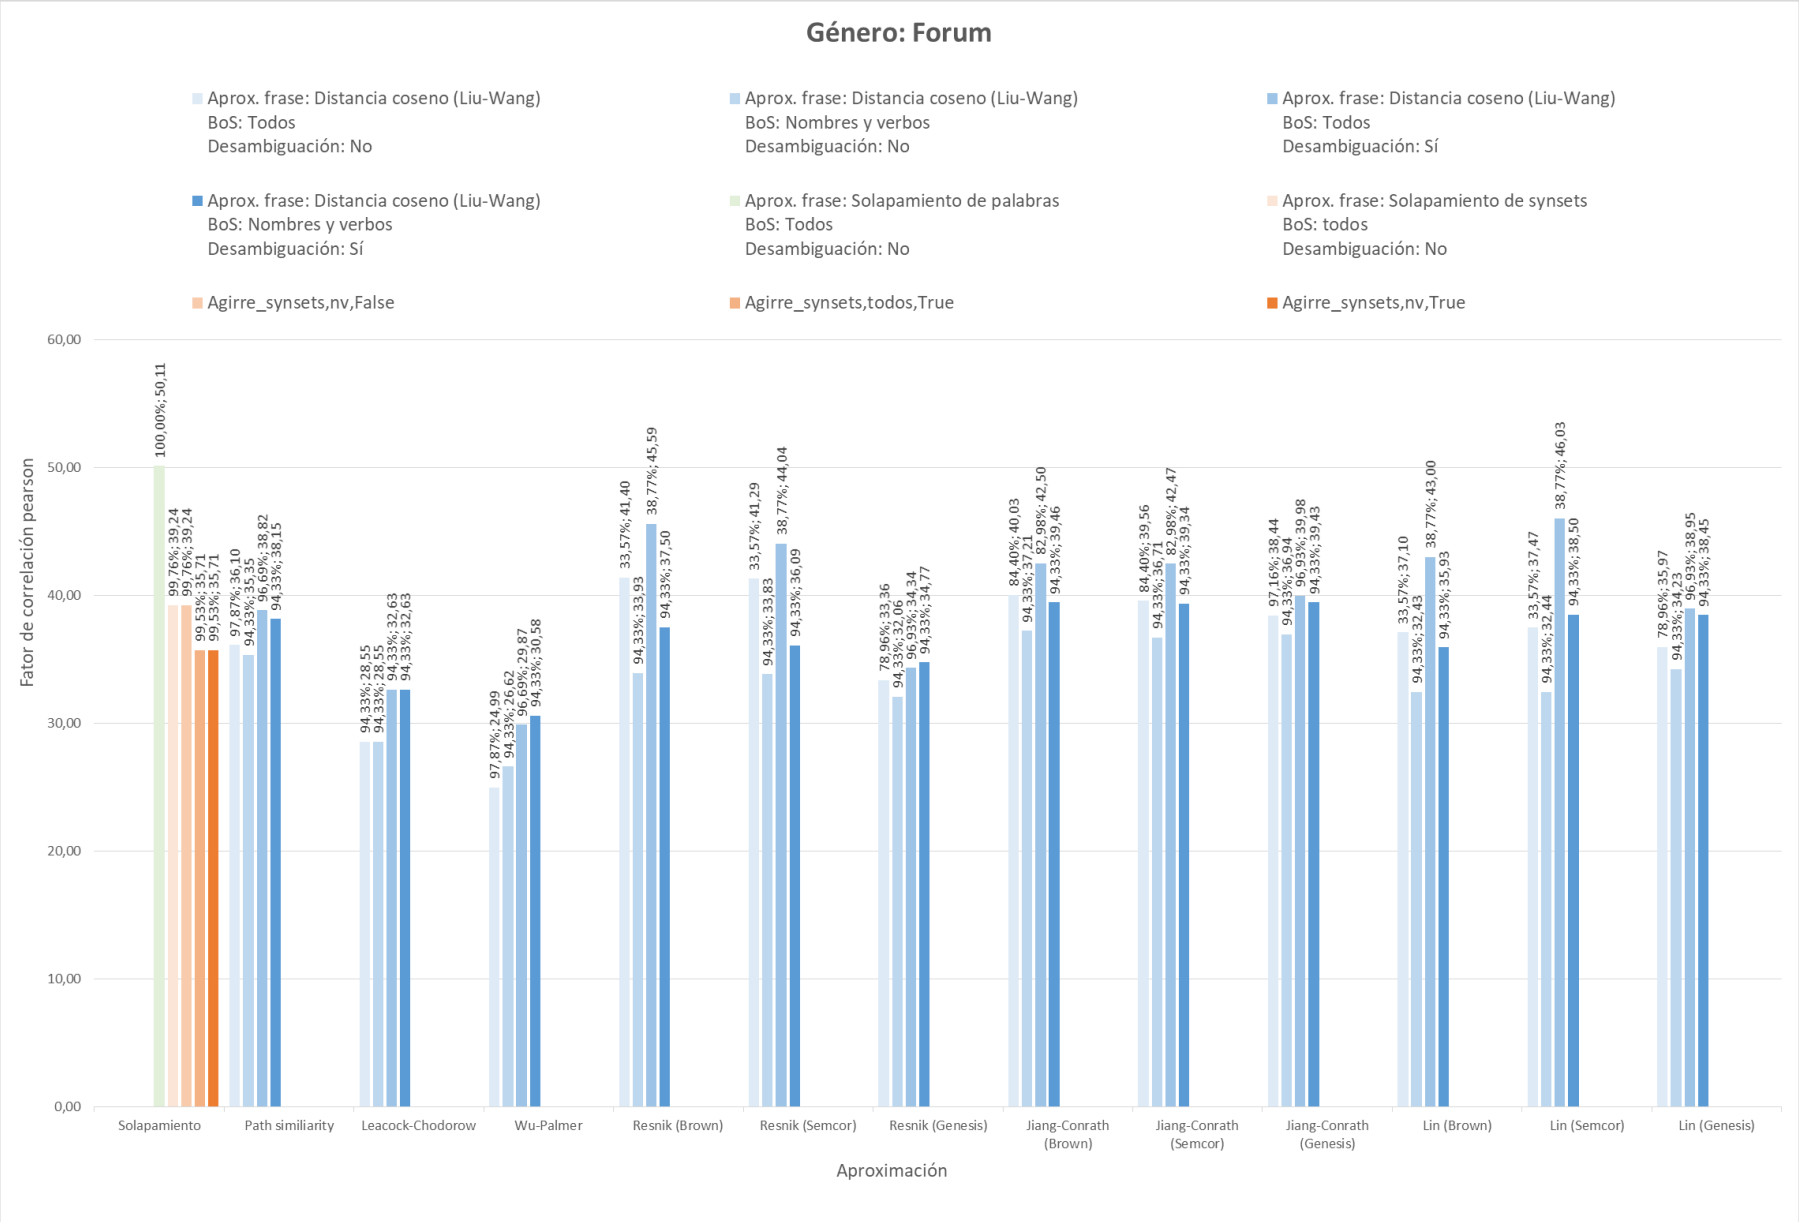
Género: Forum
Aprox. frase: Distancia coseno (Liu-Wang) BoS: Todos Desambiguación: No
Aprox. frase: Distancia coseno (Liu-Wang) BoS: Nombres y verbos Desambiguación: No
Aprox. frase: Distancia coseno (Liu-Wang) BoS: Todos Desambiguación: Sí
Aprox. frase: Distancia coseno (Liu-Wang) BoS: Nombres y verbos Desambiguación: Sí
Aprox. frase: Solapamiento de palabras BoS: Todos Desambiguación: No
Aprox. frase: Solapamiento de synsets BoS: todos Desambiguación: No
Agirre_synsets,nv,False
Agirre_synsets,todos,True
Agirre_synsets,nv,True
Fator de correlación pearson
60,00
50,00
40,00
30,00
20,00
10,00
0,00
100,00%; 50,11
99,76%; 39,24
99,76%; 39,24
99,53%; 35,71
99,53%; 35,71
97,87%; 36,10
94,33%; 35,35
96,69%; 38,82
94,33%; 38,15
94,33%; 28,55
94,33%; 28,55
94,33%; 32,63
94,33%; 32,63
97,87%; 24,99
94,33%; 26,62
96,69%; 29,87
94,33%; 30,58
33,57%; 41,40
94,33%; 33,93
38,77%; 45,59
94,33%; 37,50
33,57%; 41,29
94,33%; 33,83
38,77%; 44,04
94,33%; 36,09
78,96%; 33,36
94,33%; 32,06
96,93%; 34,34
94,33%; 34,77
84,40%; 40,03
94,33%; 37,21
82,98%; 42,50
94,33%; 39,46
84,40%; 39,56
94,33%; 36,71
82,98%; 42,47
94,33%; 39,34
97,16%; 38,44
94,33%; 36,94
96,93%; 39,98
94,33%; 39,43
33,57%; 37,10
94,33%; 32,43
38,77%; 43,00
94,33%; 35,93
33,57%; 37,47
94,33%; 32,44
38,77%; 46,03
94,33%; 38,50
78,96%; 35,97
94,33%; 34,23
96,93%; 38,95
94,33%; 38,45
Solapamiento
Path similiarity
Leacock-Chodorow
Wu-Palmer
Resnik (Brown)
Resnik (Semcor)
Resnik (Genesis)
Jiang-Conrath (Brown)
Jiang-Conrath (Semcor)
Jiang-Conrath (Genesis)
Lin (Brown)
Lin (Semcor)
Lin (Genesis)
Aproximación

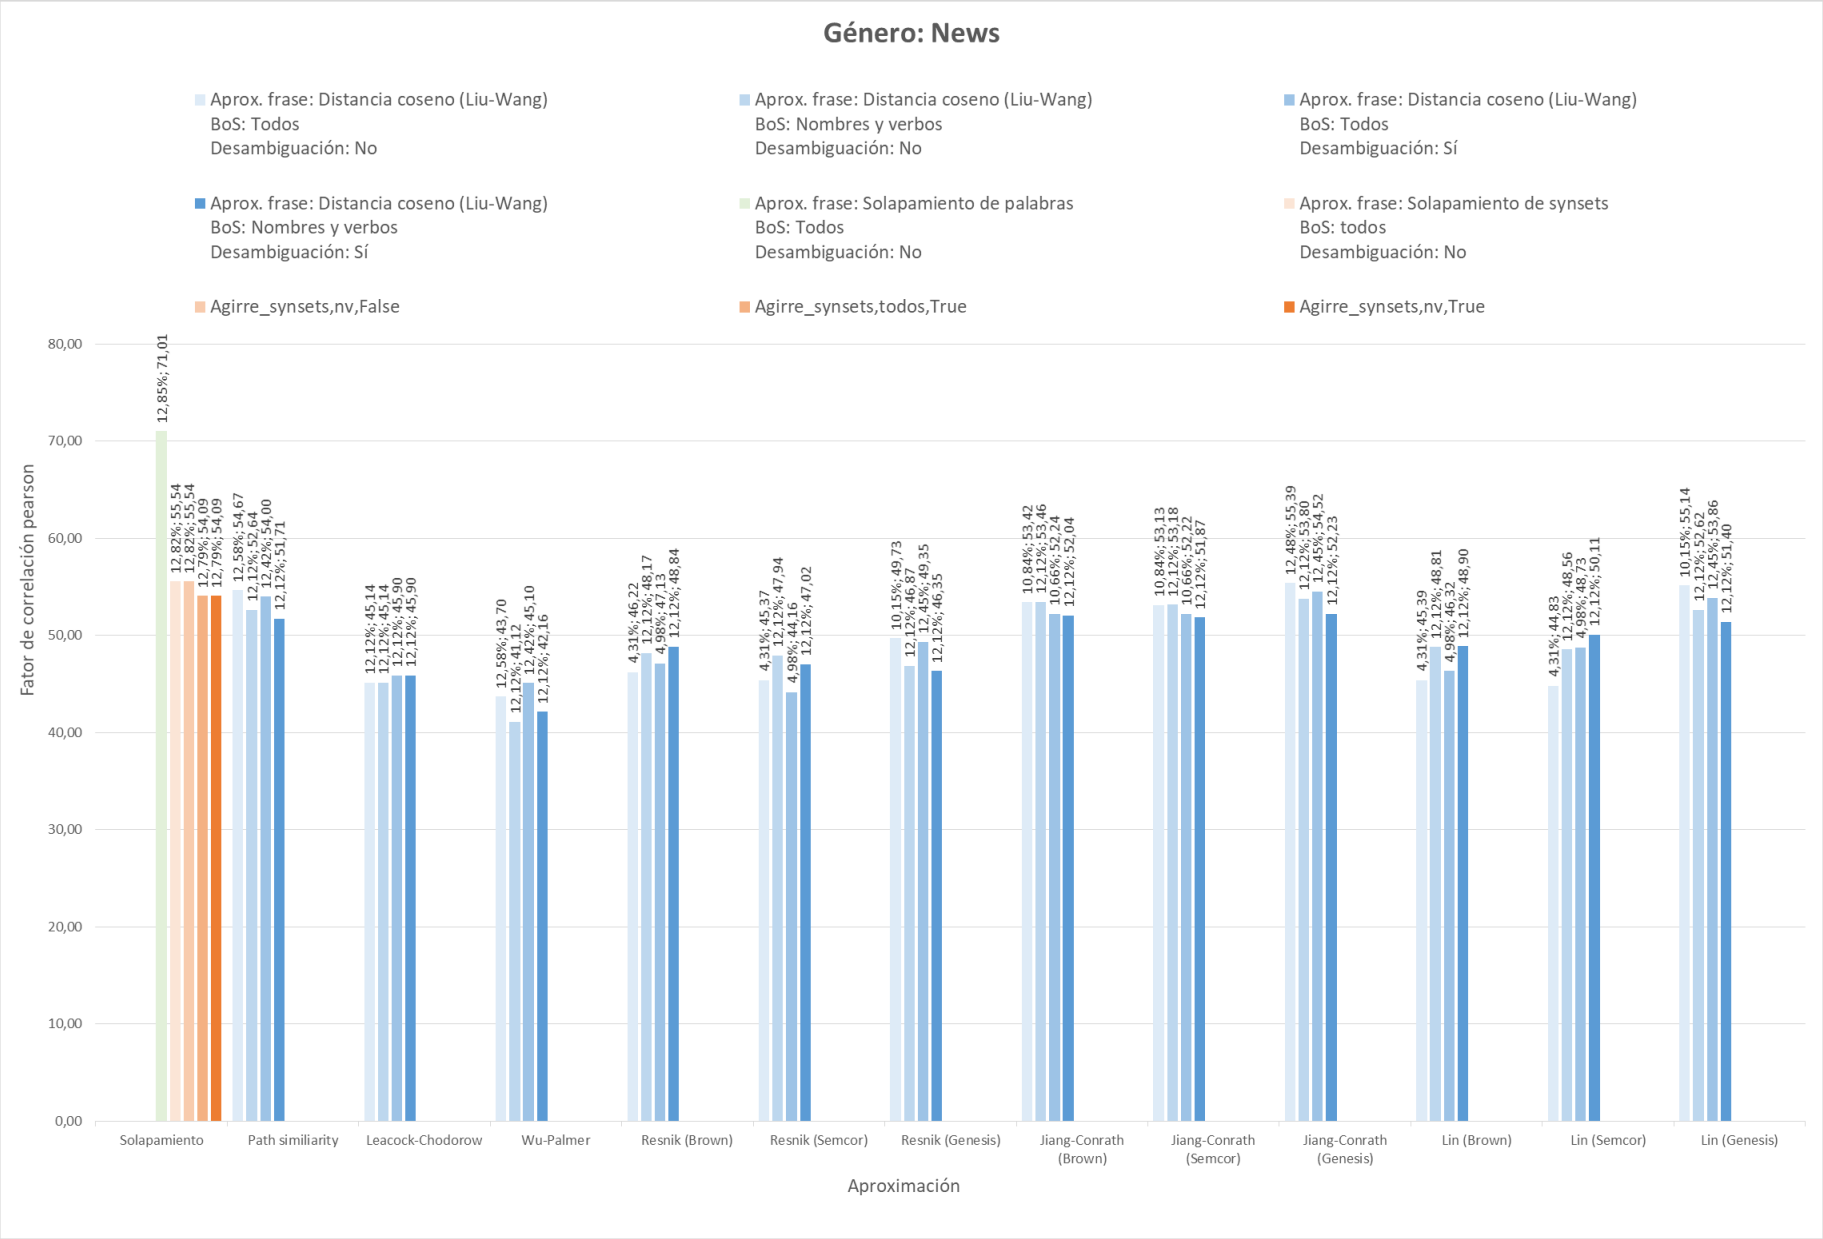
Género: News
Aprox. frase: Distancia coseno (Liu-Wang) BoS: Todos Desambiguación: No
Aprox. frase: Distancia coseno (Liu-Wang) BoS: Nombres y verbos Desambiguación: No
Aprox. frase: Distancia coseno (Liu-Wang) BoS: Todos Desambiguación: Sí
Aprox. frase: Distancia coseno (Liu-Wang) BoS: Nombres y verbos Desambiguación: Sí
Aprox. frase: Solapamiento de palabras BoS: Todos Desambiguación: No
Aprox. frase: Solapamiento de synsets BoS: todos Desambiguación: No
Agirre_synsets,nv,False
Agirre_synsets,todos,True
Agirre_synsets,nv,True
Fator de correlación pearson
80,00
70,00
60,00
50,00
40,00
30,00
20,00
10,00
0,00
12,85%;71,01
12,82%;55,54
12,82%;55,54
12,79%;54,09
12,79%;54,09
12,58%;54,67
12,12%;52,64
12,42%;54,00
12,12%;51,71
12,12%;45,14
12,12%;45,14
12,12%;45,90
12,12%;45,90
12,58%;43,70
12,12%;41,12
12,42%;45,10
12,12%;42,16
4,31%;46,22
12,12%;48,17
4,98%;47,13
12,12%;48,84
4,31%;45,37
12,12%;47,94
4,98%;44,16
12,12%;47,02
10,15%;49,73
12,12%;46,87
12,45%;49,35
12,12%;46,35
10,84%;53,42
12,12%;53,46
10,66%;52,24
12,12%;52,04
10,84%;53,13
12,12%;53,18
10,66%;52,22
12,12%;51,87
12,48%;55,39
12,12%;53,80
12,45%;54,52
12,12%;52,23
4,31%;45,39
12,12%;48,81
4,98%;46,32
12,12%;48,90
4,31%;44,83
12,12%;48,56
4,98%;48,73
12,12%;50,11
10,15%;55,14
12,12%;52,62
12,45%;53,86
12,12%;51,40
Solapamiento
Path similiarity
Leacock-Chodorow
Wu-Palmer
Resnik (Brown)
Resnik (Semcor)
Resnik (Genesis)
Jiang-Conrath (Brown)
Jiang-Conrath (Semcor)
Jiang-Conrath (Genesis)
Lin (Brown)
Lin (Semcor)
Lin (Genesis)
Aproximación

BIBLIOGRAFÍA

Diab, M., Cer, D., Specia, L., Agirre, E., & López-Gazpio, I. (2017). SemEval-2017 Task 1: Semantic Textual Similarity Multilingual and Cross-lingual Focused Evaluation. *Proceedings of the 10th International Workshop on Semantic Evaluation*.

Gonzalez-Agirre. (2017). *Computational Models for Semantic Textual Similarity.*

Hongzhe, L., & Wang, P. (2013). Assessing Sentence Similarity Using WordNet based Word Similarity. *Journal of software*.